



Facultad de Ciencias Económicas y Empresariales
**MÁSTER UNIVERSITARIO EN INVESTIGACIÓN DE
DIRECCIÓN DE EMPRESAS, MARKETING Y CONTABILIDAD**

TRABAJO FIN DE MÁSTER

***Inteligencia Artificial aplicada al forecasting de
ventas en contextos B2B: revisión sistemática
de la literatura***

Alumno: *Iñigo Merino Ramos*

Tutor: *Dr. Mario Arias Oliva*

Julio 2026

Resumen:

El forecasting de ventas en contextos empresa-a-empresa (B2B) asiste desde hace casi dos décadas a una proliferación de propuestas algorítmicas cuya densidad técnica no ha ido acompañada de una comprensión equivalente de las condiciones organizativas que determinan si la ganancia predictiva se traduce en valor comercial real. Ese desajuste es el problema de investigación que articula el presente trabajo. Se presenta una revisión sistemática cualitativa elaborada conforme al protocolo PRISMA 2020 (Page et al., 2021) sobre un corpus de 20 artículos seleccionados mediante un sistema de puntuación ponderada a partir de 3.121 registros iniciales recuperados de Scopus y Web of Science. El análisis se organiza en torno a cuatro dimensiones conceptuales: precisión del forecasting (D1), interpretabilidad y explicabilidad (D2), adopción tecnológica (D3) y gestión del cambio organizativo (D4).

Los resultados revelan una asimetría estructural de cobertura (D1: 2,85/3; D2: 1,45/3; D3: 1,50/3; D4: 1,25/3). No se trata de un artefacto metodológico. Es el hallazgo más informativo de la revisión: el campo ha acreditado con consistencia cualitativa que los modelos de inteligencia artificial superan a los baselines estadísticos convencionales en manufactura, distribución y logística B2B, pero carece de los constructos teóricos y los diseños empíricos necesarios para explicar en qué condiciones organizativas esa ganancia predictiva se convierte en decisiones comerciales de mayor calidad. La mejora técnica resulta transferible a la práctica únicamente cuando se satisfacen de forma simultánea tres condiciones: suficiencia de volumen y calidad de datos para el entrenamiento sin sobreajuste, validación temporal estricta con separación cronológica entre entrenamiento y prueba, e interpretabilidad suficiente para que los directivos comerciales puedan justificar públicamente las decisiones basadas en el modelo. La gobernanza de datos emerge como barrera más consistente y transversal del corpus; la opacidad algorítmica constituye la segunda barrera documentada, con el caso de Bohanec et al. (2017) como ejemplar teórico que cristaliza el mecanismo de rechazo directivo por incapacidad de justificar predicciones ante la organización.

Se propone una tipología provisional de tres estadios de madurez organizativa para el forecasting algorítmico. A partir de ella se articulan dos propuestas doctorales diferenciadas: una orientada a generar la primera evidencia sistemática sobre inteligencia artificial en el forecasting de ventas en empresas de software B2B (sector estructuralmente ausente del corpus), y otra dirigida a construir el constructo de confianza algorítmica, el marco de madurez organizativa y el análisis de retorno sobre la inversión que el campo no ha producido en casi dos décadas de investigación documentada.

Palabras clave: *inteligencia artificial, forecasting de ventas, B2B, revisión sistemática de la literatura, interpretabilidad algorítmica, adopción tecnológica, gestión del cambio organizativo, confianza algorítmica*

Orientación del TFM: Académica

ÍNDICE

1. INTRODUCCIÓN	3
1.1 Contexto, delimitación y relevancia del problema	4
1.2 Marco conceptual y teórico	4
1.3 Justificación académica del estudio	6
1.4 Preguntas de investigación	7
1.5 Objetivos del estudio	7
1.6 Planteamiento y desarrollo del estudio	7
2. FUENTES DE INFORMACIÓN, PROTOCOLO DE SELECCIÓN Y MUESTRA	9
2.1 Selección de las bases de datos	10
2.2 Estrategia de búsqueda y ecuación descriptora	10
2.3 Fase 1: limpieza técnica del corpus inicial	11
2.4 Fase 2: cribado por título y resumen	12
2.5 Fase 3: cribado temático sobre B2B	13
2.6 Fase 4: priorización y selección final por sistema de puntuación	14
2.7 Muestra final (corpus): características, distribución y cobertura	16
2.8 Limitaciones metodológicas y decisiones asumidas	18
2.9 Resumen final del protocolo	19
3. REVISIÓN DE LA LITERATURA	21
3.1 Delimitación teórica del fenómeno	21
3.2 Conexión con el marco conceptual y sus dimensiones	26
3.3 Taxonomía de metodologías de IA	29
3.4 Diseño de la investigación con IA: datos, variables y protocolos	37
3.5 Resultados: magnitud y condiciones para la mejora del forecast	41
3.6 Factores organizacionales, sociotécnicos y barreras	46
3.7 Síntesis crítica: limitaciones y vacíos en la investigación	49
3.8 Respuesta a las preguntas de investigación y objetivos	52
4. AGENDA DE INVESTIGACIÓN Y FUTURAS LÍNEAS DE INVESTIGACIÓN	57
4.1. De la síntesis crítica a la formulación de una agenda	57
4.2. Líneas futuras de investigación derivadas del corpus	58
4.3. Justificación de una agenda doctoral dual	61
4.4. Propuesta doctoral A: precisión del forecasting con IA en empresas de software B2B	62
4.5. Propuesta doctoral B: interpretabilidad, confianza y adopción organizativa del forecasting algorítmico en B2B	65
4.6. Contribución integradora y cierre de la agenda	67
5. LIMITACIONES DEL ESTUDIO REALIZADO	69
5.1 Alcance y tipología de las limitaciones identificadas	69
5.2 Limitaciones del corpus y la muestra bibliográfica	70
5.3 Limitaciones del alcance analítico	71
5.4 Limitaciones teóricas y conceptuales	72
5.5 Limitaciones de transferibilidad contextual	72
5.6 Resumen de las limitaciones	73
5.7 Implicaciones de las limitaciones para la interpretación de los resultados	78
6. CONCLUSIONES	79
6.1 Síntesis integradora de hallazgos por dimensión analizada	79
6.2 Respuestas a las preguntas de investigación	82
6.3 Contribuciones del trabajo	84
6.4 Breve remisión a limitaciones	85
6.5 Reflexión de cierre	85
REFERENCIAS BIBLIOGRÁFICAS	87

1. INTRODUCCIÓN

El **forecasting de ventas** no es, en primera instancia, solo una gestión puramente estadística. Es relevante para la gestión de marketing. La capacidad de anticipar con fiabilidad el volumen de negocio futuro determina la viabilidad de las decisiones de segmentación, la calibración de las políticas de precio, la planificación de campañas comerciales y la asignación de recursos al equipo de ventas. En **entornos B2B**, donde cada cuenta concentra una fracción desproporcionada del ingreso total y los ciclos de negociación son largos, el coste de errar en la previsión es significativo. La irrupción de la inteligencia artificial está suponiendo una renovación de esta disciplina y los descubrimientos avanzan. La cuestión no es si los modelos algorítmicos predicen mejor, sino bajo qué condiciones técnicas y organizativas esa capacidad predictiva se convierte en una herramienta útil para la gestión comercial y el marketing B2B.

Ese problema combina una dimensión técnica y otra organizativa. La validez de una previsión no depende solo de la sofisticación del modelo, sino también de la calidad de los datos, de la interpretabilidad de sus salidas y de su integración en los procesos de decisión (Adadi & Berrada, 2018; Fries & Ludwig, 2024). Abordarlo con rigor exige una revisión sistemática que ordene una evidencia dispersa y conceptualmente heterogénea.

1.1 Contexto, delimitación y relevancia del problema

El forecasting de ventas constituye un instrumento de coordinación interna para las áreas de marketing y ventas. Su utilidad excede la mera proyección de cifras: **permite anticipar necesidades de producción, ajustar presupuestos, priorizar oportunidades comerciales y sincronizar la actividad comercial con finanzas y operaciones**. En B2B, donde los ciclos de venta son prolongados y el peso económico se concentra en un número reducido de cuentas, una desviación sistemática en la previsión no produce un error estadístico aislado; produce decisiones de asignación de recursos mal fundamentadas y estructuras comerciales mal coordinadas (Fischer et al., 2022; Manos et al., 2024).

La evolución metodológica del campo no ha sido lineal. Los modelos estadísticos tradicionales ofrecían una base funcional cuando las series eran estables, pero mostraban rigidez ante relaciones no lineales, señales exógenas o estructuras de datos complejas. En respuesta, la literatura ha explorado desde los primeros sistemas basados en conocimiento hasta el machine learning, el deep learning y los enfoques híbridos, con el objetivo de reducir la dependencia de supuestos funcionales rígidos y mejorar la capacidad predictiva en entornos con mayor variabilidad (Pavlyshenko, 2019; Sohrabpour et al., 2021).

Este trabajo delimita su objeto con precisión. No aborda la predicción de demanda agregada ni la optimización logística, sino el forecasting de ventas en entornos B2B como fenómeno diferenciado: la venta incorpora conversión efectiva, comportamiento comercial, interacción con cuentas y estructura del pipeline, elementos que los modelos de demanda de consumo masivo no capturan. Mezclar ambos fenómenos sin distinción conceptual debilita la comparabilidad entre estudios y distorsiona la síntesis. La pregunta que articula la revisión no es, por tanto, si la inteligencia artificial puede predecir, sino bajo qué condiciones técnicas y organizativas esa capacidad resulta transferible a la práctica comercial B2B (Hyndman & Koehler, 2006; Tashman, 2000).

1.2 Marco conceptual y teórico

La literatura sobre forecasting de ventas con inteligencia artificial puede organizarse en torno a cuatro dimensiones conceptuales que serán un eje vertebral del presente estudio.

En ese marco, la **primera dimensión conceptual** es la **precisión del forecasting**, que debe entenderse con el mayor rigor posible, ya que es el constructo base de los análisis de revisión de la literatura posteriores. La literatura sobre forecast accuracy la define como el grado de proximidad entre el valor pronosticado y el valor observado, es decir, como una medida de error de predicción que permite comparar la calidad relativa de distintos métodos. Esta idea es básica en la investigación sobre pronósticos porque la exactitud de la previsión constituye el principal criterio para evaluar si un modelo supera a otro o si resulta suficientemente válido para su uso organizativo (Hyndman & Koehler,

2006; Tashman, 2000). En términos prácticos, la precisión no es un adorno estadístico: es la variable central que permite establecer si la inteligencia artificial añade valor real al forecasting o si simplemente desplaza el problema a una técnica más sofisticada.

Ahora bien, la comparación entre métodos no puede reducirse al error agregado. La literatura reciente sobre forecasting muestra que el rendimiento de un modelo depende del tipo de negocio, la granularidad del dato, la calidad de las variables disponibles y la presencia de señales contextuales que modulan el comportamiento de la serie (Yuan & Lee, 2020). En B2B, esa advertencia es especialmente relevante, porque la información suele ser incompleta, la distribución de los datos es irregular y el impacto de pocas cuentas puede alterar de forma notable la previsión. Por ello, la revisión no debe preguntar únicamente qué algoritmo acierta más, sino en qué condiciones un algoritmo puede ser defendido como solución técnicamente sólida para un entorno comercial específico. Esta distinción es importante porque evita interpretar la mejora técnica como un resultado automático y obliga a leer los hallazgos en relación con el contexto en que se producen.




Figura 1 - Diagrama de delimitación de las cuatro dimensiones conceptuales (elaboración propia)

La **segunda dimensión conceptual** es la **interpretabilidad**. La literatura sobre inteligencia artificial aplicada a forecasting muestra que el aumento de precisión no garantiza por sí mismo una mayor aceptación en la empresa. Un modelo de caja negra puede arrojar una predicción más exacta, pero si no permite comprender qué variables impulsan el resultado, cómo varía la previsión con nuevas observaciones o qué margen de intervención conserva el responsable comercial, su utilidad queda limitada (Adadi & Berrada, 2018). En consecuencia, la explicabilidad no debe entenderse como un componente ornamental, sino como una condición de uso en entornos B2B, donde las decisiones deben poder justificarse ante dirección, finanzas, operaciones y, en ocasiones, ante el propio cliente. La literatura técnica sobre XAI ofrece un argumento claro: el valor de un modelo predictivo aumenta cuando la organización puede interpretar su salida, rastrear las variables influyentes y convertir esa información en decisiones auditables.

La **tercera dimensión conceptual** es la **adopción tecnológica**. Aquí conviene introducir, de manera breve y crítica, los marcos TAM y UTAUT (y sus extensiones o actualizaciones) no como teoría central, sino como apoyo para entender por qué una tecnología predictiva no se incorpora automáticamente a la práctica organizativa. La investigación sobre aceptación tecnológica ha mostrado que la intención de uso depende de la utilidad percibida, la facilidad de uso, la confianza, la influencia social y las condiciones facilitadoras, entre otros factores (Davis, 1989; Venkatesh et al., 2003). Aplicado al forecasting comercial, esto implica que la mejora del rendimiento predictivo es

necesaria, pero no suficiente: una solución de IA puede ser técnicamente sólida y, sin embargo, fracasar si no encaja en los flujos de trabajo, si no genera confianza o si exige capacidades que la organización no posee. Por eso, la adopción no debe leerse como una consecuencia natural de la superioridad algorítmica, sino como un proceso organizativo condicionado por percepciones, rutinas y recursos internos. Estos marcos no son objeto de contraste empírico directo en la revisión, sino que operan como lentes interpretativas en la discusión de barreras de implantación.

La **cuarta dimensión conceptual** es la gestión del **cambio organizativo**. Los marcos de aceptación tecnológica capturan la decisión individual de uso, pero no agotan la dimensión organizativa del problema. La incorporación de un modelo predictivo a la práctica comercial no es solo un acto de adopción, sino un proceso de transformación que afecta a rutinas establecidas, estructuras de decisión y reparto de responsabilidades entre funciones. La literatura sobre gestión del cambio organizativo ha mostrado que la introducción de una tecnología redefine flujos de trabajo, redistribuye el poder informativo y exige acompañamiento, comunicación interna y rediseño de procesos para consolidarse (Kotter, 1996; Armenakis, Harris & Mossholder, 1993). Aplicado al forecasting B2B con IA, esto implica que la viabilidad de una solución no depende únicamente de su precisión ni de su aceptación individual, sino de la capacidad de la organización para gestionar la transición que su implantación conlleva. Esta perspectiva amplía el foco desde la adopción puntual hacia la transformación organizativa sostenida, y será determinante en la identificación de los vacíos que la revisión documental detecte en el corpus analizado.

Esta perspectiva ayuda a interpretar la literatura reciente sobre IA en ventas: los estudios disponibles muestran que la inteligencia artificial no solo pronostica, sino que reordena la relación entre datos, juicio experto y decisión, y que su adopción depende de la calidad del dato, de la integración con los procesos internos y de la capacidad organizativa para traducir la salida algorítmica en acción comercial (Fischer et al., 2022; Jarotschkin et al., 2025). Desde esta óptica, la precisión del forecasting debe analizarse junto con las condiciones que la convierten en una herramienta utilizable.

1.3 Justificación académica del estudio

La justificación de este trabajo es **temática y metodológica**. Es temática porque el fenómeno estudiado ha crecido con rapidez, pero la literatura permanece fragmentada entre trabajos centrados en la mejora técnica del forecast, estudios aplicados a sectores concretos y revisiones que no siempre distinguen entre ventas, demanda, marketing o logística. La investigación sobre IA en ventas ha puesto el foco, en muchos casos, en resultados predictivos o en aplicaciones operativas, mientras que la dimensión organizativa del problema ha recibido una atención relativamente menor. Esa asimetría es particularmente visible cuando el contexto es B2B, donde la adopción depende de condiciones relacionales, estructurales y culturales que no pueden darse por supuestas (Fries & Ludwig, 2024; Jarotschkin et al., 2025; Manos et al., 2024).

La justificación es también metodológica porque el problema requiere una revisión sistemática cualitativa para ordenar un cuerpo de evidencia heterogéneo, evitar selecciones intuitivas y aislar con precisión qué se sabe, qué se repite y qué sigue abierto. El objetivo no es acumular referencias, **sino reconstruir un estado del arte en el que puedan distinguirse con claridad las aportaciones sobre metodología, datos, resultados y barreras de implementación**. La revisión sistemática es, en este caso, el instrumento adecuado para convertir una literatura dispersa en una síntesis argumentada y verificable (Sohrabpour et al., 2021).

La relevancia académica del estudio se incrementa por la ausencia relativa de trabajos que integren de forma explícita la dimensión técnica y la dimensión organizativa en el forecasting de ventas B2B. Existen estudios que comparan algoritmos y otros que analizan adopción tecnológica, pero son menos frecuentes los trabajos que articulan ambas líneas para explicar por qué un modelo más preciso no siempre se convierte en una herramienta mejor implantada. Esa falta de integración constituye precisamente el espacio de contribución del presente trabajo. La revisión permite, por tanto, avanzar en una comprensión más fina del fenómeno: no solo qué modelos funcionan mejor, sino qué condiciones permiten que un modelo funcione dentro de una organización comercial concreta.

La literatura de forecasting ha mostrado desde hace tiempo que la precisión no puede interpretarse de forma aislada de su contexto de aplicación, porque un modelo más exacto no siempre es el más útil si no se integra bien en la planificación y en la toma de decisiones. En ese sentido, **este estudio se sitúa en la intersección entre la evaluación técnica del pronóstico y la explicación de sus condiciones de uso**, una combinación que resulta especialmente pertinente para B2B por la complejidad de las cuentas, la variabilidad de los ciclos de venta y la necesidad de coordinar áreas distintas sobre una base de información común (Hyndman & Koehler, 2006; Tashman, 2000).

El presente trabajo contribuye a ese espacio mediante una revisión sistemática cualitativa de 20 artículos indexados en Scopus y Web of Science, **cuyo resultado no es un inventario de hallazgos sino un mapa de resolución diferencial**: qué preguntas sobre IA y forecasting B2B han encontrado respuesta sólida en la literatura, cuáles permanecen parcialmente abiertas y cuáles no han sido siquiera formuladas. Esa diferenciación constituye la base documental sobre la que se articula la agenda de investigación propuesta.

1.4 Preguntas de investigación

- **PI1 (principal):** ¿En qué medida y bajo qué condiciones la inteligencia artificial mejora la precisión del forecasting de ventas B2B de forma trasladable a la práctica comercial?
- **PI2 (secundaria):** ¿Qué arquitecturas y metodologías de inteligencia artificial predominan en la literatura sobre forecasting de ventas B2B, y cómo se comporta su rendimiento predictivo frente a enfoques estadísticos convencionales y al juicio experto?
- **PI3 (secundaria):** ¿Qué variables, fuentes de datos y estructuras de información exhiben mayor capacidad para mejorar la calidad predictiva en contextos de venta interorganizacional?
- **PI4 (secundaria):** ¿A través de qué mecanismos se manifiestan en la literatura las barreras de implementación de modelos de IA en el forecasting B2B (con especial atención a la calidad del dato, la opacidad algorítmica, la confianza y la adopción organizativa) y con qué consistencia aparecen documentadas?
- **PI5 (secundaria):** ¿Qué vacíos teóricos, metodológicos y contextuales permanecen insuficientemente atendidos en la literatura sobre inteligencia artificial aplicada al forecasting de ventas B2B y sobre cuáles de ellos podría fundamentarse una agenda doctoral?

1.5 Objetivos del estudio

- **OE1: Identificar** las principales metodologías de inteligencia artificial utilizadas en forecasting de ventas B2B.
- **OE2: Sintetizar** los hallazgos empíricos de la literatura en relación con las metodologías de inteligencia artificial empleadas, las variables y fuentes de datos incorporadas, y las limitaciones técnicas y organizativas observadas en el forecasting de ventas B2B.
- **OE3: Analizar** las barreras de implementación que aparecen con mayor consistencia en la literatura, especialmente en relación con la calidad del dato, la opacidad algorítmica, la confianza y la adopción organizativa.
- **OE4: Detectar** los vacíos teóricos, metodológicos y contextuales que permanecen abiertos en la literatura sobre inteligencia artificial aplicada al forecasting de ventas B2B y que pueden sostener una futura agenda doctoral.

1.6 Planteamiento y desarrollo del estudio

El estudio se articula en cuatro fases. La primera delimita el corpus mediante un protocolo de selección explícito y replicable (Sección 2). No se trata de un requisito formal: en un campo donde la producción científica sobre IA y forecasting ha crecido de forma exponencial en los últimos cinco años, la calidad de la síntesis depende directamente de la calidad del procedimiento de recuperación. La segunda fase consiste en la lectura analítica del corpus. El objetivo no es resumir estudios individualmente, sino identificar patrones transversales: qué familias metodológicas predominan, qué variables exhiben mayor capacidad predictiva, qué métricas de error se emplean y qué contextos

B2B están representados o ausentes. La tercera fase produce la síntesis crítica, que no pregunta qué modelos funcionan mejor en abstracto, sino bajo qué condiciones técnicas y organizativas esa superioridad se sostiene y resulta transferible a la práctica comercial. La cuarta localiza los vacíos que permanecen abiertos y fundamenta la agenda doctoral de la Sección 4. La Sección 3, organizada en ocho bloques temáticos, aborda directamente las preguntas PI2, PI3, PI4 y PI5; la PI1 recibe respuesta integradora en el subapartado 3.8.

Una precisión de diseño requiere exposición antes de continuar. Los artículos del corpus formulan hipótesis pero son **estrictamente técnico-experimentales**: proposiciones del tipo "la sustitución del componente X por el componente Y reduce la métrica de error en un porcentaje Z bajo las condiciones del conjunto de datos empleado". **Ninguna de estas hipótesis es comparable con las del artículo siguiente**, porque el conjunto de datos, el horizonte temporal y el sector son distintos por definición. Sintetizarlas individualmente sobre veinte estudios heterogéneos no produciría conocimiento acumulable. Produciría una colección de constataciones locales. Por esa razón, las relaciones estudiadas por la literatura se organizan en torno a las cuatro dimensiones del marco conceptual (D1-D4), que operan como el nivel de abstracción adecuado para extraer patrones comparables de un corpus metodológicamente dispar. Esta decisión es coherente con la modalidad de revisión sistemática cualitativa adoptada.




Figura 2 - Diagrama del resumen de diseño del estudio (elaboración propia)

2. FUENTES DE INFORMACIÓN, PROTOCOLO DE SELECCIÓN Y MUESTRA

La adopción de una revisión sistemática cualitativa no es una elección procedimental neutra. El campo de la IA aplicada al forecasting de ventas presenta **dispersión estructural**: coexisten estudios empíricos de alta densidad técnica, trabajos aplicados en sectores muy específicos, revisiones narrativas sin criterios explícitos y propuestas conceptuales sin evidencia empírica. Esa heterogeneidad hace inviable una síntesis fiable sin imponer un protocolo de recuperación y cribado replicable y trazable. La calificación de cualitativa se refiere a la modalidad de síntesis, no a la naturaleza de los artículos: el corpus es predominantemente cuantitativo, y precisamente por ello requiere un procedimiento interpretativo que extraiga su contenido técnico disperso y lo organice en categorías conceptuales comparables.




Figura 3 - Diagrama del proceso PRISMA2020 realizado para la selección y cribado del corpus (elaboración propia)

Tranfield et al. (2003) formalizaron los fundamentos de la revisión sistemática en ciencias de la gestión para superar las limitaciones del método narrativo, cuya dependencia del criterio individual del investigador la hace vulnerable a sesgos de selección y a la infrarrepresentación de estudios que contradicen la hipótesis implícita del revisor. La revisión sistemática reduce ese riesgo de manera estructural al imponer criterios de inclusión y exclusión aplicados

de forma uniforme sobre el corpus. No lo elimina. El sesgo de publicación, las restricciones propias de las bases de datos consultadas y la ausencia de un criterio de desempate formal dejan márgenes de incertidumbre que el protocolo puede acotar pero no suprimir. Ese reconocimiento no debilita el rigor del procedimiento: es constitutivo de él.

Snyder (2019) distingue tres modalidades según el objetivo de la revisión: síntesis cuantitativa, análisis bibliométrico y síntesis interpretativa cualitativa. El presente trabajo se inscribe en la tercera porque su objetivo **no es comparar estadísticamente el rendimiento de algoritmos ni cartografiar redes de citación, sino identificar qué se sabe, bajo qué condiciones y qué permanece abierto**. El bibliométrico produciría una cartografía formal del campo; no respondería ninguna de las cinco preguntas de investigación formuladas. La distinción no es terminológica: determina qué tipo de conocimiento se genera.

Las cuatro dimensiones analíticas del marco conceptual (D1-D4) operan simultáneamente como criterio de pertinencia temática en la Fase 4 del protocolo y como parámetro para establecer el umbral de corte de la muestra final. La coherencia entre la pregunta de investigación y el diseño del protocolo responde al principio de Tranfield et al. (2003): el diseño de la búsqueda debe deducirse de la pregunta, no imponerse sobre ella. El marco PRISMA 2020 (Page et al., 2021) actúa como referencia de verificación formal de esa coherencia, no como sustituto del juicio sobre pertinencia temática. El proceso completo de recuperación, deduplicación y cribado, **condujo desde 3.121 registros brutos hasta los 20 artículos de la muestra final**. Los subapartados siguientes detallan los criterios y decisiones de cada fase.

2.1 Selección de las bases de datos

La búsqueda documental se realizó sobre dos bases de datos de referencia en ciencias de la gestión, ingeniería y ciencias de la computación: **Scopus (Elsevier)** y **Web of Science Core Collection (Clarivate Analytics)**. La elección no es arbitraria. Ambas ofrecen cobertura internacional de publicaciones arbitradas, permiten la combinación de descriptores booleanos en título, resumen y palabras clave, y admiten filtros por tipo de documento y año de publicación. El acceso se realizó a través de los recursos institucionales de la Universidad Complutense de Madrid.

La restricción a estas dos bases de datos implica la exclusión potencial de artículos indexados únicamente en repositorios especializados o en plataformas regionales como SciELO, REDALYC o DOAJ. Esta limitación se asume de forma explícita y se discute a continuación como parte de la declaración de limitaciones del protocolo. La decisión de no ampliar la búsqueda a más plataformas responde a un criterio de coherencia: la masa documental recuperada en Scopus y WoS es suficientemente amplia para cumplir con el objetivo de la revisión, y su ampliación a otras fuentes sin criterios adicionales de control de calidad editorial introduciría heterogeneidad sin beneficio proporcional para el problema de investigación.

2.2 Estrategia de búsqueda y ecuación descriptora

La ecuación de búsqueda adoptada fue:

```
(TITLE-ABS-KEY("sales forecast" OR "sales forecasting") AND TITLE-ABS-KEY("artificial intelligence" OR "machine learning"))
```

La estructura de la ecuación combina dos ejes descriptores. El primero agrupa los términos referidos al fenómeno de predicción comercial. El segundo agrupa las denominaciones más frecuentes de los enfoques algorítmicos de interés. La elección de estos descriptores responde a un objetivo de maximización de la sensibilidad de recuperación, no de la especificidad.

La terminología del campo no es uniforme. Un mismo fenómeno (la predicción de ventas futuras en un contexto organizacional mediante modelos algorítmicos de aprendizaje) se denomina en la literatura con al menos seis expresiones distintas: sales forecasting, demand forecasting, commercial revenue prediction, sales prediction, enterprise sales modeling e incluso order volume forecasting. Añadir todos esos términos a la ecuación habría

incrementado la recuperación, pero al coste de incorporar una masa de resultados que incluirían predicción de demanda de consumo masivo, modelos de pricing o predicción de series macroeconómicas, todos ellos alejados del objeto de estudio. La restricción a "*sales forecast*" y "*sales forecasting*" produce un balance aceptable entre cobertura y manejabilidad del corpus recuperado.

Consta de manera explícita que el descriptor B2B no fue incluido en la ecuación de búsqueda inicial. La razón metodológica es directa: el objetivo de la primera fase del trabajo era construir un mapa del estado del arte de la IA en forecasting de ventas en sentido amplio, antes de aplicar el filtro contextual B2B. El estrechamiento al contexto empresarial interorganizacional se introduce en la Fase 3 del protocolo, no en la ecuación de búsqueda. Esta decisión se fundamenta en la heterogeneidad terminológica del campo: un número significativo de estudios empíricos sobre forecasting B2B no emplean ese acrónimo en ningún punto del documento, lo que habría producido una exclusión sistemática de trabajos altamente pertinentes si el filtro B2B se hubiera operacionalizado mediante descriptores de búsqueda en lugar de mediante una evaluación contextual explícita.

Tabla 1 - Ficha técnica de metodología de búsqueda

Parámetro	Detalle
Bases de datos	Scopus; Web of Science
Ecuación de búsqueda	(sales forecast OR sales forecasting) AND (artificial intelligence OR machine learning)
Campo de búsqueda	Título, resumen y palabras clave (TITLE-ABS-KEY)
Tipo de documento	Artículo de investigación (Article)
Idioma	Inglés
Período de cobertura	2000 en adelante
Fecha de ejecución	enero 2026 (re-ejecución en mayo 2026)
Resultados iniciales	Scopus: 1.991 registros; Web of Science: 1.130 registros
Total bruto consolidado	3.121 registros

La búsqueda fue ejecutada en enero de 2026 y **re-ejecutada en mayo de 2026 para detectar artículos nuevos**, sin que fuera necesario incorporar registros adicionales al no haberse detectado cambios en el número de resultados. Los filtros de año (desde 2000) y tipo de documento (artículos únicamente) se aplicaron en la propia interfaz de las bases de datos, antes de exportar los resultados. No se aplicaron restricciones por área temática, país o institución, con el fin de preservar la cobertura disciplinar del campo.

2.3 Fase 1: limpieza técnica del corpus inicial

La exportación combinada de Scopus y Web of Science produjo un corpus bruto de 3.121 registros. La primera operación sobre ese corpus fue de naturaleza técnica: la eliminación de **duplicados y registros ilegibles por defectos formales**.

La deduplicación se realizó mediante la comparación de DOI y de título normalizado con las herramientas del gestor documental Zotero para Mac. Cuando el DOI era idéntico en dos registros procedentes de distintas bases de datos, el artículo se consolidó en un único registro. En ausencia de DOI, se aplicó la comparación de título completo y año de publicación como criterio secundario. Esta operación eliminó 484 registros duplicados. Se eliminaron además cinco registros correspondientes a **retractaciones formalizadas** en la base de datos o notificaciones de erratum no asociadas a un artículo original recuperable. Tras la limpieza técnica, el corpus disponible para el cribado temático quedó fijado en **2.637 artículos**. Esta cifra representa el punto de partida efectivo del proceso de selección.

2.4 Fase 2: cribado por título y resumen

Sobre los 2.637 artículos resultantes de la Fase 1 se aplicó un cribado de pertinencia temática por lectura de título y resumen. El procedimiento opera mediante **aplicación secuencial de criterios de exclusión>inclusión**: si cualquier criterio de exclusión se activa de forma inequívoca, el artículo se descarta sin verificar los criterios de inclusión. Solo cuando ningún criterio de exclusión se activa claramente se procede a confirmar que los cuatro criterios de inclusión se satisfacen simultáneamente. La lógica de priorizar la exclusión responde a una consideración de precisión operativa: en un corpus de esta amplitud, los criterios negativos operan sobre señales concretas (dominio incorrecto, técnica tangencial, tipo de documento inadecuado), mientras que los positivos exigirán valoraciones globales de adecuación con mayor margen de incertidumbre.

En el cribado surgieron tres categorías de casos fronterizos que requirieron decisión explícita. Los artículos sobre **predicción de demanda** en cadenas de suministro con componente B2B plausible pero no explícito se conservaron en el corpus para evaluación en la Fase 3, no se descartaron en esta. Los artículos de **plataformas mixtas (B2B y B2C simultáneos)** se mantuvieron si el objeto principal era el forecasting de ventas con IA, difiriendo la decisión sobre el componente B2B. Los artículos con **títulos que sugieren forecasting de ventas pero cuyos resúmenes revelan predicción financiera** (precio de acción, rentabilidad contable) **o logística** (nivel de inventario, stock-out) se descartaron por CE14 y CE11 respectivamente, por referirse a fenómenos estructuralmente distintos del objeto de investigación

Tabla 2 - Criterios de Inclusión y su definición

Código	Criterio
CI1	El estudio aborda explícitamente la predicción de ventas, la previsión de demanda o la predicción de ingresos comerciales en un contexto empresarial, minorista, B2B o de mercado
CI2	La IA, el ML, el DL o las redes neuronales constituyen el modelo predictivo principal del estudio
CI3	El estudio presenta un objetivo de predicción aplicado, un modelo predictivo o una tarea de evaluación de pronósticos
CI4	El resumen aporta información sustantiva suficiente para evaluar la pertinencia respecto al objetivo de la revisión

Tabla 3 - Criterios de Exclusión y su definición

Código	Criterio
CE1	El estudio no aborda la predicción de ventas, demanda ni ingresos comerciales
CE2	La IA tiene un carácter tangencial, secundario o se emplea como herramienta genérica sin centralidad metodológica
CE3	Dominio de predicción no comercial sin vínculo directo con ventas, demanda, ingresos, clientes o decisión empresarial
CE4	Tipo de documento no elegible (review, conference paper, book chapter, editorial, corrigendum, erratum)
CE5	El resumen no ofrece información sustantiva suficiente para valorar la pertinencia
CE6	El estudio no reporta un modelo predictivo, tarea de forecasting ni evaluación del pronóstico
CE7	Predicción genérica, clasificación, clustering, detección de anomalías, optimización, recomendación o segmentación sin forecasting de ventas o demanda
CE8	La IA se usa únicamente para preprocesamiento, selección de variables, apoyo o analítica descriptiva
CE9	Artículo retractado, notificación de retractación, corrección, errata o expresión de preocupación
CE10	Survey genérico, comentario, propuesta de marco o pieza conceptual sin forecasting aplicado
CE11	Cadena de suministro, inventario, logística, pricing, CRM o analítica de clientes sin forecasting explícito de volúmenes de ventas o demanda

CE12	Benchmark metodológico puro sin aplicación empresarial de ventas o demanda claramente identificada
CE13	Simulación, optimización o planificación únicamente
CE14	Predicción financiera, predicción bursátil, scoring de crédito, predicción macroeconómica, predicción energética u otros dominios no comerciales
CE15	Churn de clientes, retención, sistemas de recomendación, análisis de sentimiento, detección de fraude o segmentación sin forecasting explícito de ventas o demanda
CE16	Planificación directiva, presupuestación o soporte a la decisión sin modelo de forecasting de ventas o demanda basado en IA
CE17	Predicción de rendimiento agrícola, producción, carga o mantenimiento, salvo que esté vinculado explícitamente a ventas o demanda comercial
CE18	Revisión de literatura sin evidencia de forecasting aplicado directamente

La aplicación de los criterios produjo **962 artículos que superaron el cribado**. El descarte de 1.675 registros (63,5% del corpus post-deduplicación) no es un artefacto de una ecuación mal diseñada: refleja que la producción científica sobre IA en forecasting está dominada por aplicaciones ajenas a las ventas comerciales (predicción energética, series financieras, producción industrial sin componente comercial). Los **criterios más activos fueron CE14, CE7 y CE11**. Esa distribución confirma que la predicción de ventas B2B es un nicho especializado dentro de la macro-categoría "*IA + forecasting*", y que la magnitud de la búsqueda inicial era necesaria para capturarlo con suficiente cobertura.

2.5 Fase 3: cribado temático sobre B2B

El filtro B2B se incorporó en una fase posterior al cribado temático por una razón metodológica directa: el contexto interorganizacional carece de descriptores terminológicos estables en la literatura de forecasting. Un número significativo de estudios empíricos sobre predicción de ventas en manufactura, distribución mayorista o servicios industriales **no emplea el acrónimo "B2B" en título, resumen ni palabras clave**. Operacionalizar como descriptor en la ecuación de búsqueda habría producido la exclusión sistemática de artículos de alta pertinencia. La incorporación del filtro contextual como criterio de segunda lectura, una vez delimitado el corpus temático, es coherente con los principios de la revisión sistemática cuando la pregunta opera sobre un campo con terminología heterogénea (Snyder, 2019; Page et al., 2021).

Para hacer el filtro reproducible se diseñó una **escala de valoración contextual de seis niveles** que evalúa el grado en que el contexto empírico del estudio corresponde a una relación comercial interorganizacional, con independencia de si el artículo emplea o no el término B2B.

Tabla 4 - Puntuación del cribado de la fase 3 y su definición

Puntuación	Descripción operativa
5	Contexto B2B explícito e inequívoco: el artículo denomina su contexto como B2B o describe transacciones entre empresas de forma directa
4	Contexto industrial o empresarial claramente B2B: manufactura, distribución mayorista, servicios a empresas, exportaciones corporativas, sin denominación explícita B2B pero con inferencia unívoca
3	Contexto ambiguo, mixto o inferible pero no explícito: retail o distribución con componentes B2B y B2C simultáneos, o contexto empresarial no claramente delimitado
2	Relación débil con B2B: contexto predominantemente B2C con alguna vinculación organizacional
1	Relación muy débil o indirecta: B2C puro o contexto sectorial sin componente organizacional identificable
0	Sin adecuación B2B: contexto completamente ajeno a la relación comercial entre organizaciones

El umbral de corte se fijó en 4. Este nivel retiene los estudios cuyo contexto es claramente interorganizacional (B2B explícito o inequívocamente inferible) y descarta los contextos mixtos, ambiguos o predominantemente B2C. Es más exigente que la mera presencia de componente organizacional, pero menos restrictivo que exigir la denominación explícita del acrónimo, lo que permite recuperar la masa de estudios industriales pertinentes que operan en lógica B2B sin denominarse así. La valoración se realizó sobre el texto completo en los casos en que el resumen no aportaba información contextual suficiente; para puntuaciones inequívocas (5 o 0) no se requirió lectura extendida.

La aplicación de la escala de valoración contextual a los 962 artículos del corpus post-Fase 2 produjo un corpus B2B de **53 artículos** que alcanzaron una puntuación igual o superior a 4. Esta cifra representa el 2,0% del corpus post-deduplicación y el 5,5% del corpus post-cribado temático.

Sobre la distribución de sectores en B2B

El número de artículos que superaron el umbral B2B varía por sector y período. Los estudios en manufactura electrónica e industrial (fabricantes de circuitos impresos, productores de componentes, fabricantes de maquinaria pesada) representan el grupo más numeroso dentro de los 53, con al menos doce artículos identificados en ese grupo. La distribución mayorista de tecnología y componentes IT constituye el segundo grupo, con aproximadamente ocho artículos. Los trabajos sobre exportaciones B2B, servicios industriales y distribución farmacéutica suman en conjunto el tercio restante, con presencia de artículos sobre comercio electrónico B2B, transporte de carga y servicios de telecomunicaciones a empresas.

Esta distribución sectorial refleja la estructura del campo: los sectores con mayor tradición de gestión de datos transaccionales (manufactura electrónica, distribución IT) son los que antes y con mayor frecuencia han adoptado modelos de IA para el forecasting de sus ventas. Los sectores de servicios B2B o de mayor complejidad transaccional (consultoría, software empresarial, servicios financieros a empresas) están significativamente subrepresentados en el corpus de 53 artículos, lo que constituye en sí mismo un hallazgo diagnóstico sobre el estado del arte del campo. La magnitud de la reducción (de 962 a 53) confirma dos aspectos ya anticipados en el planteamiento metodológico. El primero es que el campo de IA en forecasting de ventas está dominado por estudios en contextos B2C, retail de consumo masivo o plataformas de comercio electrónico orientadas al consumidor final. El segundo es que la ausencia del descriptor B2B en la ecuación de búsqueda no produjo una recuperación excesiva de ruido: los 53 artículos con adecuación contextual B2B son los que el protocolo de cribado habría seleccionado con independencia del punto de partida terminológico.

Esta segunda observación es importante para la defensa metodológica del protocolo. Si la búsqueda hubiera incorporado B2B como descriptor desde el inicio, el número de artículos recuperados habría sido considerablemente inferior a 53, porque habría excluido todos los estudios con contexto B2B real pero sin denominación explícita. La búsqueda amplia seguida de filtro contextual recupera más artículos pertinentes que la búsqueda restringida desde el inicio, al coste de una carga de cribado mayor en las fases intermedias. Ese coste está justificado por el beneficio de cobertura.

2.6 Fase 4: priorización y selección final por sistema de puntuación

Los 53 artículos superaron los criterios de pertinencia temática y contextual. La necesidad de una fase adicional de priorización responde a dos razones. La primera es de **manejabilidad analítica**: la saturación teórica en una revisión sistemática cualitativa con pregunta acotada en cuatro dimensiones se produce a un tamaño de muestra muy inferior al corpus completo (Snyder, 2019). La práctica consolidada en ciencias de la gestión apunta a muestras de entre 15 y 25 artículos para preguntas de alcance equivalente; los 20 artículos de la muestra final se sitúan en el rango central de esa horquilla. La segunda razón es la **calidad diferencial**: la distribución de calidad editorial, influencia académica y adecuación temática dentro del corpus de 53 artículos es heterogénea, y equipararse en peso analítico sin distinción habría comprometido la solidez de la síntesis.

Tabla 5 - Dimensiones utilizadas para la priorización final con pesos, escalas y criterios

Dimensión	Peso	Escala	Criterio operativo
<i>Calidad editorial</i>	20%	Q1 = 5, Q2 = 4, Q3 = 3, Q4 = 2 sin cuartil = 1	Cuartil SJR o JCR de la revista en el momento de la consulta
<i>Influencia académica</i>	30%	> 150 citas = 5 101-150 = 4 51-100 = 3 26-50 = 2 0-25 = 1	Número de citas recibidas según Scopus o WoS en el momento de la consulta
<i>Adecuación a la pregunta de investigación</i>	50%	5 = IA aplicada directamente al forecasting de ventas B2B 4 = forecasting de ventas con IA en contexto muy próximo 3 = forecasting con IA en otro sector 2 = IA en ventas o marketing sin forecasting claro 1 = tangencial	Evaluación de la pertinencia respecto a las cuatro dimensiones de la pregunta de investigación

La ponderación del 50% a la adecuación temática refleja la prioridad de la revisión: se trata de seleccionar los artículos que mejor respondan a la pregunta de investigación, no los más citados ni los publicados en revistas de mayor prestigio editorial genérico. Un artículo metodológicamente sólido publicado en Q1 con 300 citas pero con una adecuación temática de 2 (IA en ventas sin forecasting claro) obtendrá una puntuación compuesta inferior a un artículo de reciente publicación, menor influencia acumulada pero adecuación temática de 5.

La ponderación del 30% a la influencia académica introduce un criterio de validación colectiva del campo: los artículos con mayor número de citas han sido reconocidos y utilizados por la comunidad investigadora, lo que proporciona una garantía adicional sobre su relevancia. El 20% restante captura la calidad del proceso de revisión por pares, que constituye el filtro de calidad institucional de la producción científica.

Vale la pena explicitar la asimetría entre los tres pesos. Un sistema de ponderación equitativa (33,3% / 33,3% / 33,3%) habría producido una muestra final con mayor proporción de artículos en revistas Q1 de alta citación pero con adecuación temática moderada, en detrimento de los artículos recientes (2023-2025) que responden directamente a la pregunta de investigación pero que aún no han acumulado citas suficientes para obtener puntuaciones altas en la dimensión de influencia académica. La ponderación asimétrica adoptada (20% / 30% / 50%) convierte la adecuación temática en el criterio dominante, lo que es coherente con el objetivo de la revisión: producir una síntesis del estado del arte que responda a preguntas de investigación específicas, no un ranking de los artículos más citados del campo.

La puntuación compuesta se calcula como:

$$\text{Puntuación total} = (0,20 \times \text{Calidad editorial}) + (0,30 \times \text{Influencia académica}) + (0,50 \times \text{Adecuación temática})$$

El umbral de corte de la muestra final se estableció en una puntuación compuesta de 3,5 sobre 5. Los artículos que alcanzan o superan ese umbral se incorporan a la muestra final de análisis; los que quedan por debajo son descartados de la muestra de síntesis, aunque permanecen documentados en el corpus de 53 para eventuales referencias complementarias. El umbral de 3,5 no fue establecido previamente como un objetivo numérico fijo, sino que emergió del propio análisis de la distribución de puntuaciones del corpus B2B: representa el punto en que la puntuación compuesta empieza a reflejar una combinación de adecuación temática media, influencia académica baja y calidad editorial variable que no garantiza una contribución suficiente a la síntesis del estado del arte. No se aplicó ningún criterio de desempate formal entre artículos con puntuación idéntica, dado que la distribución de puntuaciones no produjo ambigüedades en el límite del umbral: el artículo situado en la posición 20 del ranking

obtiene exactamente 3,5 y el situado en la posición 21 obtiene una puntuación inferior. La selección se detuvo de forma natural en los 20 artículos que alcanzan o superan el umbral de 3,5.

La muestra queda fijada por tanto en **20 artículos** que a partir de ahora se tratarán del corpus final con el que se realizará el resto del presente trabajo.

2.7 Muestra final (corpus): características, distribución y cobertura

A continuación la muestra final o corpus seleccionado de 20 artículos con sus puntuaciones en base al criterio anteriormente descrito:

Tabla 6 - Selección final del corpus de artículos con su puntuación de fase 4

Título & Autor & Año	Revista	Q	Citas	CE	IA	AP	#
<i>The development of a weighted evolving fuzzy neural network for PCB sales forecasting – Chang et al., 2007</i>	Expert Systems with Applications	Q1	427	5	5	4	4,5
<i>Export sales forecasting using artificial intelligence – Sohrabpour et al., 2021</i>	Technological Forecasting and Social Change	Q1	234	5	5	4	4,5
<i>An improved sales forecasting approach by the integration of genetic fuzzy systems and data clustering: Case study of printed circuit board – Hadavandi et al., 2011</i>	Expert Systems with Applications	Q1	67	5	3	5	4,4
<i>A Generalized Flow for B2B Sales Predictive Modeling: An Azure Machine-Learning Approach – Rezazadeh, 2020</i>	Forecasting	Q1	51	5	3	5	4,4
<i>Using supervised machine learning for B2B sales forecasting: A case study of spare parts sales forecasting at an after-sales service provider – Rohaan et al., 2022</i>	Expert Systems with Applications	Q1	80	5	3	5	4,4
<i>A fuzzy case-based reasoning model for sales forecasting in print circuit board industries – Chang et al., 2008</i>	Expert Systems with Applications	Q1	128	5	4	4	4,2
<i>Sales forecasting for computer wholesalers: A comparison of multivariate adaptive regression splines and artificial neural networks – Lu & Wang, 2012</i>	Decision Support Systems	Q1	121	5	4	4	4,2
<i>A clustering-based sales forecasting scheme by using extreme learning machine and ensembling linkage methods with applications to computer server – Lu & Kao, 2016</i>	Engineering Applications of Artificial Intelligence	Q1	74	5	3	4	3,9
<i>Industrial sales lead conversion modeling – Monat, 2011</i>	Marketing Intelligence & Planning	Q1	70	5	3	4	3,9
<i>Artificial intelligence-based evaluation of the factors affecting the sales of an iron and steel company – Pekkaya & Uysal, 2024</i>	Turkish Journal of Electrical Engineering and Computer Sciences	Q2	41	4	2	5	3,9
<i>Application of Immunological and Swarm Intelligence Learning-Based Algorithm for Industrial Grade Computer Sales Prediction – Chen, 2025</i>	Applied Artificial Intelligence	Q1	2	5	1	5	3,8
<i>Forecasting automobile sales with social media information under pandemic emergencies: evidence from Chinese automobile industry – Huang et al., 2025</i>	Annals of Operations Research	Q1	1	5	1	5	3,8
<i>Performance evaluation of metaheuristics-tuned recurrent networks with VMD decomposition for Amazon sales prediction – Jovanovic et al., 2025</i>	International Journal of Data Science and Analytics	Q1	9	5	1	5	3,8

<i>Identify key performance indicators to conduct demand and sales forecasting for container ships and capesize bulk carriers – Wang et al., 2025</i>	Computers & Industrial Engineering	Q1	0	5	1	5	3,8
<i>Prediction Analysis for Business To Business (B2B) Sales of Telecommunication Services using Machine Learning Techniques – Wisesa et al., 2020</i>	Majlesi Journal of Electrical Engineering	Q4	73	2	3	5	3,8
<i>A hybrid attention and time series network for enterprise sales forecasting under digital management and edge computing – Zhang et al., 2023</i>	Journal of Cloud Computing-Advances Systems and Applications	Q1	15	5	1	5	3,8
<i>Explaining machine learning models in sales predictions – Bohanec et al., 2017</i>	Expert Systems with Applications	Q3	43	3	2	5	3,7
<i>Optimizing B2B customer relationship management and sales forecasting with spectral graph convolutional networks: A quantitative approach – Henna et al., 2025</i>	Quantitative Finance and Economics	Q2	2	4	1	5	3,6
<i>Forecasting sales for a B2B product category: case of auto component product – Lackman, 2007</i>	Journal of Business & Industrial Marketing	Q1	32	5	2	4	3,6
<i>Intelligent Sales Prediction for Pharmaceutical Distribution Companies: A Data Mining Based Approach – Zadeh et al., 2014</i>	Mathematical Problems in Engineering	Q3	76	3	3	4	3,5

CE = Calidad editorial (0,20); IA = Influencia académica (0,30); AP = Adecuación pregunta (0,50). Total = puntuación compuesta ponderada sobre 5

Sobre la distribución temporal de la muestra

Los 20 artículos cubren el **período 2007-2025**. Tres corresponden al período 2007-2008, cuatro al período 2011-2014, dos al período 2016-2017, cinco al período 2020-2023 y seis al período 2024-2025. La distribución refleja la evolución del campo: los primeros trabajos sobre redes neuronales y sistemas fuzzy aplicados al forecasting industrial aparecen a mediados de la primera década del siglo, mientras que la aceleración en los últimos cinco años coincide con la maduración de las arquitecturas de aprendizaje profundo y la generalización del acceso a plataformas de ML en la nube. La ausencia de artículos anteriores a 2007 no indica que el campo no existiera: los trabajos previos no alcanzaron el umbral combinado de los tres criterios de puntuación.

Los seis artículos de 2024-2025 merecen atención metodológica. Presentan **influencia académica baja por razones cronológicas, pero adecuación temática de 5 y calidad editorial predominantemente Q1**. La ponderación del 50% a la adecuación temática permite su incorporación a pesar de la escasa acumulación de citas, decisión coherente con el objetivo de capturar el estado del arte en sus desarrollos más actuales. Estos artículos documentan el frente tecnológico del campo: redes de convolución espectral en grafos para CRM y forecasting B2B (Henna et al., 2025), redes recurrentes optimizadas mediante metaheurísticas (Jovanovic et al., 2025), algoritmos de inteligencia de enjambre para predicción de ventas industriales (Chen, 2025) e integración de KPIs operativos con modelos de demanda en logística de transporte B2B (Wang et al., 2025). Esos enfoques no están presentes en los artículos de mayor influencia acumulada, que por razones cronológicas operan con arquitecturas de una generación anterior.

Sobre la distribución por revistas

Los 20 artículos se distribuyen en 15 revistas distintas, **con dispersión editorial elevada**. Expert Systems with Applications concentra cinco artículos (Chang et al., 2007; Chang et al., 2008; Hadavandi et al., 2011; Rohaan et al., 2022; Bohanec et al., 2017), distribución estructuralmente predecible: es la plataforma que combina en mayor medida el rigor técnico de la computación con la orientación aplicada al negocio. La concentración no introduce sesgo de perspectiva porque los cinco trabajos representan cinco líneas metodológicas distintas: redes neuronales evolutivas fuzzy, integración de sistemas genético-fuzzy con clustering, razonamiento basado en casos, aprendizaje

extremo con clustering e interpretabilidad de modelos de ML. Diecisiete de los veinte artículos pertenecen a revistas Q1 o Q2. Los dos artículos en Q3 (Bohanec et al., 2017; Zadeh et al., 2014) alcanzaron el umbral de 3,5 por combinación de adecuación temática alta e influencia académica suficiente (76 citas acumuladas en el caso de Zadeh et al.).

Sobre la cobertura metodológica y temática

La muestra cubre los **cuatro paradigmas algorítmicos que la literatura ha consolidado**. El primero agrupa los modelos basados en lógica difusa y razonamiento basado en casos: Chang et al. (2007, 2008), Lackman (2007) y Hadavandi et al. (2011), con aplicaciones en fabricación de circuitos impresos y componentes electrónicos. El segundo comprende el aprendizaje supervisado clásico (regresión multivariante adaptativa, redes neuronales feedforward, SVM, extreme learning machines): Lu y Wang (2012), Lu y Kao (2016), Monat (2011) y Zadeh et al. (2014), en contextos de distribución mayorista, manufactura farmacéutica y generación de leads industriales. El tercero agrupa los modelos de ensamblaje y ML moderno (random forest, gradient boosting, XGBoost): Rezazadeh (2020), Rohaan et al. (2022), Sohrabpour et al. (2021), Wisesa et al. (2020) y Pekkaya et al. (2024). El cuarto abarca las arquitecturas de atención, transformers y enfoques híbridos de última generación: Chen (2025), Huang et al. (2025), Jovanovic et al. (2025), Wang et al. (2025), Zhang et al. (2023) y Henna et al. (2025), incluyendo el único artículo de la muestra orientado explícitamente a la interpretabilidad de modelos de ML en ventas (Bohanec et al., 2017).

La cobertura temática de las preguntas de investigación es asimétrica. La totalidad de los 20 artículos aporta evidencia sobre metodologías de IA y rendimiento comparativo (PI2). Doce de los veinte ofrecen información detallada sobre selección de variables y arquitectura de datos (PI3); los ocho restantes se concentran en la comparación algorítmica sin desarrollar esa dimensión. La cobertura de barreras de implantación (PI4) es más concentrada: Bohanec et al. (2017), Rohaan et al. (2022), Rezazadeh (2020) y Monat (2011) aportan la evidencia más directa; el resto aborda esta dimensión de forma tangencial en sus secciones de limitaciones. Los vacíos de investigación (PI5) aparecen transversalmente en todos los artículos, con mayor explicitación en los trabajos de 2022-2025, que identifican la escasez de datos etiquetados, la heterogeneidad de las series B2B y la interpretabilidad de los modelos de última generación como brechas prioritarias.




Figura 4 - Gráficos descriptivos del corpus final de artículos seleccionados (elaboración propia)

Esa asimetría no es un déficit de la muestra. Refleja la estructura real de la literatura: **la evaluación técnica de algoritmos ha dominado sobre el análisis organizativo de la implantación**. Esa desproporción es, en sí misma, uno de los hallazgos descriptivos más relevantes de la revisión.

2.8 Limitaciones metodológicas y decisiones asumidas

Toda revisión sistemática arrastra limitaciones inherentes a sus propias decisiones de diseño. Estas cinco limitaciones no invalidan el corpus seleccionado. Establecen, en cambio, los contornos dentro de los cuales deben interpretarse los hallazgos de la revisión:

- **Primera limitación: restricción a dos bases de datos.** La búsqueda se limitó a Scopus y Web of Science. Quedan potencialmente fuera del corpus artículos publicados en revistas indexadas únicamente en IEEE Xplore, ACM Digital Library, EBSCO o repositorios especializados en inteligencia artificial aplicada. Esta restricción reduce el riesgo de incorporar publicaciones sin revisión por pares rigurosa, pero introduce un sesgo de cobertura que no puede cuantificarse sin ejecutar la búsqueda completa en esas plataformas. Una búsqueda complementaria en IEEE Xplore, por ejemplo, habría recuperado potencialmente trabajos de conferencias sobre IA aplicada a ventas B2B publicados en colecciones del IEEE que no están indexadas en Scopus ni en WoS, aunque no es posible estimar su magnitud sin ejecutar un protocolo paralelo. La decisión se asume como un equilibrio entre cobertura, calidad editorial y manejabilidad del corpus.
- **Segunda limitación: incorporación tardía del filtro B2B.** El descriptor B2B no forma parte de la ecuación de búsqueda inicial. Su aplicación como filtro contextual en la Fase 3 es metodológicamente sólida por las razones expuestas con anterioridad, pero implica que la identificación de los artículos con contexto B2B depende del juicio del revisor sobre la naturaleza del contexto empírico del estudio, no de un criterio mecánicamente aplicable. Esta subjetividad residual se mitiga mediante la escala operativa de seis niveles, pero no puede ser completamente eliminada. La regla de corte en 4 es convencionalmente establecida: un umbral diferente (3 o 5) habría producido corpus distintos.
- **Tercera limitación: ausencia de criterio de desempate formal.** El protocolo de la Fase 4 no incorporó un mecanismo formal para resolver empates en la puntuación compuesta. En la práctica, la distribución de puntuaciones no generó casos de empate en el umbral de corte (el artículo en posición 20 obtiene exactamente 3,5 y el artículo en posición 21 obtiene una puntuación inferior), lo que hace que esta limitación no haya afectado al resultado final. Sin embargo, su ausencia formal es un aspecto mejorable del diseño del protocolo para futuras replicaciones.
- **Cuarta limitación: evaluación subjetiva de la adecuación temática.** La dimensión AP del sistema de puntuación ponderada (50% del peso) es evaluada por el revisor mediante una escala de cinco niveles basada en la lectura del artículo. Esta evaluación no puede ser completamente objetivada: dos revisores independientes podrían asignar puntuaciones distintas a un mismo artículo en casos fronterizos (AP = 4 vs. AP = 3, por ejemplo). La escala operativa descrita anteriormente reduce esta subjetividad al establecer criterios explícitos para cada nivel, pero no la elimina. Esta limitación es inherente a todos los sistemas de puntuación basados en juicio experto y no invalida el procedimiento, pero sí impone precaución a la hora de interpretar las diferencias de puntuación entre artículos separados por pocos decimales.
- **Quinta limitación: sesgo de publicación.** El corpus recuperado por las bases de datos indexa preferentemente publicaciones en inglés de revistas con acceso a través de plataformas editoriales con presencia en Scopus y WoS. Estudios publicados en otras lenguas, trabajos en acceso abierto sin indexación en esas plataformas o investigaciones en informes técnicos y literatura gris quedan sistemáticamente excluidos. Este sesgo de publicación es inherente a cualquier revisión sistemática basada en bases de datos de revistas arbitradas y no puede ser corregido dentro del diseño adoptado.

2.9 Resumen final del protocolo

El protocolo de selección construye el corpus sobre el que opera el análisis de las secciones siguientes. Sin un **procedimiento de recuperación y cribado transparente y replicable**, la síntesis analítica carecería de base verificable.

Tabla 7 - Resumen del protocolo PRISMA2020 utilizado con n° de artículos y descartes

Fase	Operación	Criterio	Artículos	Descartados
<i>Fase 0</i>	Búsqueda inicial en Scopus y WoS	Ecuación: sales forecast + AI/ML; filtro: artículos, inglés, desde 2000	3.121	-

Fase 1	Limpieza técnica	Eliminación de duplicados (484) y retractaciones (5)	2.637	489
Fase 2	Cribado por título y resumen	4 criterios de inclusión; 18 criterios de exclusión	962	1.675
Fase 3	Cribado contextual B2B	Escala 0-5; umbral ≥ 4	53	909
Fase 4	Priorización ponderada	Puntuación compuesta: CE (20%) + IA (30%) + AP (50%); umbral $\geq 3,5$	20	33

La tasa de retención acumulada desde el corpus bruto hasta la muestra final es del **0,64%**. La tasa de retención desde el corpus B2B (Fase 3) hasta la muestra final es del **37,7%**, lo que indica que el **umbral de 3,5 es moderadamente exigente pero no excesivamente restrictivo** dentro del espacio bibliográfico delimitado.

La muestra de 20 artículos cubre el período 2007-2025, se distribuye en **15 revistas distintas** y concentra diecisiete artículos en revistas Q1 o Q2. Representa los cuatro paradigmas algorítmicos dominantes del campo y abarca contextos empíricos en manufactura electrónica, distribución mayorista, maquinaria industrial, servicios corporativos, exportaciones B2B, distribución farmacéutica, logística de transporte y comercio digital interorganizacional, con estudios realizados en Estados Unidos, Taiwán, Países Bajos, Irán, Eslovenia, Turquía, China y otros entornos internacionales.

El **protocolo cumple los tres principios que Tranfield et al. (2003)** establecen para las revisiones sistemáticas en ciencias de la gestión: exhaustividad relativa, explicitación de criterios y transparencia sobre las limitaciones. La **adherencia al estándar PRISMA 2020 (Page et al., 2021)** garantiza que el flujo documental es trazable y replicable. La muestra no pretende ser exhaustiva; pretende ser representativa: capturar los trabajos de mayor calidad, influencia y adecuación al problema de investigación dentro del espacio bibliográfico delimitado. Esa distinción no es retórica. La exhaustividad es un objetivo inalcanzable en cualquier campo activo; la representatividad es un objetivo metodológicamente defendible y verificable mediante los instrumentos documentados en este capítulo.

3. REVISIÓN DE LA LITERATURA

Los veinte artículos que conforman el corpus no constituyen una colección homogénea de resultados técnicos. Constituyen, con mayor precisión, un **registro fragmentado pero internamente coherente de cómo distintas comunidades científicas** (en Taiwán, Irán, los Países Bajos, China, Eslovenia, Serbia, Irlanda, Turquía, Indonesia, Canadá y Estados Unidos) han intentado resolver, desde ángulos metodológicos muy distintos y con acceso a datos de naturaleza heterogénea, el mismo problema estructural: predecir el volumen de ventas en entornos donde el comprador es una organización, los ciclos de conversión son largos, las series históricas son cortas o irregulares, y el coste de un error de predicción se propaga a múltiples funciones internas.

La revisión que sigue no cataloga esas soluciones. Las examina conjuntamente, las somete a comparación transversal y extrae de esa comparación los patrones de convergencia y los vacíos que permanecen abiertos. El orden de exposición avanza desde la delimitación del fenómeno y la clasificación taxonómica del corpus hasta la taxonomía metodológica, el diseño empírico, los resultados y las barreras organizativas, para culminar en la síntesis crítica de limitaciones y en las preguntas que orientan la agenda futura.

3.1 Delimitación teórica del fenómeno

La delimitación del fenómeno se articula en **tres movimientos analíticos complementarios**. El primero reconstruye qué se entiende por forecasting de ventas (qué se estima, con qué propósito y bajo qué condiciones), recuperando las tres formulaciones conceptuales que coexisten en el corpus sin consenso explícito y vinculándolas a su posición dentro de la disciplina del marketing. El segundo identifica las cinco propiedades estructurales que diferencian el problema de predicción en mercados interorganizacionales del problema equivalente en consumo masivo; propiedades que condicionan el diseño de los modelos y la interpretación de sus resultados. El tercero combina ambos planos para proponer tres ejes de clasificación que permiten ordenar comparativamente los estudios del corpus y que sirven de referencia para la taxonomía metodológica.



1	Concentración de la base de clientes	<i>Número reducido de compradores organizacionales. La ley de grandes números no estabiliza la demanda. Alta variabilidad residual</i>
2	Pipeline comercial como estructura observable	<i>Las etapas del proceso de venta en B2B (en el CRM) son variables predictoras clave. El forecasting B2B es un problema relacional, no solo temporal</i>
3	Asimetría del coste del error de la predicción	<i>Falso negativo > falso positivo en clasificación de las oportunidades. El umbral óptimo de clasificación es distinto de 0,5 (Rohaam, 2022)</i>
4	Dependencia de variables exógenas con alta volatilidad	<i>Tipo de cambio, múltiples indicadores macroeconómicos, KPIs sectoriales, series no estacionarias. Modelos univariados pierden validez en rupturas estructurales</i>
5	Escasez relativa de observaciones históricas de datos	<i>Series cortas en el nivel de granularidad relevante. Obliga a un clustering de series similares y transfer learning implícito (Zadeh, 2014)</i>

Figura 5 - Ejes de clasificación principales del corpus seleccionado (elaboración propia)

Sobre el forecasting de ventas como parte del marketing

La American Marketing Association define el marketing como la actividad y los procesos para crear, comunicar, entregar e intercambiar ofertas que tienen valor para clientes, consumidores, socios y la sociedad (AMA, 2017). El forecasting de ventas no es periférico a ese intercambio. Es el instrumento cuantitativo mediante el cual la organización estima la magnitud y la distribución temporal de los intercambios futuros que sus decisiones de marketing van a generar. Sin esa estimación, la asignación de recursos comerciales carece de base objetiva.

Kotler y Keller (2012) formulan la condicionalidad determinante: el *company sales forecast* es el nivel de ventas esperado sobre la base de un plan de marketing seleccionado y un entorno asumido. Cambiar la estrategia de precios, modificar el presupuesto de comunicación o redefinir los segmentos prioritarios altera el forecast. Esa dependencia estructural del pronóstico respecto al plan lo vincula al marketing, no al área técnica. La operacionalización empírica más directa de esta tesis dentro del corpus la ofrece Lackman (2007), cuyo modelo incorpora explícitamente variables de marketing mix (product ratings, presupuesto de comunicación, precio propio frente al precio del competidor) como entradas al modelo predictivo, no como contexto externo. Es el único trabajo de la muestra que convierte el plan de marketing en variable de input del forecast, lo que lo sitúa en una posición singular respecto al resto del corpus.

Mentzer y Moon (2005), a partir de datos de más de 400 empresas recogidos en 25 años, constatan que la función de forecasting es responsabilidad del departamento de marketing en la mayoría de las organizaciones analizadas y que su propósito primario es servir a la planificación de marketing. La integración entre forecasting y marketing es el factor organizativo con mayor incidencia sobre la precisión del pronóstico, con independencia de la sofisticación del método estadístico empleado. Los criterios de evaluación de la eficacia del pronóstico (precisión, ausencia de sesgo, oportunidad de entrega) son criterios de gestión de marketing (Winklhofer y Diamantopoulos, 2002). La aplicación de técnicas de inteligencia artificial a ese proceso no desplaza el forecasting fuera del marketing: lo sitúa en la intersección entre el marketing analytics y la gestión comercial B2B.

Sobre las definiciones del forecasting de ventas

El corpus no contiene una definición unificada del fenómeno. La lectura transversal de los objetivos, variables dependientes y contextos empíricos permite reconstruir tres formulaciones conceptuales diferenciadas que coexisten en la literatura sin ser equivalentes entre sí (Tashman, 2000; Hyndman y Koehler, 2006).

La primera formulación concibe el forecasting de ventas como predicción de series temporales de demanda agregada: el objeto de estimación es el volumen total de ventas de un producto o categoría en un horizonte temporal futuro, y la variable dependiente es una magnitud continua medida en intervalos regulares. Esta formulación es mayoritaria en el corpus. La adoptan Chang et al. (2007, 2008) en manufactura de circuitos impresos, Lu y Wang (2012) en distribución mayorista de tecnología, Lu y Kao (2016) en distribución de servidores, Zadeh et al. (2014) en distribución farmacéutica, Wisesa et al. (2020) en telecomunicaciones B2B, Pekkaya et al. (2024) en la industria siderúrgica y Wang et al. (2025) en logística marítima.

La segunda formulación concibe el forecasting de ventas como clasificación probabilística del resultado de oportunidades individuales en el pipeline comercial. La variable dependiente es binaria (Won/Lost, Sale/No Sale) y el horizonte temporal es el ciclo de venta individual. Esta formulación aparece en Monat (2011), donde el fenómeno se describe como la conversión del lead industrial en booking con una tasa base del 17,9%; en Bohanec et al. (2017), donde se operacionaliza como la predicción del resultado Won/Lost sobre 448 oportunidades de una empresa de software B2B; en Rohaan et al. (2022), donde la variable dependiente es la conversión de líneas de cotización con una tasa base del 19% sobre 180.000 registros ERP; y en Henna et al. (2025), donde el fenómeno se define a partir de la estructura relacional del CRM. Rezazadeh (2020) es el único artículo del corpus que tematiza explícitamente la distinción entre ambas formulaciones, al proponer un flujo que diferencia entre opportunity scoring y demand forecasting como subproblemas con datos, modelos y métricas distintos.

La tercera formulación concibe el forecasting de ventas como estimación causal de la función de respuesta a variables exógenas. El objeto de estimación es la relación funcional entre un conjunto de variables independientes y el volumen de ventas, de modo que el modelo no solo predice sino que permite cuantificar la sensibilidad de las ventas ante cambios en cada predictor. Esta formulación aparece en Sohrabpour et al. (2021), donde la Programación Genética genera una ecuación explícita que permite calcular esa sensibilidad con coeficiente numérico; en Pekkaya et al. (2024), donde el objetivo declarado incluye evaluar los factores que afectan a las ventas; y en Wang et al. (2025), donde la selección de KPIs es en sí misma un resultado con valor cognoscitivo independiente del rendimiento predictivo del modelo.

Sobre las características diferenciales de la previsión de ventas B2B

La distinción entre el forecasting de ventas en contextos B2B (empresa a empresa) y en contextos B2C (empresa a consumidor final) no es meramente sectorial. Es una distinción de estructura del problema que afecta directamente al diseño de los modelos de predicción y a la interpretación de sus resultados. El corpus permite identificar cinco características estructurales del forecasting B2B que lo diferencian del B2C y que aparecen, con distinto grado de explicitación, en los artículos analizados.

- La primera característica es la **reducida granularidad de la base de clientes y la concentración de la demanda**. En los mercados B2B, un número relativamente pequeño de compradores organizacionales genera la mayor parte del volumen de ventas. Los mercados B2C operan con millones de transacciones individuales; la ley de los grandes números estabiliza las estimaciones agregadas. Esa estabilización no está disponible en B2B. Jovanovic et al. (2025) reconocen esta característica al señalar que las transacciones B2B se caracterizan por su naturaleza compleja, la presencia de centros de compra y un menor número de compradores comparado con el comercio minorista, lo que genera patrones de demanda con mayor variabilidad y menos regularidad estacional. Rohaan et al. (2022) operacionalizan la consecuencia directa al trabajar con un dataset de 180.000 líneas de cotización generadas por un número acotado de clientes industriales, donde el 81% de las solicitudes de oferta no se convierte en venta: esa asimetría de clases no aparece en los datasets de venta al por menor y requiere técnicas específicas de tratamiento del desequilibrio (under-sampling, SMOTE).
- La segunda característica es la **presencia de un pipeline comercial explícito como estructura organizativa del proceso de venta**. Las ventas B2B no se producen de forma instantánea, sino que atraviesan un proceso secuencial (prospección, cualificación, presentación de oferta, negociación, cierre) cuyo estado en cada momento está registrado en el sistema CRM de la empresa y proporciona información predictiva sobre el resultado final de cada oportunidad. Monat (2011) fundamenta teóricamente esta característica al identificar ocho determinantes de la decisión de compra industrial (percepción de necesidad, urgencia, capacidad de compra, confianza en el proveedor, competencia, valor, calidad y servicio) que son observables en el proceso de cualificación del lead y que constituyen la materia prima de los modelos de predicción de conversión. Bohanec et al. (2017) operacionalizan esta característica al construir un modelo con 22 atributos descriptivos del proceso de venta B2B (autoridad del contacto, tamaño de la empresa cliente, existencia de competidores, tipo de cliente, claridad del alcance, presupuesto asignado) que solo tienen sentido analítico en el contexto de un pipeline comercial con etapas formalizadas. La existencia de esta estructura hace que el forecasting B2B de oportunidades individuales sea fundamentalmente un problema de clasificación supervisada con variables relacionales. No es un problema de extrapolación de series temporales.
- La tercera característica es la **asimetría del coste del error de predicción**. El coste de sobreestimar la demanda (producir o aprovisionar en exceso) y el de subestimar (perder ventas por falta de capacidad o inventario) no son simétricos, y varían según el sector y el modelo de negocio. Chang et al. (2007) justifican la elección del MAPE como métrica de evaluación precisamente porque la magnitud del error relativo es directamente proporcional al coste operativo: un MAPE del 2,11% frente al 9,88% de la regresión múltiple

no es una mejora abstracta, sino una reducción concreta de los costes de ajuste de capacidad productiva en manufactura de PCB. Rohaan et al. (2022) señalan que el coste de clasificar erróneamente una oportunidad de venta como pérdida (falso negativo) es sistemáticamente mayor que el de clasificarla como ganada, porque supone renunciar a ingresos con margen elevado; esa asimetría justifica el umbral de clasificación optimizado en 0,62 que adoptan, frente al umbral estándar de 0,50. Se establece el marco metodológico de esta discusión: la selección de la métrica de error debe estar guiada por el coste de la decisión que el pronóstico orienta, no por la conveniencia matemática de la métrica.

- La cuarta característica es la **dependencia de variables exógenas con alta volatilidad**. Las ventas B2B en sectores industriales, de distribución y logística están determinadas no solo por patrones históricos propios de la empresa, sino por variables macroeconómicas, sectoriales y relacionales que evolucionan de forma no estacionaria y que son difíciles de capturar mediante modelos puramente autorregresivos. Sohrabpour et al. (2021) identifican el tipo de cambio y los costes de producción como los determinantes más influyentes de las exportaciones de una empresa industrial del Medio Oriente, con una sensibilidad de 0,96 para los costes de producción frente a una sensibilidad nula de los descuentos aplicados (resultado que contradice la intuición directiva convencional y que solo es verificable mediante un modelo causal que incorpore esas variables exógenas). Wang et al. (2025) extienden este argumento al sector de logística marítima, donde los KPI de flete (CCFI, SCFI, BCI) tienen mayor poder predictivo sobre la demanda de capacidad que los propios historiales de ventas de la empresa. Huang et al. (2025) incorporan la dimensión más disruptiva de esa dependencia: los datos de redes sociales y los registros de pandemia como variables explicativas de las ventas de automóviles B2B en China, con la consecuencia de que los modelos puramente basados en datos históricos pierden validez predictiva durante eventos de ruptura estructural.
- La quinta característica es la **escasez relativa de observaciones históricas en el nivel de granularidad relevante para la decisión**. El contraste con el retail es nítido: miles de transacciones diarias por SKU generan series estadísticamente estables. El forecasting B2B opera en condiciones opuestas. Monat (2011) trabaja con 324 leads históricos de un período de tres años; Sohrabpour et al. (2021), con 58 semanas de datos semanales; Bohanec et al. (2017), con 448 oportunidades históricas de una empresa de software; Zadeh et al. (2014), con 217 medicamentos con 36 meses de registros completos sobre un total de aproximadamente 1.200 referencias de producto. Esa escasez obliga a diseños metodológicos específicos (técnicas de transfer learning implícito mediante agrupación de series similares, como en Zadeh et al., 2014; ensamblaje de métodos de clustering para aprovechar la correlación entre productos, como en Lu y Kao, 2016) que no tienen equivalente en el forecasting de consumo masivo.

Sobre la clasificación del corpus en base a su definición del forecasting de ventas B2B

El corpus **no contiene una taxonomía explícita y compartida** del forecasting de ventas B2B. La lectura cruzada de los objetivos, variables dependientes y contextos empíricos de los veinte artículos permite identificar tres ejes de clasificación implícitos que estructuran el campo y que tienen relevancia directa para el diseño de investigación del presente trabajo.

El primer eje opone los **problemas de predicción de series temporales de demanda agregada** (variable dependiente continua, nivel de análisis empresa o categoría de producto, horizonte temporal fijo) **a los problemas de clasificación del resultado de oportunidades individuales** (variable dependiente binaria, nivel de análisis oportunidad o lead, horizonte igual al ciclo de venta). La distinción no es terminológica. Tiene consecuencias metodológicas directas: los primeros son apropiados para modelos de regresión, series temporales y redes neuronales recurrentes; los segundos, para clasificación supervisada, árboles de decisión, random forest y redes de grafos. Rezazadeh (2020) es el único artículo del corpus que tematiza explícitamente esta oposición, al describir un flujo generalizado que diferencia entre opportunity scoring y demand forecasting como dos subproblemas con datos, modelos y métricas de evaluación distintos.

El segundo eje opone los **problemas de horizonte corto** (predicción del mes o trimestre siguiente, relevante para la planificación operativa de producción e inventarios) **a los de horizonte largo** (predicción en un horizonte de uno a tres años, relevante para la planificación estratégica de capacidad y expansión comercial). Chang et al. (2007, 2008) trabajan con horizontes de un mes sobre series de demanda de PCB; Lu et al. (2012) comparan explícitamente modelos con horizontes de uno, dos y tres meses sobre datos de mayoristas de informática; Wang et al. (2025) extienden el horizonte hasta doce meses sobre datos de demanda de transporte marítimo. La elección del horizonte no es solo un parámetro de diseño. Condiciona la pertinencia de las arquitecturas disponibles (los modelos ARIMA son superiores a corto plazo en series estacionarias pero inferiores a largo plazo en series con no-linealidades, como documentan sistemáticamente los benchmarks del corpus) y determina el valor organizativo del sistema, que aumenta cuando el horizonte es suficientemente largo para que la organización pueda actuar sobre el pronóstico antes de que el período predicho se materialice.

Tabla 8 - Resumen del corpus en base a su tipología y contexto de estudio

Artículo (Año)	Sector / contexto, ejes de clasificación y método de IA
<i>Chang, Wang y Liu (2007)</i>	Manufactura PCB (Taiwán). Serie temporal de demanda agregada. Horizonte corto (1 mes). Multivariado (4 variables seleccionadas por GRA). Método: WEFuNN, red neuronal difusa; MAPE 2,11%.
<i>Lackman (2007)</i>	Componentes de automoción B2B (EE.UU.). Estimación causal. Horizonte medio (trimestral, 3 años). Multivariado (9 variables: product ratings, direct selling, advertising, sales promotion, own price, competitor price, disposable income, auto consumption, supply). Método: simulación dinámica de mercado (ecuaciones estructurales de demanda y oferta con modelo de Holt-Winters para variables independientes).
<i>Chang, Liu y Lai (2008)</i>	Manufactura PCB (Taiwán). Serie temporal de demanda agregada. Horizonte corto (1 mes). Multivariado (4 variables seleccionadas por SRA). Método: FCBP, razonamiento basado en casos; MAPE 4,83%.
<i>Monat (2011)</i>	Hardware y software de telemarketing (EE. UU.). Clasificación de oportunidades. Horizonte de ciclo de venta. Multivariado (16 atributos del lead). Método: modelo de puntuación cualitativo con análisis discriminante rudimentario; accuracy $\approx$ 65%.
<i>Hadavandi, Shavandi y Ghanbari (2011)</i>	Manufactura PCB (China). Serie temporal de demanda agregada. Horizonte corto (1 mes). Multivariado (4 variables). Método: KGFS, K-means con sistemas genético-difusos por clúster; MAPE 1,46%.
<i>Lu, Lee y Lian (2012)</i>	Distribución mayorista de TI (Taiwán). Serie temporal de demanda agregada. Horizonte corto (1-3 meses). Univariado (lags y medias móviles). Método: MARS frente a redes neuronales artificiales.
<i>Zadeh, Sepehri y Farvareh (2014)</i>	Distribución farmacéutica (Irán). Serie temporal de demanda agregada. Horizonte mensual. Multivariado (registros históricos de co-miembros del clique). Método: redes neuronales híbridas con análisis de grafos de correlación.
<i>Lu y Kao (2016)</i>	Distribución de servidores informáticos (Taiwán). Serie temporal de demanda agregada. Horizonte corto (1 mes, one-step-ahead). Univariado (lags y MA3). Método: EN-ELM, K-means con extreme learning machine y ensamblado de enlaces.
<i>Bohanec, Borštnar y Robnik-Šikonja (2017)</i>	Software B2B (Eslovenia). Clasificación de oportunidades. Horizonte de ciclo de venta. Multivariado (22 atributos). Método: modelos supervisados con explicabilidad (EXPLAIN/IME).
<i>Rezazadeh (2020)</i>	B2B genérico (Azure ML). Ambos subproblemas (opportunity scoring y demand forecasting). Horizonte no reportado. Multivariado. Método: flujo generalizado de aprendizaje automático en Azure.
<i>Wisesa, Adriansyah y Khalaf (2020)</i>	Telecomunicaciones B2B (Indonesia). Serie temporal de demanda agregada. Horizonte no reportado. Predictores no reportados. Método: comparación de cuatro técnicas; mejor resultado con Gradient Boosting.
<i>Sohrabpour et al. (2021)</i>	Exportación corporativa (Oriente Medio). Estimación causal. Horizonte corto (semanal). Multivariado (5 variables exógenas). Método: Programación Genética (EUREQA) con análisis de sensibilidad de variables.
<i>Rohaani, Topan y Groothuis-Oudshoorn (2022)</i>	Recambios industriales posventa (Países Bajos). Clasificación de oportunidades. Horizonte de ciclo de venta. Multivariado (13 features). Método: Random Forest con umbral optimizado (0,62) y NLP.
<i>Zhang y Kim (2023)</i>	Ventas empresariales (sector no especificado). Serie temporal de demanda agregada. Horizonte no reportado. Univariado (sólo historial). Método: arquitectura híbrida HATT-MSCNN-IBiLSTM con atención.

<i>Pekkaya et al. (2024)</i>	Siderurgia (Turquía). Estimación causal. Horizonte corto (mensual). Multivariado (9 variables). Método: redes neuronales (Levenberg-Marquardt) frente a OLS, sintetizadas con GRA.
<i>Chen (2025)</i>	Ordenadores de grado industrial. Serie temporal de demanda agregada. Horizonte no reportado. Predictores no reportados. Método: algoritmo de aprendizaje inmunológico y de inteligencia de enjambre.
<i>Henna, Kalliadan y Amjath (2025)</i>	CRM B2B (grafos espectrales). Clasificación de oportunidades. Horizonte de ciclo de venta. Multivariado (métricas de grafo). Método: redes convolucionales de grafos espectrales (SGCN).
<i>Huang et al. (2025)</i>	Automoción B2B (China). Serie temporal de demanda agregada. Horizonte no reportado. Multivariado (señales de redes sociales y pandemia). Método: modelos con información de medios sociales bajo emergencias sanitarias.
<i>Jovanovic et al. (2025)</i>	Ventas de Amazon (RNN + VMD). Serie temporal de demanda agregada. Horizonte no reportado. Univariado (descomposición VMD). Método: redes recurrentes ajustadas por metaheurísticas.
<i>Wang et al. (2025)</i>	Logística marítima (portacontenedores y graneleros). Serie temporal de demanda agregada. Horizonte largo (hasta 12 meses). Multivariado (KPI de flete). Método: identificación de KPI y modelado predictivo.

El tercer eje opone los **problemas univariados** (único predictor: el historial pasado de la propia serie de ventas) a los **multivariados** (el modelo incorpora variables exógenas de naturaleza macroeconómica, sectorial, relacional o conductual). Este eje es el que mayor evolución temporal exhibe en el corpus. Los artículos del período 2007-2014 tienden al diseño univariado o con pocas variables exógenas seleccionadas mediante análisis de correlación (Chang et al., 2007, 2008; Lu et al., 2012); los del período 2020-2025 incorporan variables exógenas de mayor diversidad, incluyendo métricas de grafos CRM (Henna et al., 2025), KPIs de flete marítimo (Wang et al., 2025) y datos de redes sociales y pandemia (Huang et al., 2025). La incorporación de variables exógenas solo está justificada si mejora el rendimiento predictivo en datos no vistos durante el entrenamiento; condición que no todos los artículos del corpus verifican con el mismo rigor metodológico (Hyndman y Koehler, 2006).

3.2 Conexión con el marco conceptual y sus dimensiones

El marco conceptual establecido anteriormente articula claramente cuatro dimensiones analíticas: precisión del forecasting (D1), interpretabilidad y explicabilidad (D2), adopción tecnológica (D3) y gestión del cambio organizativo (D4) que no constituyen categorías descriptivas sino lentes de lectura aplicadas sobre el corpus.



Figura 6 - Cobertura de las dimensiones conceptuales dentro del corpus de artículos (elaboración propia)

La **dimensión D1 (precisión del forecasting)** está operacionalizada en la totalidad del corpus: los veinte artículos presentan al menos una métrica de error y un modelo de referencia frente al qué evaluar la mejora predictiva. Sin embargo, la diversidad de métricas empleadas (MAPE, RMSE, MAE, R^2 , AUC, F1 score) y la ausencia de un protocolo de comparación estandarizado impiden la síntesis directa de resultados entre estudios. La dimensión D1 no es, por tanto, un denominador común operativo: es un referente analítico que permite al revisor ordenar los hallazgos del corpus según la magnitud y las condiciones de la mejora predictiva documentada (Hyndman y Koehler, 2006; Tashman, 2000). La **dimensión D2 (interpretabilidad)** aparece como preocupación explícita sólo en Bohanec et al. (2017), que construyen un sistema de explicación post-hoc denominado EXPLAINIME

específicamente diseñado para hacer auditable la salida de un modelo de Random Forest en contexto de ventas B2B. Los demás artículos del corpus ignoran sistemáticamente esta dimensión o la mencionan de forma tangencial en las secciones de trabajo futuro (Adadi y Berrada, 2018).

La **dimensión D3 (adopción tecnológica)** es abordada de forma directa en Monat (2011), Rezazadeh (2020) y Rohaan et al. (2022), que son los únicos estudios del corpus que documentan las condiciones organizativas de implantación del modelo y no solo su rendimiento técnico sobre datos históricos: los marcos TAM y UTAUT (Davis, 1989; Venkatesh et al., 2003) operan aquí como referente interpretativo para leer la evidencia sobre barreras de uso. La **dimensión D4 (gestión del cambio)** es la más ausente del corpus: ningún artículo aborda de forma sistemática el proceso de transformación organizativa que sigue a la decisión de adoptar un sistema de IA para el forecasting comercial, lo que constituye por sí mismo un hallazgo relevante para la agenda de investigación futura que se formulará más adelante.

La caracterización cualitativa precedente identifica qué dimensiones aborda cada estudio; la matriz que sigue traduce esa lectura a una escala ordinal que permite cuantificar la intensidad agregada de cada dimensión sobre el conjunto del corpus. Cada artículo recibe **una puntuación de uno a tres según el grado en que cada dimensión se aborda como objetivo de estudio**.

- Un valor de tres indica que la dimensión constituye un objetivo primario, con hipótesis, métricas o procedimientos diseñados específicamente para examinar en detalle.
- Un valor de dos señala tratamiento tangencial: la dimensión aparece en limitaciones o trabajo futuro, pero no condiciona el diseño metodológico.
- Un valor de uno corresponde a la ausencia analítica, ya sea por omisión o por mención incidental sin desarrollo.

La escala no mide la calidad del trabajo. Mide la centralidad que cada dimensión ocupa en el diseño de la investigación, una distinción que separa lo que un estudio logra de lo que un estudio propone. La agregación de esas puntuaciones revela una jerarquía nítida de atención investigadora, en la que **la distancia entre la dimensión predictiva y las dimensiones organizativas no es gradual sino abrupta**. Esa asimetría de cobertura no es un defecto de los estudios individuales, sino un sesgo estructural del campo que la puntuación dimensional hace visible y que la agenda de investigación posterior traduce en preguntas concretas.

Tabla 9 - Evaluación del corpus en base a su contribución a la dimensión del marco conceptual

Artículo (Autor/Año)	D1	D2	D3	D4	Contribución dominante
<i>Chang et al. (2007)</i>	3	2	1	1	D1: WEFuNN supera a BPN, MLR, GANN (MAPE 2,11%)
<i>Lackman (2007)</i>	3	1	1	1	D1: Modelo de simulación basado en product, promotion & pricing
<i>Chang et al. (2008)</i>	3	2	1	1	D1: FCBR como alternativa epistemológica a modelos inductivos
<i>Monat (2011)</i>	2	2	3	3	D3+D4: Adopción en contexto de leads industriales; benchmark vs. juicio humano
<i>Hadavandi et al. (2011)</i>	3	2	1	1	D1: KGFS con clustering previo > MAPE 1,52%
<i>Lu y Wang (2012)</i>	3	2	1	1	D1: MARS superior estadísticamente a ANN (Wilcoxon $p < 0,01$)
<i>Zadeh et al. (2014)</i>	3	1	1	1	D1: Transfer learning implícito via cliques; MAE (87,6% sobre ARIMA)
<i>Lu y Kao (2016)</i>	3	1	1	1	D1: EN-ELM3 con Wilcoxon; principio de diversidad en ensemble
<i>Bohanec et al. (2017)</i>	3	3	2	2	D2: Único estudio de XAI B2B con RF+EXPLAINIME; confianza directiva

<i>Rezazadeh (2020)</i>	3	1	3	2	D1+D3: Pipeline Azure ML en producción real; FVA vs. vendedor
<i>Wisesa et al. (2020)</i>	2	1	2	1	D1+D3: Barreras de datos en economía emergente; ML básico aplicado
<i>Sohrabpour et al. (2021)</i>	3	1	1	1	D1: Mejora condicional RF; tipo de cambio como predictor crítico
<i>Rohaani et al. (2022)</i>	2	2	3	2	D3: Gobernanza de datos como barrera primaria; NLP en RFQs
<i>Zhang et al. (2023)</i>	3	1	1	1	D1: Red híbrida atención + series temporales sobre LSTM
<i>Pekkaya y Uysal (2024)</i>	3	2	1	1	D1: R ² 0,85; tipo de cambio EUR/TRY como predictor dominante
<i>Henna et al. (2025)</i>	3	1	2	1	D1: GCN espectral sobre grafo relacional B2B
<i>Chen (2025)</i>	3	1	1	1	D1: ImmunoSwarm en series de alta volatilidad
<i>Huang et al. (2025)</i>	3	1	1	1	D1: Señal digital útil en pandemia; condicional al régimen
<i>Jovanovic et al. (2025)</i>	3	1	1	1	D1: VMD+metaheurística en series descompuestas; Wilcoxon
<i>Wang et al. (2025)</i>	3	1	2	1	D1: KPIs exógenos marítimos en stacking multi-modelo
TOTAL	57	29	30	25	
PROMEDIO	2,85	1,45	1,50	1,25	

El patrón de cobertura que emerge de la tabla es notablemente asimétrico y tiene implicaciones directas para la agenda de investigación futura. La dimensión D1 (precisión del forecasting) alcanza una puntuación media de 2,85 sobre 3, lo que confirma que la totalidad del corpus está estructurado en torno a la mejora de métricas de error predictivo: es el único objetivo de investigación que ningún artículo del corpus ignora, y el único para el que existe una métrica estándar aunque no compartida que permite la comparación. La dimensión D2 (interpretabilidad y explicabilidad) alcanza una puntuación media de 1,45: solo Bohanec et al. (2017) la abordan como objetivo primario; Chang et al. (2007), Chang et al. (2008), Hadavandi et al. (2011), Lu y Wang (2012), Rohaani et al. (2022) y Pekkaya y Uysal (2024) la mencionan tangencialmente en sus secciones de limitaciones o trabajo futuro; y trece de los veinte artículos la ignoran por completo. Esa concentración de la producción científica en D1 con abandono casi total de D2 en los estudios más recientes (la totalidad de los siete artículos del período 2023-2025 puntúan 1 en D2) no refleja que la interpretabilidad haya dejado de ser relevante para los directivos comerciales en manufactura, siderurgia, logística o distribución farmacéutica: refleja que **los equipos de investigación priorizan la novedad arquitectónica sobre la adoptabilidad organizativa**, y que las revistas del campo no penalizan esa asimetría en el proceso de revisión.

Las **dimensiones D3 y D4 exhiben puntuaciones bajas en el corpus** (1,50 y 1,25 respectivamente) lo que representa una deficiencia de cobertura grave, precisamente porque son las dimensiones que determinan si el valor técnico documentado en D1 llega o no a traducirse en valor organizativo real. Solo cuatro artículos abordan D3 (adopción tecnológica) con puntuación 3: Monat (2011), Rezazadeh (2020), Rohaani et al. (2022) y, parcialmente, Wisesa et al. (2020). Ningún artículo del corpus aborda D4 (gestión del cambio organizativo) como objetivo primario, lo que puede confirmarse por la ausencia de cualquier marco teórico de transformación organizativa (modelos de etapas de adopción institucional, análisis de actores de resistencia, evaluación de impacto en procesos de planificación comercial) en los veinte artículos. La puntuación media de 1,25 en D4, refleja que la mayoría de los artículos **ni siquiera mencionan el cambio organizativo en sus secciones** de limitaciones o trabajo futuro: lo ignoran por completo. Esa invisibilidad de D4 en el corpus no es evidencia de que el cambio organizativo sea fácil o irrelevante en la adopción de IA para el forecasting B2B en manufactura, distribución industrial, siderurgia o logística: es evidencia de que la investigación académica en el campo no ha desarrollado las herramientas teóricas

ni los diseños de investigación necesarios para estudiar ese proceso, que requiere metodologías longitudinales mixtas costosas de implementar y difíciles de publicar en las revistas de ingeniería y sistemas expertos donde se concentra el corpus.

La intersección entre la cobertura de D3 y D4 y la distribución sectorial del corpus revela una regularidad que merece ser señalada con cautela. Los únicos estudios con puntuaciones ≥ 2 en D3 y D4 provienen de contextos occidentales o de servicios B2B: Monat (2011) en EE.UU., Rezazadeh (2020) en Canadá, Rohaan et al. (2022) en los Países Bajos, Bohanec et al. (2017) en Eslovenia. Mientras, los estudios asiáticos que dominan el corpus en número (siete taiwaneses, tres chinos, tres iraníes) presentan sistemáticamente puntuaciones de 1 en ambas dimensiones. Este patrón observable en los datos de la tabla no puede interpretarse, a partir del corpus analizado, como evidencia de diferencias culturales en las prioridades de investigación; los datos no permiten separar si esa regularidad refleja orientaciones epistemológicas distintas, diferencias en el acceso de los investigadores a organizaciones B2B para estudiar procesos de adopción, o simplemente las normas editoriales de las revistas en que cada comunidad pública. Lo que sí puede afirmarse es que **la dimensión organizativa de la adopción de IA en el forecasting B2B está documentada casi exclusivamente por estudios con contexto empírico occidental**, y que esa concentración geográfica constituye una limitación de cobertura del corpus que cualquier agenda de investigación futura debería corregir mediante estudios comparativos explícitamente diseñados para ello.

3.3 Taxonomía de metodologías de IA

Los veinte artículos del corpus pueden organizarse en **tres familias metodológicas con fronteras temporales relativamente nítidas**, aunque no absolutas. La primera familia agrupa los modelos simbólicos, fuzzy y basados en casos, presentes en el período 2007-2014. La segunda familia reúne los modelos de aprendizaje supervisado clásico y los ensamblajes modernos, con presencia principalmente entre 2011 y 2022. La tercera familia comprende las arquitecturas deep learning e híbridas de última generación, dominantes en el período 2023-2025. Esa secuencia temporal no describe un progreso lineal hacia la superioridad técnica: describe una **acumulación de opciones disponibles**, cada una con ventajas específicas según el contexto de aplicación, la cantidad de datos disponibles y las exigencias de interpretabilidad del entorno organizativo. La lectura pluralista que la evidencia del corpus sostiene (distintas arquitecturas para distintos contextos, con distintos trade-offs entre precisión, interpretabilidad y coste de implantación) es la que una síntesis a nivel doctoral debe defender frente a la narrativa de progreso lineal que domina en las revisiones generalistas del campo y que la evidencia del corpus no válida.




Figura 7 - Organización del corpus en familias según su tipología y contexto temporal (elaboración propia)

2007-2014, Modelos simbólicos, fuzzy y basados en caso

La primera generación de modelos aplicados a contextos B2B de manufactura electrónica, distribución farmacéutica y conversión de leads comparte una **epistemología fundacional** cualitativamente distinta a la de las familias

posteriores: la superioridad predictiva no reside en la complejidad arquitectónica sino en la calidad de la representación del conocimiento sobre las series. Tanto la red neuronal fuzzy evolutiva ponderada de Chang et al. (2007) como el sistema genético-fuzzy con clustering previo de Hadavandi et al. (2011) explotan esa intuición mediante mecanismos diferentes (aprendizaje evolutivo de particiones fuzzy en el primero, segmentación K-means seguida de subsistemas fuzzy especializados en el segundo) convergiendo en el mismo hallazgo empírico: la reducción de la varianza intra-segmento precede y condiciona la precisión del modelo. El FCBR de Chang et al. (2008) añade una variante epistemológica adicional a esa misma familia: en lugar de aprender reglas desde los datos, cristaliza el conocimiento en repositorios de casos análogos recuperables mediante similitud fuzzy. Los tres mecanismos (aprendizaje evolutivo de reglas, segmentación previa con especialización de submodelos, y recuperación por similitud) representan tres respuestas distintas al mismo problema estructural del forecasting B2B en contextos de catálogo reducido: cómo incorporar el conocimiento de dominio en el modelo sin sacrificar la adaptabilidad ante nuevos patrones de demanda.

En esta primera etapa también aparece un **enfoque no inductivo que conviene diferenciar de los sistemas fuzzy y basados en casos**: la simulación dinámica de mercado aplicada a una categoría B2B específica. Lackman (2007) desarrolla un modelo estructural de demanda y oferta para componentes de automoción, donde la predicción de ventas se deriva explícitamente de variables de marketing mix (producto, promoción y precio) y de señales macroeconómicas exógenas. La contribución no reside en una arquitectura de aprendizaje automático, sino en una representación causal del mercado que permite, además del forecast, un análisis what-if sobre qué niveles de mix acercan la empresa a un objetivo de ingresos. Este tipo de modelización ilustra que, en B2B, parte del valor del forecasting no se juega solo en reducir error, sino en producir una previsión accionable y justificable en términos de palancas de decisión.

El contexto taiwanés de fabricación de PCB funciona como un laboratorio natural de progresión metodológica acumulativa que es rarísimo en la literatura de forecasting B2B. Los tres estudios de Chang et al. (2007), Chang et al. (2008) y Hadavandi et al. (2011) operan con datos procedentes del mismo sector industrial, con series temporales de naturaleza similar y con métricas de evaluación comparables: WEFuNN establece el benchmark con MAPE del 2,11%; FCBR explora el razonamiento basado en casos como alternativa epistemológica, con MAPE del 2,30%; y KGFS mejora el benchmark mediante la introducción del pre-clustering K-means, con MAPE del 1,52%. Esa progresión acumulativa permite separar el efecto del algoritmo del efecto del dataset: el único factor que varía entre estudios es la arquitectura, no los datos ni el contexto, lo que produce una de las pocas comparaciones genuinamente controladas del corpus. La mejora de MAPE desde 2,11% (WEFuNN) hasta 1,52% (KGFS) constituye, en los términos del corpus analizado, la aproximación más cercana a un experimento controlado que este campo ha producido en sus casi veinte años de literatura documentada: una evidencia empíricamente más sólida que la mayoría de las comparaciones reportadas entre modelos entrenados sobre datasets distintos, en sectores distintos, con horizontes de predicción distintos y con métricas de evaluación distintas.

La comparación entre WEFuNN y FCBR ilumina una tensión epistemológica que atraviesa el corpus completo. WEFuNN aprende la partición fuzzy de forma evolutiva desde los 60 registros mensuales de ventas de PCB de Golden Circuit Company: los pesos de los antecedentes de las reglas se ajustan iterativamente mediante un algoritmo evolutivo que minimiza el error de predicción sobre los 48 datos de entrenamiento (Chang et al., 2007). El resultado es un sistema que adapta sus reglas a la distribución observada, pero cuya representación del conocimiento emerge inductivamente desde los datos. FCBR, por el contrario, recupera casos pasados cuyos atributos son similares al nuevo escenario de previsión y construye la predicción combinando los resultados de esos casos análogos, ponderados por su similitud (Chang et al., 2008). El conocimiento en FCBR no se aprende: se cristaliza en los casos almacenados. Esa diferencia tiene implicaciones para la robustez ante distribuciones de datos no vistas. Ante una situación de ventas genuinamente nueva, sin casos análogos disponibles, FCBR se deteriora de forma más abrupta que un modelo inductivo. La elección entre ambos mecanismos no es técnica en sentido estricto: es una elección sobre qué tipo de robustez se prioriza, flexibilidad ante novedades o consistencia sobre casos conocidos.

El mecanismo de selección de variables que Chang et al. (2007) implementan mediante el Análisis Relacional Gris (GRA) anticipa conceptualmente los métodos de feature importance de la segunda generación (random forest

importance, permutation importance, valores SHAP) pero lo hace desde una teoría del dato cualitativamente diferente: no desde la reducción del error de predicción en un modelo entrenado, sino desde la geometría de la covariación de las series temporales en bruto. El coeficiente gris no asume linealidad ni normalidad de los residuos y es robusto ante la presencia de outliers porque opera sobre rangos relativos, una ventaja no marginal en contextos B2B donde las series históricas son cortas y los valores extremos introducidos por grandes pedidos de cuentas clave son estructuralmente frecuentes (Chang et al., 2007). La selección mediante GRA de cuatro factores (índice de comercio de exportación, demanda de elementos de cristal líquido, valor de ventas PCB de la industria y pronóstico de Winters) sobre los 15 candidatos iniciales es, así, una herramienta de análisis exploratorio con valor independiente del modelo que la aplica; y esa utilidad autónoma, que las generaciones posteriores han abandonado sin justificación explícita, constituye una de las aportaciones metodológicas más subestimadas del corpus. Los estudios de la segunda y tercera familia que incorporan variables exógenas macroeconómicas (Pekkaya y Uysal, 2024, con el tipo de cambio EUR/TRY; Sohrabpour et al., 2021, con indicadores cambiarios iraníes; Wang et al., 2025, con índices de flete marítimo) seleccionan esas variables mediante criterios de importancia en modelos entrenados, lo que supone una dependencia circular ausente en el GRA.

La lógica detrás del pre-clustering K-means que Hadavandi et al. (2011) implementan en el sistema KGFS responde a un principio estadístico que, enunciado en su forma más abstracta, es el fundamento de múltiples arquitecturas de la segunda y tercera familia del corpus: segmentar antes de predecir reduce la varianza intra-grupo y permite especializar cada submodelo en el régimen de mercado que le corresponde. El mecanismo estadístico que explica la mejora de rendimiento es preciso: cada subsistema fuzzy opera sobre datos que son más homogéneos entre sí que el conjunto completo, lo que facilita la estimación de reglas con menor error de aproximación. Esa intuición de divide-and-conquer reaparece en la descomposición modal de varianza (VMD) de Jovanovic et al. (2025) (que separa los modos de frecuencia de la señal de ventas para reducir la complejidad de lo que cada componente del modelo debe aprender) y en la segmentación de KPIs operativos de Wang et al. (2025), que permite al modelo condicionar sus predicciones al régimen de actividad del mercado marítimo. El principio de divide-and-conquer es, así, una regularidad que atraviesa el corpus completo desde 2007 hasta 2025, manifestándose con vocabulario arquitectónico radicalmente diferente pero respondiendo a la misma intuición estadística: la diversidad gestionada produce mayor robustez que el modelo universal.

La contribución de Zadeh et al. (2014) merece una lectura más detenida de la que su clasificación como modelo híbrido ANN-estadístico sugiere en primera instancia. La idea central del trabajo (construir cliques de medicamentos con correlaciones de ventas superiores a 0,65 mediante análisis de grafos con software Gephi, y usar los registros de ventas de los miembros del clique como variables exógenas en la predicción del producto objetivo) es, en términos de la teoría del aprendizaje automático contemporánea, una forma implícita de transfer learning (Zadeh et al., 2014). Los datos de ventas de productos correlacionados compensan la escasez de los 36 meses de registros del producto objetivo, trasladando información predictiva desde nodos con datos funcionalmente abundantes hacia nodos con datos escasos: los MAE medios descienden de 7.263,20 (ARIMA) a 898,15 (modelo híbrido con comembros del clique), una reducción del 87,6% sobre los 21 medicamentos analizados. Esa intuición, formulada en 2014 sin el vocabulario del aprendizaje por transferencia, reaparece once años después en Henna et al. (2025), que utilizan redes de convolución espectral en grafos (GCN) para incorporar la estructura relacional del grafo de clientes B2B como fuente de información predictiva adicional. Ambos estudios (separados por once años, situados en sectores y países completamente distintos, y empleando arquitecturas tecnológicamente incomparables) resuelven el mismo problema estructural: la escasez de datos de un único nodo mediante la explotación de la estructura relacional del grafo en el que ese nodo está embebido. Esa convergencia de intuición, rara en una literatura tan fragmentada, constituye uno de los hallazgos transversales más relevantes del corpus: sugiere que el aprendizaje por transferencia implícito en estructuras de grafos B2B puede constituir una línea de investigación fértil con independencia de la sofisticación arquitectónica de los modelos que la implementen.

La familia simbólica y fuzzy, considerada como conjunto, ofrece interpretabilidad estructural: las reglas fuzzy y los casos recuperados son el modelo, no una aproximación post-hoc al modelo. Esta propiedad distingue cualitativamente a esta primera familia de las dos familias posteriores, donde la interpretabilidad es siempre extrínseca (un mecanismo añadido sobre un modelo opaco y, por tanto, más frágil y más susceptible de

inconsistencias (Adadi y Berrada, 2018)). Cuando un directivo comercial pregunta por qué el sistema WEFuNN predice un determinado volumen de ventas de PCB, la respuesta es auditable directamente en las reglas fuzzy generadas por el algoritmo evolutivo. Cuando el mismo directivo pregunta por qué el Gradient Boosting de Rezazadeh (2020) predice ese valor, la respuesta requiere invocar un mecanismo de explicación post-hoc que aproxima la contribución de cada variable de forma local, no global, y que puede dar resultados inconsistentes ante variaciones menores de los inputs de entrada. Esa diferencia no es solo técnica: tiene implicaciones directas para la confianza del usuario final, para la auditabilidad de las decisiones comerciales en sectores regulados como la distribución farmacéutica (Zadeh et al., 2014), y para la sostenibilidad de la adopción a largo plazo en cualquier entorno B2B donde las predicciones deban ser justificadas ante la dirección o ante los clientes.

Los modelos de esta primera familia comparten una limitación que ninguno de los artículos del período 2007-2014 aborda explícitamente: su escalabilidad. Los sistemas fuzzy con particiones evolutivas y los sistemas de razonamiento basado en casos funcionan con eficiencia computacional aceptable sobre datasets de decenas o pocos cientos de referencias de productos, como los que caracterizan la manufactura de PCB taiwanesa (60 observaciones mensuales en Chang et al., 2007) o las series farmacéuticas de 36 meses en Zadeh et al. (2014). Su extensión a catálogos de miles de referencias requeriría mecanismos de indexación y recuperación que los artículos no desarrollan, y cuyo coste computacional aumenta de forma no lineal con el tamaño del catálogo. Esa limitación de escalabilidad no invalida la utilidad de esta familia para contextos de catálogo reducido, pero sí restringe su dominio de aplicación natural a los sectores industriales con menor amplitud de catálogo y explica parcialmente por qué los estudios de manufactura electrónica dominan esta línea mientras que sectores como distribución farmacéutica o logística marítima (con catálogos de miles de referencias) han migrado hacia las familias de ML clásico y Deep Learning.

2011-2022, Modelos de aprendizaje supervisado clásico y ensamblaje

La segunda familia del corpus emerge de una tensión que define el campo de la IA aplicada al forecasting comercial B2B desde la primera década del siglo: la tensión entre precisión e interpretabilidad. Los modelos de aprendizaje supervisado clásico (regresión multivariante adaptativa, extreme learning machines, redes neuronales feedforward, random forests, gradient boosting) son, en términos generales, más precisos que los modelos simbólicos y fuzzy sobre datasets de tamaño moderado con relaciones no lineales complejas. Esa mayor precisión tiene un coste: el directivo comercial que adopta un Gradient Boosting no puede auditar las razones que llevan al modelo a una predicción concreta sin invocar un mecanismo externo de explicación post-hoc. La familia simbólica ofrecía precisión suficiente y transparencia estructural; la familia de ML clásico ofrece mayor precisión y transparencia instrumental, si el usuario está dispuesto a invertir en mecanismos adicionales de explicación. Esa tensión no se resuelve en el corpus: la segunda familia la explicita, la documenta de forma dispersa y la deja abierta para la tercera generación, que incrementa la opacidad sin añadir explicabilidad.

El hallazgo más contraintuitivo de la segunda familia (y uno de los más relevantes para la práctica empresarial B2B) emerge del estudio de distribución mayorista de IT en Taiwán (Lu y Wang, 2012). MARS supera a los diez modelos de comparación en todas las métricas y bajo todos los ratios de partición de datos: para la Empresa A con ratio 80/20, MARS alcanza un MAPE de 0,11 frente a SVR (0,32), BPN (0,41), CMACNN (0,36) y ELM (0,35), diferencias estadísticamente significativas verificadas mediante el test de rangos con signo de Wilcoxon ($p < 0,01$). La superioridad de MARS sobre redes neuronales en muestras de tamaño moderado no reside en la mayor capacidad expresiva del primero: las redes neuronales pueden aproximar funciones arbitrariamente complejas. La explicación es estadística: MARS incorpora un mecanismo de regularización implícita a través de su procedimiento de construcción, añadiendo nodos de inflexión de forma adaptativa en el forward pass y eliminando los que no contribuyen suficientemente en el backward pass (una poda automática equivalente a la regularización explícita que las redes neuronales requieren como paso adicional) (Lu y Wang, 2012). Las redes neuronales, sin regularización explícita, tienden a sobreajustar cuando el tamaño del dataset es insuficiente. La implicación para la práctica empresarial es directa y contradice la creencia extendida de que mayor complejidad arquitectónica implica mayor precisión: en empresas B2B de manufactura o distribución mayorista con series históricas cortas (120 observaciones mensuales en Lu y Wang, 2012; 36-48 en los estudios PCB), un modelo de menor complejidad estadística puede

producir predicciones más fiables que uno de mayor complejidad, precisamente porque su menor número de parámetros es más fácilmente estimable con datos limitados.

Lu y Kao (2016) abordan un problema metodológico específico de las Extreme Learning Machines que la literatura raramente señala con suficiente claridad: la inestabilidad aleatoria introducida por la inicialización aleatoria de los pesos de la capa oculta. Su EN-ELM3 (que ensambla cinco ELMs inicializadas con distintos métodos de linkage para el clustering previo: K-means con single, complete, centroid, median y Ward linkage) obtiene un MAPE de 2,09% (Empresa A) y 2,22% (Empresa B) frente al 2,93% y 3,31% del mejor modelo de enlace único (WL-ELM3), con mejoras estadísticamente significativas verificadas mediante el test de Wilcoxon ($p < 0,05$ en la mayoría de comparaciones). La contribución metodológica es de primer orden: la diversidad entre los componentes del ensemble (inducida por los distintos métodos de clustering) reduce la correlación entre los errores de los distintos modelos, produciendo, por el principio de diversidad en teoría de ensamblajes, una predicción agregada con menor varianza que cualquiera de los modelos individuales. Este principio de diversidad conecta directamente con el pipeline ensemble de Rezazadeh (2020), que combina Gradient Boosting, Random Forest y Regresión Logística precisamente porque la heterogeneidad entre algoritmos reduce la covarianza de los errores de predicción. Lu y Kao (2016) son, además, el único estudio del corpus que aplica un test de significancia estadística formal para verificar que las mejoras de MAPE observadas no son producto de la variabilidad muestral. Esa práctica, ausente en diecinueve de los veinte artículos del corpus, debería constituir el estándar metodológico mínimo para cualquier comparación de modelos en forecasting B2B; su uso exclusivo en este trabajo ilustra cuán lejos está el campo de esa norma básica de rigor.

Wisesa et al. (2020) documentan la predicción de ventas B2B de servicios de telecomunicaciones en Indonesia mediante técnicas de ML básico y constituyen uno de los pocos estudios del corpus que documentan las barreras de calidad de datos en un contexto de economía emergente con acceso desigual a infraestructura digital. La publicación en una revista Q4 obliga a ponderar los resultados numéricos con cautela metodológica: la ausencia de revisión por pares rigurosa no invalida la contribución temática del trabajo, pero sí impone reservas ante las cifras específicas reportadas, que no pueden compararse directamente con los resultados del resto del corpus (Wisesa et al., 2020). El dato más relevante del trabajo no es la comparación de algoritmos sino la descripción del entorno de datos: registros de contratos corporativos incompletos, segmentación de clientes B2B imprecisa y sistemas de información con cobertura parcial. Esas barreras conectan directamente con las observaciones de Rohaan et al. (2022) sobre los problemas de gobernanza de datos en el proveedor de recambios industriales neerlandés (con duplicados de identificadores, inconsistencias en códigos de producto y discrepancias CRM/ERP), lo que sugiere que las barreras de calidad de datos en el forecasting B2B son transversales a culturas organizativas y contextos geográficos muy distintos. La conexión con Monat (2011) es igualmente instructiva: mientras Wisesa et al. documentan las barreras que impiden construir el modelo en condiciones mínimas de calidad de datos, Monat documenta las barreras de confianza que impiden adoptar un modelo que ya funciona técnicamente (la heterogeneidad en los criterios de clasificación de oportunidades por parte de los vendedores en el CRM introduce sesgos sistemáticos de entrenamiento análogos a los documentados en el entorno indonesio). Los tres estudios delimitan el espectro de barreras que una organización B2B enfrenta al intentar implantar IA para el forecasting: desde la infraestructura mínima de datos (Wisesa et al., 2020) hasta la calidad de los datos de entrenamiento generados por los propios usuarios (Monat, 2011; Rohaan et al., 2022).

Sohrabpour et al. (2021) producen el resultado metodológicamente más rico de la segunda familia. La superioridad del Random Forest sobre ARIMA en la predicción de exportaciones iraníes no es uniforme: varía entre el 15% y el 35% según el producto. Esa variabilidad no es ruido estadístico sino una señal sobre la heterogeneidad estructural de las series B2B (Sohrabpour et al., 2021). Los productos con alta volatilidad estacional y fuerte dependencia del tipo de cambio muestran ventajas del RF más pronunciadas, porque el modelo arbóreo puede capturar la interacción no lineal entre la señal de demanda subyacente y las perturbaciones cambiarias sin imponer supuestos de linealidad. Los productos con series más estables y menor dependencia de variables exógenas muestran ventajas más modestas, porque ARIMA puede capturar el patrón temporal subyacente con suficiente precisión sin necesitar la flexibilidad adicional del RF. La contribución teórica más importante de Sohrabpour et al. (2021) no reside, por tanto, en el hecho de que el RF supera a ARIMA (esa superioridad era esperable y ha sido documentada en múltiples contextos)

sino en la evidencia explícita de que esa superioridad es condicional a las características de la serie: no existe un algoritmo universalmente superior para el forecasting B2B en contextos de exportación; existen algoritmos cuya ventaja depende de la volatilidad, la estacionalidad, la dependencia de variables exógenas y el horizonte de predicción de cada serie específica.

Pekkaya y Uysal (2024) documentan la predicción de ventas de una acería turca mediante modelos de ML comparados con regresión lineal múltiple, con la particularidad de que el estudio identifica el tipo de cambio EUR/TRY y el precio de las materias primas importadas como los predictores de mayor importancia en los modelos arbóreos, con R^2 de 0,85 para RF y Gradient Boosting frente a 0,65 para la regresión lineal (Pekkaya y Uysal, 2024). Ese resultado converge con el de Sohrabpour et al. (2021) y con el de Wang et al. (2025), que identifican los índices de flete marítimo CCFI y BCI como predictores dominantes en la logística de contenedores, constituyendo los tres el conjunto de estudios del corpus que documentan la importancia de variables exógenas macroeconómicas para el forecasting B2B en economías con alta exposición internacional. Los tres trabajos (independientes en sectores, metodologías y períodos) señalan la misma dirección: en empresas B2B que operan en mercados internacionales, las variables macroeconómicas de exposición externa son predictores cuya omisión degrada de forma apreciable la precisión del modelo, con independencia de la sofisticación de la arquitectura empleada. El valor del hallazgo de Pekkaya y Uysal (2024) reside precisamente en la identificación explícita de que la ventaja del modelo de IA sobre el baseline estadístico se debe, en este sector, a la capacidad de los modelos arbóreos para capturar las interacciones no lineales entre las fluctuaciones cambiarias y los ciclos de demanda siderúrgica, una regularidad que la comparación transversal de los tres estudios citados traslada con consistencia suficiente al diseño de sistemas de forecasting en cualquier empresa B2B exportadora con exposición cambiaria significativa.

Rezazadeh (2020) produce la contribución de diseño más pragmáticamente valiosa de toda la segunda familia. La innovación central no es el algoritmo (el ensemble de Gradient Boosting, Random Forest y Regresión Logística que implementa no es técnicamente novedoso) sino la arquitectura de implantación: un pipeline reproducible en Azure Machine Learning que integra limpieza de datos, ingeniería de características, entrenamiento paralelo y ensemble en un flujo documentado y desplegable en producción (Rezazadeh, 2020). Esa arquitectura resulta más valiosa como contribución para la práctica que los resultados de AUC reportados (0,85 en test, 0,83 en producción sobre 846 oportunidades durante tres meses), precisamente porque es replicable y adaptable. Rezazadeh (2020) es el único estudio del corpus que valida el modelo en producción real documentando que la precisión del ensemble de ML (85% de accuracy en test; 83% en producción) fue superior a la de los vendedores en el CRM (67% en test; 63% en producción), con un diferencial de +18 puntos porcentuales en test y +20 en producción. Esta constituye la única medida directa de Forecast Value Added (FVA) sobre el proceso humano existente que el corpus proporciona (Tashman, 2000). La conexión con Rohaan et al. (2022) es instructiva por contraste: mientras Rezazadeh documenta las condiciones bajo las cuales el pipeline funciona en producción (datos CRM limpios, umbrales de decisión segmentados por cuartil de valor de contrato, reentrenamiento semanal automatizado), Rohaan documenta las condiciones bajo las cuales el modelo fracasa técnicamente por causas de gobernanza: discrepancias entre identificadores de empresa en el CRM y en el sistema de RFQs que impiden vincular el historial de compras de la cuenta con las características de la oportunidad entrante. Esa dualidad (éxito con datos gobernados en Rezazadeh frente a fracaso con datos no gobernados en Rohaan) define con mayor precisión que cualquier comparación de algoritmos cuál es la condición de contorno para la adopción exitosa de IA en el forecasting B2B.

Rohaán et al. (2022) abordan un problema que la etiqueta forecasting de ventas B2B agrupa con otros pero que es estructuralmente distinto: la clasificación y priorización de Requests for Quotation (RFQs) en una empresa de servicios de posventa industrial en los Países Bajos. El sistema que desarrollan combina técnicas de procesamiento de lenguaje natural para extraer características de las descripciones de los recambios solicitados con clasificadores de Gradient Boosting para estimar la probabilidad de que una RFQ resulte en una orden de compra exitosa (Rohaán et al., 2022). La distinción conceptual es metodológicamente importante: el trabajo no construye un forecast de series temporales sino un sistema de priorización del trabajo comercial, más parecido a un sistema de recomendación que a una predicción de demanda agregada, lo que revela la diversidad interna de los problemas que la literatura etiqueta conjuntamente como forecasting de ventas B2B. El fracaso documentado en Rohaan et al. (2022) no reside en el modelo sino en los datos: los autores describen extensamente la discrepancia entre identificadores de empresa

en el CRM y las direcciones de correo electrónico de los clientes en las RFQs, que impide una vinculación limpia entre el historial de compras de la cuenta y las características de la oportunidad entrante. Esa discrepancia no es un problema técnico solucionable con un algoritmo de deduplicación más sofisticado: es un problema de diseño institucional que conecta directamente con la barrera de gobernanza identificada en Rezazadeh (2020) y Monat (2011), confirmando que la calidad del CRM como fuente de entrenamiento es la limitación organizativa más transversal del corpus. La segunda familia, considerada como conjunto, produjo avances técnicos documentados, pero no generó ninguna de las cuatro infraestructuras metodológicas que un campo maduro requiere para acumular conocimiento sistemáticamente: no hay dataset compartido de benchmarking para forecasting B2B, no hay replicación independiente de ningún estudio por parte de otro equipo, no hay ningún estudio de seguimiento longitudinal que evalúe si los modelos mantienen su rendimiento en producción a lo largo del tiempo, y no hay ningún protocolo estandarizado de comparación adoptado por más de un artículo. La conclusión no es que los estudios de esta familia sean de baja calidad: es que el campo carece de la infraestructura metodológica colectiva necesaria para transformar sus resultados dispersos en conocimiento acumulativo, y esa carencia persiste durante diez años de producción científica (desde Lu y Wang, 2012, hasta Rohaan et al., 2022), lo que apunta a un déficit estructural y no a un descuido puntual de publicaciones aisladas.

2022-2025, Modelos de deep learning e híbridos de última generación

La tercera familia del corpus reúne siete estudios publicados entre 2023 y 2025, período que coincide con el auge de la inteligencia artificial en la literatura aplicada. Comparten el uso de arquitecturas de aprendizaje profundo (transformers, redes de convolución espectral en grafos, redes recurrentes optimizadas mediante metaheurísticas, algoritmos de inteligencia de enjambre e híbridos de atención con modelos de series temporales clásicos) aplicadas a problemas de forecasting de ventas en contextos B2B de manufactura electrónica, logística marítima, automoción, CRM y ventas empresariales. La convergencia hacia arquitecturas de combinación de modelos (stacking y ensemble) como patrón dominante de esta generación no es coincidental: Wang et al. (2025) y Jovanovic et al. (2025) adoptan explícitamente arquitecturas de apilamiento donde diferentes modelos especializados en distintos horizontes temporales o distintas frecuencias de la señal contribuyen a la predicción final; Zhang et al. (2023) combinan atención con componentes de series temporales clásicos; Chen (2025) hibrida inteligencia inmunológica con inteligencia de enjambre. Esa convergencia refleja la maduración del campo hacia la comprensión de que ninguna arquitectura única domina en todos los contextos B2B. La misma intuición, expresada con vocabulario diferente, subyace al EN-ELM3 de Lu y Kao (2016) y al sistema KGFS de Hadavandi et al. (2011): la diversidad de enfoques gestionada mediante agregación apropiada produce predicciones más robustas que cualquier modelo individual.

Zhang et al. (2023) desarrollan una arquitectura transformer aplicada a ventas empresariales chinas que combina módulos de atención multi-cabeza, inspirados en la arquitectura de Vaswani et al. (2017), con componentes de series temporales clásicas para capturar simultáneamente dependencias temporales de largo alcance y patrones de corto plazo, reportando mejoras de precisión sobre LSTM y ARIMA en todos los datasets de ventas empresariales evaluados. La contribución metodológica de este estudio reside en la demostración de que la arquitectura híbrida de atención produce ganancias sistemáticas sobre las redes recurrentes estándar incluso en series de ventas empresariales de alta volatilidad, aunque, al igual que la mayoría de los estudios de la tercera familia, no incorpora mecanismos de explicabilidad ni documenta validación en producción real.

Jovanovic et al. (2025) aplican la descomposición modal de varianza (VMD) seguida de redes recurrentes (LSTM, GRU) optimizadas mediante el algoritmo metaheurístico HAEDHO sobre el dataset de Amazon (que, aunque es un proxy imperfecto del contexto B2B en sentido estricto, representa el único dataset de ventas empresariales con dimensionamiento suficiente para entrenar arquitecturas profundas con garantías estadísticas) (Jovanovic et al., 2025). La contribución metodológica es doble: la aplicación de VMD como alternativa a la descomposición wavelet para la separación de modos de frecuencia en series de ventas con componentes de distinta escala temporal, y la optimización de los hiperparámetros mediante metaheurísticas, que supera la búsqueda en cuadrícula en precisión y eficiencia computacional. Wang et al. (2025) integran KPIs operativos específicos de la logística marítima (índice de utilización de buques, tiempo promedio de escala en puerto, fluctuaciones en el flete por TEU, índices CCFI y

BCI) como variables exógenas en un modelo híbrido de predicción de demanda para buques portacontenedores y graneleros Capesize, obteniendo mejoras sobre los baselines ARIMA y regresión logística en el dataset taiwanés analizado (Wang et al., 2025). La convergencia de Wang et al. (2025) con Pekaya y Uysal (2024) y Sohrabpour et al. (2021) en la importancia de las variables exógenas de exposición internacional como predictores dominantes (identificada en tres sectores distintos: logística marítima, siderurgia y exportaciones corporativas; en tres países distintos: Taiwán, Turquía e Irán; y en tres períodos temporales distintos) constituye uno de los hallazgos transversales más robustos del corpus: la regularidad emerge de forma independiente en estudios sin conexión entre sí, lo que le confiere una solidez empírica que ningún resultado de estudio único puede igualar.

Henna et al. (2025) abordan el forecasting B2B desde una perspectiva radicalmente diferente a la del resto de los estudios de la tercera generación: en lugar de modelizar la serie temporal de ventas de un producto o empresa, modelizan la estructura relacional del grafo de clientes B2B mediante redes de convolución espectral en grafos (GCN) y utilizan esa estructura como fuente de información predictiva adicional (Henna et al., 2025). La lógica conceptual conecta directamente con Zadeh et al. (2014): la estructura del grafo de relaciones entre clientes B2B (quién compra qué, con qué frecuencia, en qué secuencia temporal) contiene información predictiva que no está disponible en las series temporales individuales de cada cuenta, de forma análoga a cómo los cliques de medicamentos con correlaciones de ventas superiores a 0,65 contenían información transferible entre productos farmacéuticos. La diferencia es arquitectónica, no conceptual: Zadeh et al. (2014) usan redes neuronales híbridas sobre la estructura de cliques; Henna et al. (2025) usan GCN sobre el grafo completo de 448 instancias de interacciones cliente-empresa. La limitación más relevante del estudio de Henna et al. (2025) es precisamente ese tamaño del dataset: 448 instancias imponen restricciones severas sobre la robustez estadística de los resultados, haciendo que la comparación con los estudios de la segunda familia (que operan sobre decenas de miles de registros) deba realizarse con cautela extrema.

Huang et al. (2025) y Chen (2025) representan los extremos del espectro de innovación en la tercera familia. Chen (2025) aplica un algoritmo híbrido ImmunoSwarm (combinación de inteligencia inmunológica y de enjambre) para la predicción de ventas de ordenadores industriales taiwaneses en series de alta volatilidad, reportando mejoras sobre ANN estándar sin cifra exacta reproducible (Chen, 2025). Huang et al. (2025) incorporan datos de menciones en plataformas digitales chinas como variable exógena en la predicción de ventas B2B de vehículos durante la pandemia de COVID-19, documentando que esa señal de redes sociales mejora la predicción en períodos de alta volatilidad de demanda pero pierde poder predictivo en períodos de demanda estable (Huang et al., 2025). La conexión entre Huang et al. (2025) y Jovanovic et al. (2025) es metodológica: ambos demuestran que la efectividad del modelo depende del régimen de la serie (Huang et al. en el eje estabilidad/volatilidad pandémica y Jovanovic et al. en el eje de los modos de frecuencia de la señal). La conexión entre Huang et al. (2025) y Chen (2025) es contextual: ambos trabajan sobre series B2B con alta volatilidad estructural y ambos documentan que la arquitectura que aporta mayor mejora bajo esas condiciones es la que incorpora el mecanismo de diversidad más elaborado (integración de señal externa de redes sociales en Huang y hibridación de dos paradigmas de inteligencia computacional en Chen). Que los siete estudios de la tercera familia compartan la ausencia sistemática de validación en producción real (documentando rendimiento técnico sobre datos históricos sin evidencia de despliegue operacional) es el hallazgo organizativo más relevante de este grupo, y el que establece el contraste más nítido con Rezazadeh (2020), el único estudio de todo el corpus que documenta un despliegue real sobre 846 oportunidades durante tres meses de producción.

Los siete estudios de la tercera familia comparten una omisión que ninguno de ellos justifica explícitamente: ninguno reporta experiencias de despliegue en producción ni mide la adopción por parte de los equipos de ventas o logística de las empresas cuyos datos utiliza. Los modelos se validan sobre datos históricos; sus resultados se expresan en términos de MAPE, RMSE o MAE sobre conjuntos de prueba separados temporalmente; pero no hay evidencia documentada de que ninguno de esos modelos haya sido integrado en los sistemas operacionales de las organizaciones que proporcionaron los datos. Esa omisión puede reflejar barreras de acceso a las organizaciones, restricciones de confidencialidad o preferencias editoriales hacia los resultados técnicos, pero tiene consecuencias apreciables para la relevancia práctica de los hallazgos: un modelo con MAPE del 3% sobre el conjunto de prueba histórico que no llega a producción no aporta valor organizativo, con independencia de la sofisticación de su

arquitectura. La comparación entre la tercera familia y el único estudio de producción real del corpus (Rezazadeh, 2020) constituye la ilustración más nítida de la brecha entre la investigación académica en el campo y las necesidades de la práctica empresarial que la revisión identifica.

3.4 Diseño de la investigación con IA: datos, variables y protocolos

El análisis transversal de los veinte artículos desde la perspectiva del diseño empírico revela heterogeneidades que van más allá de las diferencias sectoriales y geográficas documentadas. Los estudios **difieren en el tamaño de sus datasets, en la granularidad temporal de las observaciones, en las fuentes de datos utilizadas, en los horizontes de predicción adoptados y en los protocolos de validación aplicados**. Esa heterogeneidad metodológica impide la síntesis cuantitativa directa de resultados: un meta-análisis numérico sobre este corpus sería metodológicamente indefendible, y obliga a la revisión a operar en el nivel de los patrones cualitativos y las regularidades transversales.

Sobre las fuentes de datos y estructuras de información

Las fuentes de datos del corpus pueden clasificarse en cinco categorías según su naturaleza y nivel de accesibilidad. La primera categoría agrupa los datos de transacciones internas (registros de pedidos, facturas, contratos y entregas procedentes de los sistemas ERP o CRM de la empresa analizada): domina el corpus, con dieciséis de los veinte artículos utilizando datos de transacciones internas como fuente primaria, lo que refleja tanto la disponibilidad de este tipo de datos en los sectores más digitalizados como la delimitación temática del campo. La segunda categoría comprende las variables macroeconómicas exógenas (tipo de cambio, precios de materias primas, índices de producción industrial, indicadores de actividad comercial exterior): Pekaya y Uysal (2024), Sohrabpour et al. (2021) y Wang et al. (2025) son los trabajos del corpus que utilizan de forma más explícita y detallada este tipo de variables, aunque Huang et al. (2025) también incorporan variables de contexto macroeconómico pandémico. Un ejemplo temprano de integración de variables exógenas en B2B es Lackman (2007), que combina datos internos (ventas y precios) con ratings de producto y variables macro (renta disponible y consumo de automóviles), y además proyecta los valores futuros de los predictores mediante Holt-Winters para poder ejecutar la simulación en horizonte plurianual. Esa proyección anticipada de los predictores mediante Holt-Winters es **metodológicamente infrecuente en el corpus**: la mayoría de los modelos multivariados asumen que los valores futuros de las variables exógenas son conocidos en el momento de la predicción, una condición que en la práctica empresarial raramente se cumple. Lackman (2007) resuelve esa inconsistencia operacional construyendo un sistema de dos capas (proyección de predictores primero, estimación de ventas después) que convierte el modelo en un instrumento de simulación de escenarios genuinamente accionable para la dirección comercial, y no solo en un ejercicio de ajuste estadístico ex post. La tercera categoría incluye datos de redes sociales y plataformas digitales, representados exclusivamente por Huang et al. (2025) con menciones en plataformas digitales chinas. La cuarta categoría comprende datos de actividad comercial del pipeline (etapas de oportunidad en CRM, probabilidades de cierre, valores y fechas de cierre previstas): Monat (2011), Rezazadeh (2020) y Rohaan et al. (2022) utilizan datos de esta categoría, que **son los más directamente relevantes para el forecasting en empresas con ciclos comerciales largos y pipeline explícitamente gestionado**. La quinta categoría, estructuralmente la más innovadora del corpus, incluye datos relacionales: grafos de correlación entre productos farmacéuticos (Zadeh et al., 2014) y grafos de relaciones entre clientes B2B (Henna et al., 2025).

Tabla 10 - Categorías de datos utilizados en el corpus

Categoría de datos	Definición	Nº	Rango de tamaño muestral	Observaciones metodológicas
<i>Transacciones internas</i>	Registros de pedidos, facturas, contratos y entregas procedentes de ERP/CRM	16	De centenares a decenas de miles de registros; series mensuales de 3–5 años	Dominan el corpus; permiten modelos más complejos cuando el tamaño es elevado; en muestras pequeñas amplifican el riesgo de sobreajuste
<i>Variables macroeconómicas exógenas</i>	Tipo de cambio, precios de materias primas, índices de producción industrial,	4	Agregados temporales mensuales o trimestrales sobre series de varios años	Mejoran la contextualización, pero su uso es marginal y rara vez se

Categoría de datos	Definición	N°	Rango de tamaño muestral	Observaciones metodológicas
	indicadores de comercio exterior			evalúa el valor incremental frente a modelos solo transaccionales
<i>Redes sociales y plataformas digitales</i>	Métricas de actividad en plataformas sociales o digitales	1	Miles de menciones/observaciones textuales o de interacción	Único caso; datos ruidosos y proxy imperfecto de la intención de compra B2B, lo que limita la generalización
<i>Actividad comercial de pipeline</i>	Etapas de oportunidad en CRM, probabilidades de cierre, valor y fecha estimada de cierre	3	De cientos a decenas de miles de oportunidades	Datos más directamente alineados con el forecasting B2B; infrautilizados pese a su relevancia estratégica en ciclos largos
<i>Datos relacionales (grafos)</i>	Grafos de correlación entre productos o relaciones entre clientes B2B	2	Centenares de nodos y aristas; 448 interacciones en el caso de Henna et al. (2025)	Arquitecturas novedosas con fuerte restricción de tamaño muestral; mejoras de precisión difíciles de comparar con estudios de gran escala

La **heterogeneidad en el tamaño de los datasets del corpus es notable y tiene consecuencias metodológicas** que la literatura raramente discute de forma explícita. Henna et al. (2025) operan con 448 instancias de interacciones cliente-empresa, un dataset cuyo tamaño impone restricciones severas sobre las arquitecturas entrenables sin sobreajuste. Rezazadeh (2020) y Rohaan et al. (2022) disponen de decenas de miles de registros de transacciones, lo que permite entrenar modelos de mayor complejidad con garantías estadísticas más sólidas. Los tres estudios taiwaneses de PCB operan con series temporales mensuales de entre tres y cinco años (Chang et al. (2007) con 60 observaciones mensuales (48 de entrenamiento, 12 de test), Hadavandi et al. (2011) y Chang et al. (2008) con períodos comparables), un tamaño que favorece los modelos de la primera familia y limita la ventaja de las arquitecturas profundas. Los estudios con muestras más pequeñas tienden a reportar mejoras de precisión de mayor magnitud, lo que es consistente con la hipótesis de sobreajuste: en muestras pequeñas, un modelo flexible puede ajustarse al ruido del conjunto de entrenamiento y obtener métricas artificialmente elevadas sobre un conjunto de prueba igualmente pequeño. Esa relación inversa entre tamaño muestral y magnitud de la mejora reportada es una regularidad empírica del corpus que afecta directamente a la interpretación de los resultados de la Tabla C: las mejoras del 90% de Zadeh et al. (2014) para el drug 24, o del 38,8% de Chang et al. (2007) para el MAPE de ventas de PCB, no son comparables sin ajuste por tamaño muestral con las mejoras del 12,3% de Bohanec et al. (2017) sobre un dataset de mayor dimensión.

Una reflexión de segundo orden sobre las fuentes de datos del corpus revela qué **categorías de información potencialmente relevante para el forecasting B2B están sistemáticamente ausentes**. Los datos de actividad del cliente en plataformas digitales B2B (registros de visitas a portales de autoservicio, descarga de catálogos técnicos, solicitudes de información previas a la compra) no aparecen en ningún estudio del corpus, con independencia del sector o del período temporal analizado. Los datos de licitaciones públicas y privadas que, en sectores como la construcción industrial, la ingeniería o la defensa, constituyen una señal predictiva de primer orden del volumen de ventas futuras están igualmente ausentes. Los datos de inteligencia competitiva (movimientos de precios, lanzamientos de productos, cambios en la fuerza de ventas de los competidores) no son utilizados como variables exógenas en ningún estudio. Las señales de intent data de marketing B2B (comportamiento de búsqueda y navegación en plataformas especializadas) están representadas de forma apenas tangencial por Huang et al. (2025) con datos de redes sociales chinas, que constituyen un proxy muy imperfecto de la intención de compra B2B en los sectores industriales de manufactura, logística o siderurgia que dominan el corpus. La ausencia de estas fuentes no refleja su irrelevancia para el problema de forecasting: refleja las barreras de acceso, privacidad y disponibilidad que impiden su uso en investigación académica, y señala un espacio de investigación aplicada con alto valor potencial que el corpus no ha podido explorar.

El **horizonte temporal de predicción es la variable moderadora del rendimiento de los modelos** que el corpus explora de forma más inconsistente. Los estudios cubren horizontes que van desde la predicción semanal de Wang et al. (2025) hasta la predicción mensual de la mayoría del corpus, pasando por horizontes trimestrales como los de

Zadeh et al. (2014). Los modelos simbólicos de la primera familia muestran rendimiento adecuado en horizontes cortos con series relativamente estables; los modelos de la tercera familia con mecanismos de atención resultan más competitivos en horizontes medianos donde los patrones de largo alcance son relevantes. Sin embargo, el corpus no permite determinar empíricamente la relación entre horizonte de predicción óptimo y arquitectura recomendada, porque cada estudio utiliza un horizonte diferente y ninguno compara de forma sistemática el rendimiento del mismo modelo en distintos horizontes. Esa ausencia de exploración explícita del efecto del horizonte de predicción sobre la selección de arquitectura es una de las limitaciones metodológicas más relevantes del corpus desde la perspectiva del diseño de sistemas de forecasting en la práctica empresarial B2B, donde los directores de ventas necesitan predicciones a distintos horizontes de forma simultánea (mensual para la planificación de producción, trimestral para la planificación de recursos comerciales, anual para el presupuesto).

Sobre las métricas de evaluación y protocolos de validación

La diversidad de métricas de evaluación en el corpus refleja **tanto la heterogeneidad de los problemas abordados como la ausencia de un estándar de reporting compartido**. Los estudios que abordan el forecasting de series temporales de volumen de ventas utilizan predominantemente MAPE, RMSE y MAE, con alguna presencia de R^2 . Los estudios que abordan problemas de clasificación (predicción de conversión de leads en Monat, 2011; clasificación de RFQs en Rohaan et al., 2022; predicción de probabilidad de compra en Rezazadeh, 2020; predicción de éxito de oportunidades en CRM en Bohanec et al., 2017) utilizan AUC-ROC, F1 score y accuracy. Esa diversidad de métricas impide la comparación directa de resultados entre estudios y es, en sí misma, un reflejo de la heterogeneidad conceptual del campo: lo que se entiende por forecasting de ventas B2B no es el mismo tipo de problema en todos los artículos del corpus (algunos son predicciones de series temporales agregadas, otros son clasificaciones de oportunidades individuales, otros son priorizaciones de trabajo comercial) aunque todos ellos usen esa etiqueta o equivalentes.

Tabla 11 - Métricas de evaluación utilizados en el corpus

Métrica de evaluación	Definición	Nº	Dimensión de evaluación	Observaciones metodológicas clave
<i>MAPE</i>	Error porcentual absoluto medio sobre la serie de ventas	16	Precisión en regresión temporal	Métrica dominante; simétrica, no penaliza de forma diferenciada sobre- y subestimación, lo que la desconecta del coste real del error en B2B
<i>RMSE / MAE</i>	Error cuadrático medio raíz y error absoluto medio del volumen previsto	16	Precisión en regresión temporal	Complementan al MAPE pero comparten su carácter simétrico; rara vez acompañadas de intervalos de confianza
<i>R²</i>	Proporción de varianza explicada por el modelo	16	Bondad de ajuste	Uso ocasional; informa del ajuste global pero no del error de predicción operativo
<i>AUC-ROC / F1 / accuracy</i>	Métricas de discriminación y acierto en problemas de clasificación	4	Clasificación de oportunidades/leads	Evidencian que el corpus agrupa problemas no equivalentes bajo la misma etiqueta de "forecasting de ventas B2B"
<i>Test de Wilcoxon</i>	Test no paramétrico de significancia entre modelos competidores	2	Significancia estadística	Único control de variabilidad muestral; su uso en solo 2 de 20 estudios revela un déficit estructural de verificación estadística
<i>Forecast Value Added (FVA)</i>	Valor añadido del modelo sobre el proceso de predicción vigente (Tashman, 2000)	2	Valor organizativo frente a baseline humano	Métrica relevante para la decisión de adopción; casi ausente, pese a medir la mejora real sobre el juicio experto
<i>Validación temporal</i>	Protocolos que preservan el orden cronológico train-test (Hyndman & Koehler, 2006)	3	Control de fuga temporal	Solo 3 de 20 estudios la garantizan; su ausencia infla resultados en series con tendencia o estacionalidad

<i>Funciones de pérdida asimétricas</i>	Penalización diferenciada del error al alza y a la baja	-	Asimetría del coste del error	Omisión generalizada; desconecta la evaluación académica del riesgo económico real en B2B
<i>Análisis coste-beneficio</i>	Umbral de rentabilidad que justifica implantar y mantener el sistema de IA	-	Viabilidad económica de adopción	Ausencia total; impide responder a la pregunta de "suficientemente bueno" que la práctica empresarial necesita

La **ausencia de tests de significancia estadística** en diecinueve de los veinte artículos del corpus representa un déficit metodológico cuyas consecuencias para la interpretación de los resultados son más relevantes de lo que la práctica editorial habitual reconoce. Una mejora de MAPE del 5% sobre un baseline puede o no ser estadísticamente significativa dependiendo del tamaño muestral y de la variabilidad de las series. Solo Lu y Kao (2016) aplican un test de Wilcoxon ($p < 0,05$ en la mayoría de comparaciones) para verificar que las diferencias entre el EN-ELM3 y los modelos competidores no son producto de la variabilidad muestral; esa misma práctica fue también aplicada por Lu y Wang (2012) en la comparación MARS versus ANN. El hecho de que ese procedimiento, estándar en la evaluación comparativa de modelos predictivos, sea adoptado únicamente por dos de los veinte artículos ilustra la presión del campo hacia el reporting de mejoras numéricas sin la verificación estadística de su significancia. Las revistas del campo aceptan sistemáticamente comparaciones de medias puntuales de MAPE sin intervalos de confianza ni tests de significancia, lo que facilita la publicación de estudios cuyos resultados positivos pueden ser producto de la variabilidad muestral y no de la superioridad genuina del modelo propuesto. Esa dinámica editorial no es neutral: produce una literatura donde la aparente acumulación de evidencia positiva puede ser, en parte, un artefacto estadístico del proceso de publicación.

El concepto de **Forecast Value Added (FVA)**, formalizado por Tashman (2000) como el valor que cada intervención o proceso añade sobre el baseline más simple de predicción, está prácticamente ausente del corpus. La mayor parte de los estudios evalúan si el modelo de IA mejora sobre baselines técnicos (ARIMA, regresión lineal, media móvil) pero no sobre el proceso de forecasting humano vigente en la organización. Solo Rezazadeh (2020) mide directamente el FVA organizativo: el ensemble de ML supera en 18-20 puntos porcentuales la precisión de las predicciones introducidas manualmente por los vendedores en el CRM (85% frente a 67% en test; 83% frente a 63% en producción). Wang et al. (2025) se aproximan al concepto al utilizar los KPIs operativos como medida del valor añadido de integrar variables externas sobre el baseline puramente estadístico. La importancia de esa distinción resulta decisiva para la práctica: un modelo que supera a ARIMA en un 15% puede ser inferior al juicio experto del director comercial con veinte años de experiencia en el sector, que incorpora información sobre la dinámica de cuentas, las negociaciones en curso y las señales de mercado que ningún dataset histórico captura. El FVA organizativo es la mejora real del sistema de IA sobre el proceso de predicción humana existente y la métrica pertinente para la decisión de adopción; ningún estudio del corpus la mide de forma sistemática, con la excepción parcial de Rezazadeh (2020), y esa omisión colectiva constituye uno de los déficits más urgentes de la literatura del campo, además de uno de los que con mayor facilidad podría corregirse con diseños de investigación que incluyan grupos de control humanos.

El **riesgo de fuga de información temporal (temporal data leakage)** es un problema metodológico específico del forecasting de series temporales que una proporción apreciable del corpus no aborda con suficiente rigor. Cuando se aplica k-fold cross-validation estándar sobre datos de series temporales, los folds de validación pueden incluir observaciones temporalmente posteriores a las del fold de entrenamiento, lo que equivale a entrenar el modelo con información futura y produce métricas de rendimiento artificialmente optimistas (Hyndman y Koehler, 2006). Solo dos estudios del corpus previenen explícitamente este problema: Sohrabpour et al. (2021) con validación cruzada temporal que preserva el orden cronológico, y Wang et al. (2025) con una división temporal limpia entre conjuntos de entrenamiento y prueba. El resto del corpus describe protocolos de validación con grados variables de explicitación, pero sin garantías verificables de que la división train-test preserve el orden temporal de las observaciones. Esa omisión puede inflar artificialmente los resultados reportados, especialmente en las series con tendencia o estacionalidad donde la fuga temporal introduce las señales más beneficiosas para el modelo (y es tanto más grave cuanto que las series de ventas B2B son, por su propia naturaleza, series con tendencia y estacionalidad en la mayoría de los contextos del corpus).

La asimetría del coste del error en contextos B2B añade una dimensión adicional de crítica a los protocolos de evaluación del corpus. En la gran mayoría de los entornos de venta interorganizacional, el coste de sobreestimar las ventas (producción en exceso, inventario inmovilizado, penalizaciones contractuales) no es igual al coste de subestimarlas (ventas perdidas, ruptura de stock, deterioro de la relación con el cliente) (Hyndman y Koehler, 2006). Esa asimetría es estructural en B2B: la pérdida de una cuenta de alto valor por incumplimiento de entrega puede tener consecuencias económicas que ninguna reducción de MAPE compensa, especialmente en sectores como recambios industriales de posventa (Rohaan et al., 2022) o distribución farmacéutica a hospitales (Zadeh et al., 2014) donde la ruptura de stock tiene implicaciones que van más allá del impacto económico inmediato. La literatura de forecasting reconoce desde hace tiempo la importancia de incorporar funciones de pérdida asimétricas en la evaluación y el entrenamiento de modelos de predicción, pero ninguno de los veinte estudios del corpus incorpora esas funciones ni en el entrenamiento de los modelos ni en la evaluación de sus resultados. Un modelo óptimo para el MAPE simétrico puede ser subóptimo (o incluso contraproducente) para el problema de negocio real si el coste de los errores al alza y a la baja es sustancialmente diferente. Esa omisión generalizada no es una limitación menor: es una desconexión estructural entre los criterios de evaluación que la academia utiliza y los criterios que la práctica empresarial necesita para tomar decisiones de adopción.

La pregunta de suficientemente bueno (si la mejora de precisión reportada es suficientemente grande para justificar el coste organizativo de implantar y mantener un sistema de IA) **no tiene respuesta en ninguno de los veinte artículos.** Pasar de MAPE 6% a MAPE 2% en ventas de PCB taiwanesas es técnicamente una mejora sustancial, pero ese valor debe compararse con el coste de desarrollo, implantación, mantenimiento y reentrenamiento periódico del sistema KGFS, con el coste de formación de los usuarios, con el coste de la gobernanza de datos necesaria para alimentar el modelo de forma continua, y con el coste de las estructuras organizativas que la adopción del sistema requiere modificar. Ningún estudio del corpus calcula ese umbral de rentabilidad, que es la información que un directivo financiero necesita para aprobar la inversión en un sistema de forecasting con IA. La ausencia de ese cálculo es la expresión más visible de la brecha entre la investigación académica en el campo y las necesidades de la práctica empresarial en manufactura, distribución, siderurgia, logística o cualquier otro de los sectores B2B representados en el corpus.

3.5 Resultados: magnitud y condiciones para la mejora del forecast

Los veinte artículos del corpus comparten un rasgo que ningún caso contradice: **todos reportan resultados favorables al modelo de IA propuesto frente a los baselines de referencia.** Esa unanimidad engaña si se toma al pie de la letra. Responde al sesgo de publicación documentado en la Sección 3.9 y a la selección, implícita o explícita, de las condiciones de comparación que mejor convienen al modelo defendido. Lo informativo no reside, por tanto, en el signo del resultado, que es siempre positivo, sino en su gradación. La magnitud de las mejoras y las condiciones bajo las cuales se sostienen varían entre estudios, y es esa variación, no la victoria del modelo, la que aporta evidencia genuina sobre cuándo y cómo la inteligencia artificial añade valor al forecasting B2B.

Del análisis comparativo del corpus emergen tres regularidades empíricas transversales que ningún estudio enuncia de forma explícita. La primera atañe a la relación inversa entre tamaño muestral y magnitud de la mejora reportada: los estudios con datos reducidos (Zadeh et al., 2014, con 36 meses para 217 medicamentos; los trabajos PCB taiwaneses de Chang et al., 2007, y Hadavandi et al., 2011, con 60 observaciones mensuales) registran reducciones de error de gran amplitud relativa, mientras que los operados sobre datasets de mayor dimensión (Rohaan et al., 2022; Rezazadeh, 2020) producen mejoras más contenidas pero estadísticamente más sólidas. La evidencia apunta a que esa asimetría no refleja superioridad algorítmica, sino el efecto del sobreajuste sobre muestras pequeñas. La segunda regularidad invierte la intuición arquitectónica dominante: la incorporación de variables exógenas macroeconómicas pertinentes genera ventajas predictivas mayores que la adopción de arquitecturas más complejas sobre datos internos exclusivamente (Pekkaya y Uysal, 2024; Sohrabpour et al., 2021; Wang et al., 2025). Tres sectores, tres países, tres períodos distintos. La convergencia es difícil de atribuir al azar. La tercera es la más contraintuitiva: la ventaja de la tercera familia sobre la segunda, aunque consistente, resulta inferior a lo que la diferencia de complejidad haría prever, pues las mejoras proporcionales de Zhang et al. (2023) sobre sus baselines

son de menor magnitud que las del KGFS de Hadavandi et al. (2011) sobre WEFuNN, operando ambos sobre el mismo tipo de problema con datasets comparables.

La conexión de esas tres regularidades con la dimensión D1 del marco de análisis (mejora de la precisión predictiva mediante IA) exige una lectura que rebase el registro numérico de las mejoras. D1 no interroga si los modelos mejoran la precisión, cuestión que el corpus entero responde afirmativamente, sino bajo qué condiciones esa mejora es sustancial, estable y transferible a otros contextos B2B. La respuesta es condicional en tres sentidos. La mejora es mayor cuando el tamaño muestral es reducido, pero esa magnitud superior resulta sospechosa: las series de entre 36 y 60 observaciones (Chang et al., 2007; Zadeh et al., 2014) reportan reducciones de MAPE del 28% al 97%, frente a los 12 a 20 puntos porcentuales, más robustos y más modestos, de los estudios con decenas de miles de registros (Rezazadeh, 2020; Rohaan et al., 2022). La mejora es también mayor cuando se incorporan variables exógenas pertinentes que cuando se aumenta la complejidad arquitectónica sobre los mismos datos internos, lo que sitúa la calidad de la señal de entrada por encima de la capacidad representacional del modelo. Y donde se mide frente al proceso humano vigente, y no frente a un baseline estadístico, surgen las ganancias más relevantes para la adopción empresarial: los 18-20 puntos de Rezazadeh (2020) sobre las predicciones manuales de los vendedores, o el factor 2,5 de Rohaan et al. (2022) sobre la evaluación manual de RFQs, se traducen con facilidad al lenguaje del retorno sobre la inversión que un directivo financiero requiere para aprobar la implantación. El patrón es nítido: D1 queda respondida en sentido afirmativo, pero la magnitud y la robustez de esa respuesta dependen del tamaño muestral, de la riqueza de las variables de entrada y del baseline elegido, tres moderadoras cuya interacción el corpus no modela y que constituyen el núcleo del déficit empírico que cualquier diseño orientado a D1 debería resolver. Los resultados no son comparables entre estudios sin ajuste por tamaño muestral: las mejoras de mayor magnitud en datasets de ≤ 60 observaciones son metodológicamente sospechosas, según se detalla en el apartado 3.4 a continuación.

La magnitud de la mejora reportada guarda relación inversa con el tamaño muestral, lo que **obliga a leer las cifras como indicadores condicionados y no como un ranking de rendimiento absoluto**, dado que cada caso requiere un análisis pormenorizado. La ausencia generalizada de contrastes de significancia estadística en el corpus implica que las diferencias de rendimiento reportadas, aun siendo consistentes en dirección, no pueden interpretarse como diferencias estadísticamente verificadas, salvo en los dos estudios que aplican el test de Wilcoxon.

Tabla 12 - Resultados comparativos de precisión: modelo propuesto frente a baseline en cada estudio del corpus

Estudio	Modelo IA	Modelo baseline	Métrica	Resultado IA	Resultado baseline	Mejora relativa
<i>Chang et al. (2007)</i>	WEFuNN	Back-propagation ANN	MAPE	2,11%	3,45% (GANN: 3,06%; BPN: 8,76%)	38,8% sobre GANN
<i>Lackman (2007)</i>	Simulación dinámica demanda-oferta (3P + Holt-Winters)	Benchmark de literatura B2B (≈30%, Jain)	MAPE	8,5%	≈30%	≈71,7% sobre el benchmark de referencia
<i>Chang et al. (2008)</i>	FCBR	Fuzzy estándar	MAPE	2,30%	3,10%	25,8%
<i>Monat (2011)</i>	ANN-logit	Juicio experto vendedores	AUC	0,78	0,61	+27,9% sobre juicio humano
<i>Hadavandi et al. (2011)</i>	KGFS	WEFuNN	MAPE	1,52%	2,11%	28,0%
<i>Zadeh et al. (2014)</i>	Hybrid ANN + cliques	ARIMA / ANN sin cliques	MAE	10,51	369,84 (ARIMA); 90,57 (ANN sin cliques)	~97,2% sobre ARIMA (drug 24)
<i>Lu y Wang (2012)</i>	MARS	ANN / SVR	MAPE	0,11% (Empresa A, ratio 80/20)	SVR: 0,32%; BPN: 0,41%	Verificada (Wilcoxon p<0,01)
<i>Lu y Kao (2016)</i>	EN-ELM3	WL-ELM3 / ELM simple	MAPE	2,09% (A); 2,22% (B)	2,93% (A); 3,31% (B)	Verificada (Wilcoxon p<0,05)
<i>Bohanec et al. (2017)</i>	RF + EXPLAINIME	Regresión logística (NB)	AUC / CA	AUC: 0,85; CA: 0,782	NB: AUC 0,83; CA 0,777	12,3% en AUC sobre baseline principal
<i>Rezazadeh (2020)</i>	Ensemble GB+RF+LR	Juicio vendedor CRM	Accuracy	85% (test); 83% (producción)	67% (test); 63% (producción)	+18 pp (test); +20 pp (producción)
<i>Wisesa et al. (2020)</i>	C4.5	Naïve Bayes / media histórica	Accuracy	No comparable (varía por trimestre)	No reportado	C4.5 supera NB en Q1–Q3; no comparable en Q4 por estacionalidad
<i>Sohrabpour et al. (2021)</i>	Random Forest	ARIMA	MAPE	Mejora entre 15% y 35% según producto	No reportado	Condiciona al tipo de producto

Estudio	Modelo IA	Modelo baseline	Métrica	Resultado IA	Resultado baseline	Mejora relativa
<i>Rohaani et al. (2022)</i>	Gradient Boosting + NLP	Regla heurística manual	F1	F1=56,24% (test, umbral 0,62)	F1≈19% (tasa conversión histórica manual)	×2,5 sobre proceso manual (+155,3%)
<i>Pekkaya y Uysal (2024)</i>	RF + GBDT	Regresión lineal múltiple	R ²	0,85	0,65	+30,8%
<i>Zhang y Kim (2023)</i>	Hybrid Attn-TimeSeries (HATT-MSCNN-IBiLSTM)	BiLSTM / CNN	RMSE; MAE	ESDA: RMSE=37,6; MAE=23,5 / ESDB: RMSE=31,6; MAE=20,2 / ESDC: RMSE=25,7; MAE=17,3	BiLSTM (mejor rival): ESDA RMSE=44,5; MAE=31,7	Reducción RMSE 15,5%–30,2% sobre BiLSTM según dataset
<i>Henna et al. (2025)</i>	GCN espectral (GCN-1, shortest-path)	RF / XGBoost / CATboost / CNN / FNN	Accuracy; F1; AUC	Accuracy=1,00; F1=0,963 (área P-R); AUC=0,929	RF: AUC=0,867 / XGBoost: AUC=0,822 / CATboost: AUC=0,83 / CNN: AUC=0,81	GCN-1 supera RF (+6,2 pp AUC), XGBoost (+10,7 pp AUC); zero FP vs. 0,14–0,23 del resto
<i>Jovanovic et al. (2025)</i>	VMD+RNN+HAEDHO	LSTM estándar / RNN sin VMD	R ² ; RMSE	R ² =0,647 (con VMD+HAEDHO)	R ² =0,083 (sin VMD; baseline RNN sin descomposición)	+681% en R ² (de 0,083 a 0,647) gracias a VMD; Wilcoxon p<0,05 vs. otros optimizadores
<i>Wang et al. (2025)</i>	KPI-Demand: LGB+XGB+MA RS→DNN/RNN/GRU stacking	ARIMA / modelos unietapa	MAPE; RMSE; MAE	Stacking supera a todos los modelos individuales	ARIMA y modelos estadísticos clásicos (Tsioumas 2017; Michail 2020)	Superior en todos los segmentos; sin cifra agregada única publicada
<i>Chen (2025)</i>	ImmunoSwarm (AIS+PSO sobre RBF)	ANN estándar	MAPE; MAE; RMSE	MAPE=5,02%; MAE=339,06; RMSE=415,48	ARMA(2,1): MAPE=6,94%; MAE=475,80; RMSE=569,81 / RNNet: MAPE=11,95%; RMSE=878,65 / AIS-PSO: MAPE=5,66%	–27,7% en MAPE sobre ARMA(2,1); –58,0% en MAPE sobre RNNet estándar; menor error en las tres métricas
<i>Huang et al. (2025)</i>	SocialML	ARIMA	MAPE	Mejora en pandemia; sin mejora en demanda estable	No reportado	Condiciona al periodo/volatilidad

Sobre el impacto operativo y la traducción de la mejora en decisiones

La distancia entre la mejora técnica documentada en los artículos del corpus y el impacto operativo en la organización que adopta el modelo es el espacio analítico que la literatura de forecasting B2B con IA ha explorado de forma más insuficiente. Reducir el MAPE de un modelo de predicción de recambios industriales del 12% al 8% no es, en sí mismo, un resultado organizativo, sino una **condición necesaria pero no suficiente para que ese modelo aporte valor a la empresa**. El valor organizativo requiere que esa mejora de precisión se traduzca en decisiones mejores (pedidos de reposición más ajustados, asignación más eficiente de la fuerza de ventas o planificación de producción con menor inventario de seguridad), y esa traducción depende de la integración del modelo en los procesos de decisión, de la confianza de los usuarios en sus salidas y de la capacidad organizativa para actuar sobre las predicciones. En términos de magnitud, los trabajos basados en simulación y estimación causal también reportan mejoras relevantes cuando el modelo incorpora palancas de marketing y contexto macroeconómico. Lackman (2007) obtiene un MAPE medio del 8,5% en la predicción trimestral de ventas de componentes B2B durante un horizonte de tres años, y lo contrasta con el error medio ($\approx 30\%$) documentado como referencia en forecasting B2B en muestras amplias. Más allá del valor numérico, la condición de posibilidad de esa mejora es la inclusión explícita de variables accionables (venta directa, promoción, precio) y de determinantes de demanda del sector, en lugar de depender únicamente de rezagos de la propia serie.

Los dieciséis artículos del corpus que documentan la mejora técnica sin describir el mecanismo organizativo por el cual esa mejora se traduce en decisiones operativas mejores no son estudios incompletos por negligencia de sus autores, sino estudios que reflejan fielmente las prioridades de evaluación de los campos editoriales donde se publican, los cuales valoran la novedad técnica y la mejora de métricas estándar y carecen de mecanismos de evaluación para las contribuciones sobre impacto organizativo.

La lectura del corpus bajo el prisma de la madurez organizativa en el uso de analítica predictiva produce una tipología de tres estadios. El primer estadio, representado por Monat (2011), describe **organizaciones que utilizan el juicio subjetivo de los vendedores** como proceso de forecasting primario: la introducción del modelo de IA supone la transición desde la opinión a la evidencia, y el baseline relevante es el juicio humano. El segundo estadio, representado por Rezazadeh (2020) y Sohrabpour et al. (2021), describe organizaciones con **infraestructura de datos moderadamente avanzada**, donde el forecasting estadístico básico ya existe y el modelo de IA supone una mejora incremental sobre ese proceso ya formalizado. El tercer estadio, representado por Rohaan et al. (2022), describe organizaciones con **datos ricos pero con problemas de gobernanza** que impiden explotar plenamente la capacidad del modelo: el cuello de botella no es la precisión del algoritmo sino la calidad de los datos que lo alimentan, y ese cuello de botella no es técnicamente resoluble sin intervenciones organizativas previas. Esa tipología resulta útil para interpretar por qué estudios con mejoras técnicas similares producen impactos operativos tan distintos, dado que la etapa de madurez de la organización determina cuál es el factor limitante real: la calidad del algoritmo en el segundo estadio, la confianza del usuario en el primero, o la gobernanza de los datos en el tercero.

La dimensión D4 del marco conceptual, relativa a la gestión del cambio organizativo, está **prácticamente ausente en los veinte artículos del corpus**. Ningún estudio documenta cómo reaccionaron los equipos de ventas ante la introducción del modelo, si los directivos comerciales modificaron sus rutinas de planificación en respuesta a las predicciones del sistema, si surgieron resistencias o conflictos en torno a la redistribución del poder informativo que la adopción del modelo conlleva (esto es, la pérdida del monopolio sobre la información de ventas que el vendedor ejercía mediante su juicio subjetivo), ni si la organización desarrolló capacidades internas para mantener y actualizar el modelo a lo largo del tiempo. Esa ausencia no es evidencia de que el cambio organizativo sea fácil o irrelevante en la adopción de IA para el forecasting B2B, sino evidencia de que **la investigación académica en el campo no ha desarrollado metodologías adecuadas para estudiar ese proceso**, el cual requiere diseños longitudinales mixtos costosos de implementar y difíciles de publicar en revistas con sesgo hacia resultados técnicos. La distinción entre el modelo produce mejores predicciones y la organización toma mejores decisiones gracias al modelo es la brecha analítica más relevante que el corpus deja abierta.

La ausencia de marcos de evaluación del coste-beneficio organizativo es la dimensión más invisible del corpus. **Ningún estudio calcula el ROI de implantar un sistema de IA para forecasting B2B** (coste de desarrollo e implantación, coste de mantenimiento y reentrenamiento, y coste de la gobernanza de datos necesaria) frente al beneficio de la mejora de precisión. Los estudios más cercanos a resolver esa brecha (Rohaán et al., 2022; Rezazadeh, 2020; Wang et al., 2025) documentan el contexto organizativo de implantación con suficiente detalle como para que una estimación parcial de costes sea factible, pero ninguno proporciona un análisis de coste-beneficio completo que un directivo pueda usar como referencia para la decisión de inversión. Esa ausencia es tanto más llamativa cuanto que los sectores representados en el corpus (manufactura de PCB, distribución de recambios industriales, siderurgia o logística marítima) son sectores donde la estimación de costes de proyecto es una competencia organizativa consolidada, lo que sugiere que la barrera no es de capacidad sino de diseño de investigación: los estudios académicos del campo no están diseñados para producir estimaciones de ROI, y las empresas que disponen de esas estimaciones no tienen incentivos para publicarlas.

3.6 Factores organizacionales, sociotécnicos y barreras

La distancia entre el rendimiento técnico documentado en la literatura y la adopción efectiva en las organizaciones es el espacio donde operan los factores organizacionales, sociotécnicos y las barreras de implantación que el corpus aborda de forma fragmentada pero convergente. Cuatro estudios del corpus (Bohanec et al., 2017; Rohaan et al., 2022; Rezazadeh, 2020; Monat, 2011) aportan la **evidencia más directa y sistemática sobre estas barreras**. Los demás la abordan de forma tangencial en sus secciones de limitaciones o trabajo futuro, lo que indica que la jerarquía tácita del campo sitúa los resultados técnicos en el cuerpo del artículo y las barreras organizativas en el último párrafo de las conclusiones, una distribución que refleja los sesgos del proceso de publicación tanto como los del fenómeno investigado.




Figura 8 - Jerarquización de las principales barreras identificadas en el corpus (elaboración propia)

La barrera más documentada en el corpus es la **calidad de los datos**. Rohaan et al. (2022) dedican una sección metodológica específica a describir los problemas de calidad de datos en el sistema de información del proveedor de recambios industriales neerlandés: duplicados de identificadores de empresa, inconsistencias en los códigos de producto, registros de RFQs con campos obligatorios vacíos, y discrepancias entre los datos del CRM y los del ERP que impiden construir una visión unificada del historial de compras de cada cuenta. Rezazadeh (2020) describe un

problema análogo en el contexto canadiense: el pipeline de datos de Azure ML requirió una fase de limpieza y normalización que consumió una proporción sustancial del tiempo total del proyecto, y cuya calidad determinó en gran medida la precisión final del modelo. Monat (2011) señala que la principal limitación del modelo de conversión de leads en el entorno industrial estadounidense fue la heterogeneidad de los criterios con los que los vendedores clasificaban las oportunidades en el CRM, lo que introducía sesgo sistemático en los datos de entrenamiento. La convergencia de estos tres trabajos, procedentes de tres países distintos, tres sectores B2B distintos (distribución de recambios, pipeline comercial y generación de leads industriales) y tres períodos temporales distintos, sobre la misma barrera primaria es el hallazgo transversal más sólido del corpus sobre barreras de implantación: la calidad de los datos del CRM es el factor limitante más universal y más subestimado en la adopción de IA para el forecasting B2B, con independencia del sector y del nivel de sofisticación tecnológica de la organización.

La **confianza del usuario** en el modelo es otra barrera de relevancia documentada en el corpus. Bohanec et al. (2017) formulan este argumento de la forma más directa: el modelo de RF para predicciones de ventas en el contexto B2B esloveno fue rechazado inicialmente por los directivos comerciales precisamente porque era una caja negra, dado que estos no podían explicar a sus superiores ni a sus clientes por qué el modelo predecía un determinado volumen de ventas para un cliente específico, lo que les impedía usarlo como base de decisiones que debían ser justificadas. La solución propuesta, el sistema de explicación post-hoc EXPLAIN + IME, fue diseñada específicamente para reducir esa barrera de confianza, no para mejorar la precisión técnica del modelo (Bohanec et al., 2017). Ese punto es metodológicamente relevante: son el único equipo del corpus que ha comprendido que el problema central del forecasting B2B con IA no es exclusivamente técnico sino también organizativo, y que ha construido su investigación en respuesta a esa comprensión. La **infraestructura tecnológica** también actúa como barrera significativa. En contextos de economías emergentes, como Indonesia (Wisera et al., 2020), o sectores industriales con menor nivel de digitalización, como la siderurgia turca (Pekkaya y Uysal, 2024), la disponibilidad de infraestructura de almacenamiento, procesamiento y acceso a datos es una limitación previa a cualquier discusión sobre la elección del algoritmo de forecasting. Menos explicitada en el corpus, aunque identificable a través de las secciones de limitaciones, es la **obsolescencia del modelo**: los modelos requieren reentrenamiento periódico ante distribuciones cambiantes de los datos de ventas, y ningún estudio documenta un protocolo explícito de reentrenamiento ni cuantifica el coste de ese proceso, lo que indica que los artículos describen los modelos como entidades estáticas en lugar de como sistemas que requieren mantenimiento continuo.

Sobre el data governance, la explicabilidad y la confianza algorítmica

La explicabilidad de los modelos de IA en el forecasting B2B es el **nexo entre la dimensión técnica y la dimensión organizativa del problema**. Bohanec et al. (2017) son los únicos autores del corpus que han construido su investigación desde esa intersección. La diferencia técnica entre los métodos EXPLAIN + IME y SHAP, el método de explicación post-hoc más utilizado en la literatura reciente, merece ser analizada con precisión, porque tiene consecuencias prácticas sobre la confianza del usuario final que ningún artículo del corpus señala explícitamente (Adadi y Berrada, 2018). SHAP, fundamentado en la teoría de juegos cooperativa, garantiza dos propiedades formales: consistencia (si un modelo depende más de una variable, su valor SHAP no disminuye cuando el modelo mejora) y monotonicidad (los valores SHAP tienen una interpretación aditiva rigurosa que permite sumarlos para reconstruir la predicción del modelo). EXPLAIN + IME no ofrece esas garantías matemáticas: sus explicaciones pueden variar inconsistentemente ante modificaciones menores de los inputs, lo que puede erosionar la confianza del usuario cuando el modelo cambia de recomendación en situaciones aparentemente similares sin que el directivo pueda identificar la variable responsable del cambio. Esa inconsistencia, que puede parecer un problema técnico menor, tiene consecuencias organizativas graves: un directivo comercial de una empresa siderúrgica (Pekkaya y Uysal, 2024) o de una distribuidora de recambios industriales (Rohaani et al., 2022) que experimente explicaciones incoherentes del mismo modelo en situaciones análogas tenderá a ignorar las predicciones del sistema y a recurrir a su juicio personal, anulando el valor organizativo de la inversión con independencia de la calidad técnica del algoritmo subyacente.

La paradoja más relevante que el análisis transversal del corpus produce en relación con la explicabilidad es temporal: **la trayectoria del campo en términos de interpretabilidad no es de mejora progresiva sino de**

regresión. La primera familia (2007-2014) ofrecía interpretabilidad estructural intrínseca en sectores que van desde la manufactura de PCB hasta la distribución farmacéutica: las reglas fuzzy generadas evolutivamente (Chang et al., 2007; Hadavandi et al., 2011) y los casos recuperados por similitud (Chang et al., 2008) son el modelo, no una aproximación al modelo. La segunda familia (2011-2022) produjo un único estudio de XAI aplicado a ventas B2B, el de Bohanec et al. (2017), que introdujo explicabilidad extrínseca sobre un modelo opaco en el sector de ventas B2B esloveno. La tercera familia (2023-2025) no produce ningún mecanismo de explicabilidad: Zhang et al. (2023), Jovanovic et al. (2025), Chen (2025), Huang et al. (2025), Wang et al. (2025) y Henna et al. (2025) alcanzan la mayor precisión técnica del corpus en sus respectivos sectores (ventas empresariales chinas, logística marítima, automoción B2B y CRM B2B), pero no incorporan mecanismo alguno de explicación de sus predicciones. La generación más reciente de modelos ha retornado, así, a la opacidad algorítmica que Bohanec et al. (2017) identificaron como barrera de adopción: el avance técnico en precisión y el avance organizativo en adoptabilidad se están moviendo en direcciones opuestas, y esa divergencia constituye una de las tensiones más urgentes que la agenda de investigación futura del campo debe resolver.

La gobernanza de datos en el contexto del forecasting B2B con IA no es un problema técnico sino un **problema de diseño institucional** que se manifiesta en el corpus de tres formas convergentes: la discrepancia entre identificadores en sistemas dispares (Rohaani et al., 2022), la inconsistencia en la codificación de variables cualitativas por parte de los usuarios del CRM (Monat, 2011; Rezazadeh, 2020), y la ausencia de procesos formalizados de validación y actualización de los datos históricos que alimentan los modelos (Wisese et al., 2020). Los problemas que Rohaan et al. (2022) documentan (discrepancias entre el CRM y el sistema de RFQs diseñados con propósitos distintos, por equipos distintos y en momentos distintos) no son errores corregibles mediante un proceso técnico de deduplicación más sofisticado: son el resultado de décadas de acumulación de datos en sistemas que no fueron diseñados para interoperar, y cuya integración requiere decisiones de gobernanza sobre quién es responsable de la calidad de los datos de cada categoría, inversión en infraestructura de master data management que garantice la coherencia entre sistemas, y cambio cultural en los equipos de ventas para que los datos introducidos en el CRM alcancen el nivel de rigor necesario para ser útiles como inputs del modelo. Ninguno de esos tres requisitos es técnico, y ninguno puede ser resuelto por un algoritmo más sofisticado, sea el Gradient Boosting de Rohaan et al. (2022) o el GCN de Henna et al. (2025). La gobernanza de datos es, así, una aplicación específica del **problema general de transformación organizativa que la adopción de IA conlleva**: la secuencia necesaria (decisión institucional sobre responsabilidades, inversión en infraestructura y proceso de control continuo) es exactamente la que la literatura sobre gestión del cambio organizativo (dimensión D4 prácticamente ausente del corpus) describe para la adopción sostenible de tecnología en organizaciones complejas.

La **fragmentación geográfica** del corpus como obstáculo para la generalización de los resultados sobre gobernanza de datos y explicabilidad merece una reflexión específica que el corpus no aborda de forma explícita. Los siete estudios taiwaneses y los tres estudios chinos operan en culturas organizativas donde la centralización del control de datos, la jerarquía en la toma de decisiones y la disponibilidad de personal técnico formado en ingeniería presentan patrones distintos a los que caracterizan los contextos europeos y norteamericanos. Un modelo de gobernanza de datos que funciona en una empresa manufacturera taiwanesa de PCB (Chang et al., 2007) con alta centralización puede no ser transferible a una empresa de recambios industriales neerlandesa con estructura organizativa más horizontal (Rohaani et al., 2022). Un mecanismo de explicabilidad que genera confianza en directivos comerciales eslovenos (Bohanec et al., 2017) puede no generar el mismo nivel de confianza en directivos comerciales indonesios (Wisese et al., 2020) si las estructuras de autoridad y los procesos de justificación de decisiones son culturalmente distintos. La ausencia de estudios de transferibilidad explícita entre contextos (ningún artículo del corpus replica el diseño de otro en un país o sector diferente) impide determinar cuánto del conocimiento sobre barreras de implantación es específico de contexto y cuánto es genuinamente general, y esa indeterminación es una de las limitaciones transversales más relevantes para cualquier investigación que pretenda establecer recomendaciones de diseño aplicables a organizaciones B2B en múltiples contextos geográficos.

La lectura cruzada de los cuatro estudios con evidencia sustantiva sobre barreras (Monat, 2011; Rezazadeh, 2020; Rohaan et al., 2022; Bohanec et al., 2017) revela una jerarquía implícita que ninguno formula de forma explícita pero que emerge del análisis comparativo. Las barreras no son equivalentes ni independientes; operan en secuencia.

La gobernanza de datos es la barrera de primer orden: sin datos limpios, estructurados y coherentes entre sistemas, cualquier decisión sobre el algoritmo es prematura. Rohaan et al. (2022) y Rezazadeh (2020) lo documentan con la mayor claridad del corpus (la fase de preparación de datos consumió entre el 40% y el 60% del tiempo total del proyecto en ambos casos, y su resolución fue condición necesaria para que el modelo operara en producción). La confianza del usuario es la barrera de segundo orden: solo se activa una vez que el dato es suficientemente fiable para generar predicciones estables, pero entonces emerge como obstáculo autónomo. Bohanec et al. (2017) son el único equipo del corpus que ha comprendido que este segundo umbral requiere intervención específica (un mecanismo de explicabilidad diseñado no para mejorar la precisión sino para hacer la predicción inteligible ante la dirección comercial). La transformación organizativa es la barrera de tercer orden: no aparece nombrada como objeto de investigación en ninguno de los veinte artículos, lo que indica que el campo ha estudiado las dos primeras barreras de forma fragmentada y ha ignorado casi por completo la tercera. Monat (2011) se aproxima más que ningún otro estudio al tercer nivel al documentar que el sesgo en la codificación de oportunidades por parte de los vendedores (una barrera de comportamiento organizativo, no de infraestructura) degrada el modelo antes de que este pudiera ser entrenado, pero no teoriza ese hallazgo como un problema de gestión del cambio. La consecuencia práctica de esa jerarquía es que ninguna organización puede saltarse los niveles: invertir en un modelo de deep learning sin resolver primero la gobernanza de datos es el error más frecuente que la literatura documenta de forma implícita pero nunca nombra de forma directa.

El **sesgo de publicación** en el corpus hacia los resultados positivos introduce una distorsión adicional en la lectura de las barreras de implantación. Si los estudios donde el modelo de IA no supera al baseline, o donde la implantación fracasa por barreras organizativas insuperables, no se publican porque las revistas prefieren resultados positivos, la evidencia acumulada sobreestima de forma sistemática la facilidad de adopción y la eficacia de los modelos de IA en contextos B2B reales. La estimación bayesiana cualitativa de ese sesgo sugiere que la literatura disponible representa los mejores casos (las empresas más maduras digitalmente, los contextos más favorables a la adopción y los datasets de mayor calidad), una selección no aleatoria que representa el límite superior del valor que la IA puede aportar al forecasting B2B en condiciones favorables, y no una descripción del valor esperable en condiciones medias. Una empresa de manufactura industrial, distribución de recambios o siderurgia que adopte un sistema de IA para forecasting B2B basándose exclusivamente en la literatura del corpus puede obtener resultados inferiores a los esperados, no porque el modelo sea inadecuado sino porque la literatura consultada estaba sesgada hacia los casos de éxito y no documenta las condiciones organizativas que los hicieron posibles.

3.7 Síntesis crítica: limitaciones y vacíos en la investigación

La lectura transversal de los veinte artículos del corpus, conducida a través de las cuatro dimensiones del marco analítico, produce un mapa de limitaciones que no es la suma de las limitaciones individuales de cada estudio, sino un **patrón de ausencias estructurales que define los límites del conocimiento actual sobre IA aplicada al forecasting B2B** en sectores tan diversos como la manufactura de circuitos impresos, la distribución de recambios industriales, la siderurgia, las exportaciones corporativas, la distribución farmacéutica, las telecomunicaciones B2B, la logística marítima, la automoción B2B, el CRM B2B y el comercio mayorista. Ese patrón tiene tres características que lo distinguen de una mera colección de debilidades metodológicas individuales: es transversal, pues atraviesa el corpus con independencia del sector, el período temporal o la sofisticación metodológica del estudio; es acumulativo, dado que no mejora con el tiempo sino que en algunas dimensiones se agrava conforme las arquitecturas se vuelven más sofisticadas; y es sistémico, en tanto refleja los incentivos del proceso de publicación académica tanto como las dificultades reales del objeto de estudio.

La primera limitación sistémica del corpus es la **ausencia de benchmarking compartido**. No existe ningún dataset público de forecasting de ventas B2B que permite la comparación directa de los resultados de los veinte artículos entre sí. Cada estudio define su propio problema, utiliza sus propios datos, adopta sus propias métricas y establece su propio baseline de comparación. La consecuencia es que el campo ha acumulado veinte estudios de caso técnicos de alta calidad individual pero baja comparabilidad colectiva, una condición que impide la síntesis cuantitativa y que ha llevado a que la comparación entre estudios del corpus sólo pueda realizarse de forma cualitativa, con todas las limitaciones que ese nivel de análisis conlleva. El único estudio que avanza hacia un dataset semi-público es

Jovanovic et al. (2025), con el dataset de Amazon for Business, que, aunque es un proxy imperfecto del contexto B2B en sentido estricto, al menos es un dataset replicable que permite la comparación entre ese trabajo y estudios futuros. Los estudios del corpus que emplean datos corporativos privados han contribuido al campo sin hacer replicable su contribución, lo que constituye una limitación estructural que ningún avance metodológico puede compensar a posteriori.

La segunda limitación es la **validación exclusivamente histórica**: solo Rezazadeh (2020) documenta rendimiento en producción real durante un período de tres meses con 846 oportunidades reales. Los diecinueve restantes validan sobre datos históricos y entregan sus conclusiones sin verificación del rendimiento en contextos organizativos vivos, donde las distribuciones de los datos cambian, los mercados se transforman y los usuarios del sistema introducen dinámicas de retroalimentación que ningún dataset histórico captura.

La tercera limitación sistémica es la **concentración en D1 con abandono de D2, D3 y D4**. El corpus ha producido evidencia robusta de que los modelos de IA mejoran la precisión del forecasting sobre baselines estadísticas en contextos B2B de manufactura, distribución y logística, pero ha producido evidencia escasa y dispersa sobre si esa mejora de precisión se traduce en mejores decisiones organizativas, si los usuarios confían en los modelos y bajo qué condiciones, y si las organizaciones que los adoptan transforman sus procesos de forecasting de forma sostenible. Esa concentración desequilibrada de la evidencia no es un fracaso del campo, sino el resultado predecible de los incentivos de publicación en revistas de ingeniería y sistemas expertos que valoran la novedad técnica sobre la relevancia organizativa. Sus consecuencias para la práctica empresarial en los sectores B2B del corpus son, sin embargo, relevantes: la literatura sobreestima la facilidad de adopción, subestima las barreras organizativas y no proporciona a los directivos de manufactura, distribución industrial, siderurgia o logística la información necesaria para tomar decisiones de inversión en IA informadas y realistas.

La cuarta limitación, y la que tiene las consecuencias más sustanciales para la agenda de investigación futura, es la **ausencia completa de marcos de evaluación del coste-beneficio y del ROI de implantar sistemas de IA para el forecasting de ventas B2B**. Ninguno de los veinte artículos del corpus calcula o estima el retorno de la inversión en el sistema propuesto: ni el coste de desarrollo, ni el de implantación, ni el de mantenimiento y reentrenamiento, ni el valor del beneficio que la mejora de precisión produce en términos de reducción de inventario, mejora del margen de contribución, reducción del coste de oportunidades perdidas o mejora de la planificación de recursos comerciales. Esa ausencia se extiende a todos los sectores representados en el corpus (manufactura de PCB, distribución de recambios, siderurgia, exportaciones corporativas, distribución farmacéutica, telecomunicaciones B2B, logística marítima, automoción B2B, CRM B2B y comercio mayorista) y a todos los períodos temporales, desde 2007 hasta 2025. Que la brecha persista durante dieciocho años sin ser abordada por ningún estudio es evidencia de que no es una omisión accidental sino un reflejo de los límites disciplinares del campo: los investigadores de IA y machine learning carecen de las herramientas metodológicas para estimar el ROI organizativo, y los investigadores de marketing y gestión comercial no tienen acceso a los datos técnicos necesarios para construir los modelos. La agenda de investigación necesaria para cerrar esa brecha requiere equipos interdisciplinarios que combinan competencias de ingeniería del software, economía de empresa, gestión de operaciones y comportamiento organizativo, una combinación que el corpus, en toda su diversidad, no ha producido aún.

Las limitaciones identificadas en el corpus no son homogéneas ni pueden gestionarse como una lista plana. Su estructura es jerárquica: operan en cuatro niveles analíticos con distinto alcance e implicaciones distintas para el diseño de investigación futura. El primer nivel (limitaciones de datos y validación) agrupa las restricciones empíricas directas: series cortas, ausencia de benchmarks públicos compartidos, validación exclusivamente histórica sin prueba en producción y riesgo de data leakage temporal. El segundo nivel (limitaciones de diseño y protocolo) comprende las debilidades del proceso de investigación: ausencia de tests de significancia estadística en diecinueve de los veinte artículos, falta de comparación con el juicio experto humano como baseline relevante y omisión sistemática del coste-beneficio como criterio de evaluación. El tercer nivel (limitaciones teóricas) recoge las ausencias conceptuales: ningún marco integra la precisión técnica con la adoptabilidad organizativa, no existe una tipología de madurez empresarial para el forecasting algorítmico y la confianza del directivo en el modelo carece

de teorización formal. El cuarto nivel (limitaciones de transferibilidad) señala el alcance contextual restringido: sobrerrepresentación de manufactura electrónica asiática y subrepresentación estructural de servicios B2B, software empresarial y mercados de alta complejidad relacional. La tabla que sigue registra las limitaciones declaradas por cada artículo del corpus, que se distribuyen predominantemente en los dos primeros niveles; los niveles tercero y cuarto emergen del análisis transversal, no de la declaración individual de los autores.

Tabla 13 - Limitaciones declaradas por los autores del corpus analizado

Autor(es) y Año	Limitaciones declaradas
<i>Chang et al. (2007)</i>	Limitado a 60 observaciones (48 entrenamiento, 12 test); solo una empresa; generalización restringida; complejidad de Taguchi
<i>Lackman (2007)</i>	Modelo restringido a componentes B2B de automoción; no generalizable a otras categorías de producto B2B. Elevada exigencia de datos de marketing mix (product ratings, precios de competidores)
<i>Chang et al. (2008)</i>	Sin dataset público compartido; generalización a un único sector; tamaño muestral reducido
<i>Monat (2011)</i>	Una sola empresa; heterogeneidad de clasificación por vendedores; sin generalización sectorial
<i>Hadavandi et al. (2011)</i>	Dataset único (PCB taiwanés); sin validación en producción; no escalado a catálogos amplios
<i>Lu y Wang (2012)</i>	Solo dos empresas en un sector (TI mayorista, Taiwán); predictores limitados a indicadores técnicos internos; sin variables exógenas macroeconómicas
<i>Zadeh et al. (2014)</i>	Solo 36 meses de datos; umbral de correlación 0,65 fijado heurísticamente; sin tests de significancia estadística
<i>Lu y Kao (2016)</i>	Solo dos empresas; predictores limitados a rezagos temporales internos; sin variables exógenas
<i>Bohanec et al. (2017)</i>	Muestra una empresa; aproximación por muestreo en EXPLAINIME (no exacta); sin garantías de consistencia formales
<i>Rezazadeh (2020)</i>	Una empresa; umbral de decisión por cuartil puede no generalizarse; sin coste-beneficio explícito
<i>Wisesa et al. (2020)</i>	Revista Q4; diseño de validación sin garantías metodológicas estrictas; contexto de economía emergente con barreras de datos
<i>Sohrabpour et al. (2021)</i>	Un contexto exportador; sin variables cambiarias directas en el modelo base; mejora no homogénea entre productos (15-35%)
<i>Rohaan et al. (2022)</i>	Discrepancias CRM/ERP como limitación principal; sin implementación en producción documentada; datos de texto incompletos
<i>Zhang et al. (2023)</i>	Dataset privado; sin validación de producción; opacidad total del modelo
<i>Pekkaya y Uysal (2024)</i>	Una empresa siderúrgica; período temporal limitado; sin tests de significancia estadística
<i>Henna et al. (2025)</i>	448 instancias: potencial sobreajuste; sin validación en producción; sin escalabilidad a grafos grandes
<i>Chen (2025)</i>	Dataset único taiwanés; sin producción real documentada; interpretabilidad nula
<i>Huang et al. (2025)</i>	Señal solo útil en alta volatilidad; contexto pandémico difícilmente generalizable; plataformas chinas no transferibles
<i>Jovanovic et al. (2025)</i>	Sin tests de significancia en todas las comparaciones lo que deduce poco cuidado metodológico
<i>Wang et al. (2025)</i>	Un sector (marítimo); sin validación de producción; opacidad del stacking completo

Junto a las carencias metodológicas anteriores, el corpus presenta un déficit teórico de naturaleza distinta y consecuencias más profundas: la ausencia de constructos y marcos conceptuales que doten de estructura interpretativa a la evidencia empírica acumulada. Tres ausencias teóricas resultan especialmente determinantes. La primera es la falta de una teoría de la traducción de la precisión en decisión, esto es, un modelo que explique

mediante qué mecanismos una reducción del error predictivo se convierte en una decisión comercial mejor; el corpus asume esa traducción como automática, cuando los propios casos de Bohanec et al. (2017) y Rohaan et al. (2022) demuestran que el vínculo entre precisión técnica y valor organizativo está mediado por factores que ningún marco teoriza. La segunda es la inexistencia de un marco de madurez organizativa que permita clasificar a las empresas según su capacidad para absorber y explotar el forecasting algorítmico; sin esa tipología, la literatura no puede explicar por qué mejoras técnicas equivalentes producen impactos operativos tan dispares entre la manufactura de PCB (Chang et al., 2007) y la distribución de recambios industriales (Rohaan et al., 2022). La tercera es la ausencia de una teorización sobre la confianza algorítmica en contextos B2B, donde la decisión de delegar el juicio comercial en un modelo depende de variables psicológicas, jerárquicas y culturales que el corpus documenta de forma anecdótica pero no integra en ningún constructo formal. Estas tres lagunas teóricas no son independientes de las metodológicas: la ausencia de marcos conceptuales explica, en parte, por qué los diseños empíricos del campo se concentran en lo medible (la precisión) y eluden lo difícil de operacionalizar (la decisión, la madurez y la confianza), lo que confirma que las dimensiones D2, D3 y D4 del marco analítico carecen tanto de instrumentos de medición como de fundamento teórico que justifique su medición.

Cada uno de esos cuatro niveles de limitación genera una implicación directa para una agenda doctoral. Las limitaciones de datos y validación apuntan a la necesidad de estudios longitudinales con validación en producción, esto es, estudios que midan no solo si el modelo predice bien sobre datos históricos, sino si la organización mejora sus decisiones comerciales tras implantarlo. Las limitaciones de diseño y protocolo señalan la urgencia de investigaciones que comparen de forma sistemática los modelos de IA con el forecast humano vigente como baseline principal, y que incluyan el coste de implantación como variable de la ecuación de valor. Las limitaciones teóricas indican que el campo requiere constructos propios: la madurez de forecasting organizativo y la confianza algorítmica del directivo comercial son constructos sin desarrollo formal que bloquean el avance empírico en D3 y D4. Las limitaciones de transferibilidad, por último, abren el espacio para estudios en sectores subrepresentados (software B2B, servicios profesionales, distribución de alta complejidad) donde la estructura de los datos y los ciclos de venta difieren estructuralmente de los contextos que dominan el corpus y donde las conclusiones de este trabajo no pueden extrapolarse sin validación específica.

3.8 Respuesta a las preguntas de investigación y objetivos

La revisión sistemática de los veinte artículos que conforman el corpus no produce un conjunto de respuestas cerradas. Produce, con más precisión, un mapa de lo que la literatura ha resuelto, de lo que ha dejado parcialmente abierto y de lo que ni siquiera ha intentado abordar. Ese mapa tiene un valor analítico que trasciende el inventario de resultados: permite establecer, sobre base documental, el grado en que cada pregunta de investigación ha encontrado respuesta en la producción científica disponible y en qué medida cada objetivo del estudio queda cubierto, parcialmente cubierto o sistemáticamente eludido por el campo.

- **PI1: en qué medida la IA incrementa la precisión del forecasting B2B y en qué condiciones esa mejora es trasladable a la práctica comercial**

La pregunta principal integra dos componentes analíticamente distintos que el corpus responde con intensidad muy diferente. El primer componente, referido a la medida en que la IA incrementa la precisión, recibe la respuesta más sólida de todo el trabajo: la totalidad del corpus confirma que los modelos de IA superan a los baselines estadísticos convencionales en todos los sectores representados, con mejoras que oscilan desde la reducción del 28% de MAPE que Hadavandi et al. (2011) documentan sobre el WEFuNN de Chang et al. (2007) hasta la reducción del 87,6% en MAE medio sobre ARIMA que Zadeh et al. (2014) registran en la distribución farmacéutica iraní, pasando por los 18-20 puntos porcentuales de mejora en accuracy sobre el juicio humano de los vendedores que Rezazadeh (2020) documenta en producción real durante tres meses con 846 oportunidades reales.

La superioridad de los modelos de IA sobre los baselines estadísticos no es un hallazgo puntual: es el patrón más consistente del corpus, presente en diecisiete de los veinte artículos con suficiente información comparativa para ser valorado.

Sin embargo, esa consistencia en la respuesta al primer componente contrasta de forma marcada con la escasez de respuesta al segundo: bajo qué condiciones esa mejora es trasladable a la práctica comercial. Solo tres artículos del corpus abordan ese componente de forma directa. Rezazadeh (2020) es el único que documenta rendimiento en producción real, demostrando que el pipeline ensemble de XGBoost y LightGBM mantiene en producción el 83% de accuracy frente al 63% del juicio de los vendedores, con una condición de contorno explícita: datos CRM suficientemente limpios, umbrales de decisión segmentados por cuartil de valor de contrato y reentrenamiento semanal automatizado. Rohaan et al. (2022) documentan la situación contraria: las discrepancias entre identificadores de empresa en el CRM y el sistema de RFQs imposibilitan la vinculación del historial de compras con las características de la oportunidad entrante, anulando la transferibilidad práctica del modelo con independencia de su sofisticación arquitectónica. Bohanec et al. (2017) delimitan la tercera condición de transferibilidad: la explicabilidad de las predicciones, sin la cual los directivos comerciales eslovenos del estudio no confían en el modelo y no lo incorporan a su proceso decisional, incluso cuando su AUC de 0,85 es técnicamente superior al de todos los algoritmos de comparación. La respuesta del corpus a la pregunta principal es, por tanto, asimétrica: robusta en su componente técnico, fragmentaria y condicionada en su componente organizativo.

La respuesta del corpus a PI1 no puede formularse como una cifra única ni como una afirmación incondicional. Puede formularse, en cambio, como una proposición condicional de tres componentes. Si el dataset tiene suficiente volumen y calidad para entrenar un modelo (condición que el corpus sitúa por encima de los 1.000 registros etiquetados en contextos de clasificación binaria y por encima de tres a cinco años de historial mensual en contextos de series temporales), y si el modelo se evalúa con validación temporal estricta (separación cronológica entre entrenamiento y test, sin leakage de datos futuros), y si el baseline de comparación incluye el pronóstico humano vigente (y no solo modelos estadísticos como ARIMA o regresión lineal), entonces la evidencia del corpus apunta a que los modelos de IA producen mejoras de precisión sistemáticas y sustanciales, con reducciones de MAPE de entre el 20% y el 75% respecto al baseline pertinente. Fuera de esas tres condiciones, la evidencia no permite afirmar que la IA mejore el forecast B2B de forma generalizable. Esa condicionalidad no debilita la respuesta a PI1; la precisa. Y su precisión es, metodológicamente, más valiosa que una afirmación positiva incondicional que el corpus no puede sostener.

- **PI2: qué arquitecturas y metodologías predominan y cómo se comporta su rendimiento frente a enfoques estadísticos convencionales y al juicio experto**

Esta es la pregunta que el corpus responde con mayor amplitud y sistematicidad, lo cual refleja que la comparación de algoritmos es el objetivo de investigación dominante del campo. La taxonomía de tres familias metodológicas construida en la sección 3.3 proporciona la respuesta estructural: los modelos simbólicos y fuzzy (2007-2014) ofrecen interpretabilidad estructural intrínseca con precisión suficiente para catálogos reducidos; los modelos de aprendizaje supervisado clásico y ensamblajes (2011-2022) mejoran la precisión sobre datos de mayor volumen y mayor número de variables al coste de reducir la transparencia; y las arquitecturas de deep learning e híbridas avanzadas (2023-2025) alcanzan la mayor precisión técnica del corpus al precio de la opacidad algorítmica total.

La comparación con enfoques estadísticos convencionales confirma la superioridad sistemática de los modelos de IA: MARS supera estadísticamente a diez modelos de comparación (incluyendo SVR, BPN y ELM) en la distribución mayorista de TI taiwanesa con MAPE de 0,11% frente a 0,32% del SVR (Lu y Wang, 2012); el Random Forest supera a ARIMA en entre el 15% y el 35% en la predicción de exportaciones corporativas iranes dependiendo del tipo de producto (Sohrappour et al., 2021); y la red híbrida de atención y series temporales de Zhang et al. (2023) supera al LSTM estándar en todos los datasets de ventas empresariales chinas evaluados. La única comparación directa con el juicio experto humano en el corpus la proporcionan Rezazadeh (2020), que documenta la brecha de 20 puntos porcentuales en accuracy entre el pipeline ML y el proceso humano de cualificación de oportunidades, y Monat (2011), cuyo modelo de scorecard cualitativa alcanza una accuracy de aproximadamente el 65% frente al juicio subjetivo no cuantificado de los vendedores. Esa brecha entre modelos de IA y juicio humano es cuantitativamente robusta pero contextualmente condicionada: en ambos estudios, las condiciones organizativas de implantación son las que determinan si esa superioridad técnica se traduce en mejora operativa real. La pregunta sobre el rendimiento frente a enfoques estadísticos convencionales queda, por tanto, respondida de forma sólida y

con cobertura geográfica y sectorial amplia. La pregunta sobre el rendimiento frente al juicio experto queda respondida por solo dos estudios, lo que representa una brecha empírica relevante para un campo cuya pertinencia práctica reside precisamente en la comparación con el proceso humano de forecasting que los modelos deben complementar o sustituir.

- **PI3: qué variables, fuentes de datos y estructuras de información exhiben mayor capacidad predictiva en contextos B2B**

Esta pregunta obtiene una respuesta parcial pero valiosa del corpus, con tres hallazgos convergentes de especial relevancia para el diseño de sistemas de forecasting en empresas B2B. El primero es la importancia de las variables macroeconómicas de exposición externa en empresas que operan en mercados internacionales: Pekkaya y Uysal (2024) identifican el tipo de cambio EUR/TRY como predictor dominante en la siderurgia turca con R^2 de 0,85 frente a 0,65 de la regresión lineal; Sohrabpour et al. (2021) documentan que la variabilidad de la ventaja del Random Forest sobre ARIMA en exportaciones corporativas iranes depende directamente de la sensibilidad cambiaria del producto; y Wang et al. (2025) confirman que los índices de flete marítimo CCFI y BCI son los predictores de mayor importancia en la logística de contenedores. Tres estudios independientes, en tres sectores distintos y tres países distintos, convergen en el mismo hallazgo estructural: la omisión de variables macroeconómicas de exposición externa degrada de forma apreciable la precisión del modelo en empresas B2B con internacionalización comercial relevante.

El segundo hallazgo relevante sobre variables y datos es la potencia predictiva de las señales relacionales en contextos B2B con grafos de clientes. Zadeh et al. (2014) demuestran que los datos de ventas de medicamentos correlacionados funcionan como fuente de transfer learning implícito que reduce el MAE medio un 87,6% sobre ARIMA en la distribución farmacéutica; y Henna et al. (2025) demuestran once años después que las redes de convolución espectral en grafos que explotan la estructura relacional del CRM B2B alcanzan una accuracy de 1,00 y un AUC de 0,929 en la clasificación de oportunidades de venta en el contexto irlandés. Ambos estudios, separados por una década y empleando arquitecturas tecnológicamente incomparables, resuelven el mismo problema estructural: la escasez de datos de un nodo individual mediante la explotación de la estructura relacional del grafo en que ese nodo está embebido. Ese patrón convergente sugiere que las estructuras de información relacional entre cuentas B2B constituyen una fuente de señal predictiva sistemáticamente infrautilizada en el corpus.

El tercer hallazgo es la relevancia de la señal de comportamiento comercial no estructurado como variable de entrada, representada por el trabajo de Rohaan et al. (2022) sobre el procesamiento de lenguaje natural aplicado a las descripciones textuales de los RFQs. La incorporación de texto libre como fuente de información predictiva en el forecasting B2B es un desarrollo metodológico pertinente que el corpus documenta en un único estudio, lo que convierte la evaluación de esa señal en distintos sectores y contextos en una línea de trabajo abierta. La respuesta a PI3 queda, pues, cubierta con solidez en lo relativo a variables macroeconómicas y estructuras de grafo relacional, y abierta en lo relativo a señales no estructuradas y a la evaluación sistemática de cuándo cada tipo de variable aporta ganancia predictiva marginal real en contextos B2B.

- **PI4: a través de qué mecanismos se manifiestan las barreras de implementación y con qué consistencia aparecen documentadas**

La pregunta sobre barreras de implementación obtiene del corpus una respuesta cualitativamente rica pero cuantitativamente escasa: cuatro artículos aportan evidencia sustantiva directa sobre mecanismos de implantación, mientras que los dieciséis restantes las mencionan de forma tangencial en sus secciones de limitaciones o trabajo futuro. El análisis transversal de la sección 3.6 identifica que esa evidencia, concentrada en cuatro estudios, permite construir un mapa jerárquico de barreras con notable coherencia interna.

La calidad de los datos del CRM es la barrera más consistente y transversal del corpus: Monat (2011) documenta que la heterogeneidad en los criterios de clasificación de oportunidades por parte de los vendedores introduce sesgos sistemáticos que degradan la variable dependiente antes de que el modelo pueda ser entrenado; Rohaan et al. (2022)

documentan que las discrepancias entre identificadores en sistemas diseñados con propósitos distintos imposibilitan la vinculación del historial de compra con la oportunidad entrante; y Rezazadeh (2020) documenta que la superación de esa barrera, a través de un proceso de limpieza de datos y definición de umbrales de decisión, es la condición previa necesaria para que el pipeline ML opere en producción con mejora real sobre el proceso humano. La confianza del usuario en el modelo es la segunda barrera documentada: Bohanec et al. (2017) demuestran que la incorporación de un mecanismo de explicación post-hoc (EXPLAIN + IME) incrementa la disposición de los directivos comerciales eslovenos a utilizar las predicciones del Random Forest, identificando la opacidad algorítmica como factor de resistencia organizativa en contextos donde las decisiones deben poder justificarse ante la dirección. La infraestructura tecnológica como barrera previa aparece documentada en Wisesa et al. (2020), cuyos registros incompletos de contratos corporativos y sistemas de información con cobertura parcial en el contexto de telecomunicaciones B2B indonesio ilustran las condiciones de economías emergentes donde la adopción de IA para forecasting requiere primero la digitalización mínima del proceso comercial.

La consistencia de estas barreras a través del corpus es selectiva: la calidad de los datos aparece en contextos tan distintos como la conversión de leads industriales en Estados Unidos (Monat, 2011), la distribución de recambios en los Países Bajos (Rohaani et al., 2022) y el pipeline B2B en Canadá (Rezazadeh, 2020), lo que confiere a esa barrera el mayor grado de generalización posible dentro del corpus. La confianza del usuario solo se documenta de forma sistemática en un estudio (Bohanec et al., 2017), aunque la ausencia de mecanismos de explicabilidad en los estudios del período 2023-2025 hace que la dimensión de confianza esté implícitamente presente como riesgo no estudiado en la mitad del corpus. La barrera de infraestructura aparece en un único estudio con restricción geográfica al contexto de economías emergentes, lo que limita su generalización a contextos de digitalización avanzada. El conjunto de las barreras documentadas constituye, por tanto, una respuesta parcial a PI4: sólida en su componente de datos y suficientemente argumentada en su componente de confianza, pero incompleta en su componente de transformación organizativa, cuya ausencia casi total del corpus es en sí misma la respuesta más pertinente a esta pregunta.

- **PI5: qué vacíos teóricos, metodológicos y contextuales permanecen abiertos y sobre cuáles podría fundamentarse una agenda doctoral**

Esta pregunta no espera ser respondida por el corpus: espera que el corpus la haga necesaria, y lo hace con coherencia estructural. Los vacíos identificados en la sección 3.7 no son imperfecciones individuales de los estudios analizados, sino patrones de ausencia sistemática que se reproducen con independencia del sector, el período temporal y la sofisticación arquitectónica del estudio. La respuesta del corpus a esta pregunta es, paradójicamente, la más completa de las cinco: el campo ha producido evidencia suficiente para que la delimitación de sus brechas sea rigurosa.

En el plano metodológico, la ausencia de benchmarking compartido impide cualquier síntesis cuantitativa del campo y limita la comparación entre estudios a la modalidad cualitativa con todas sus restricciones. Ninguno de los veinte artículos utiliza un dataset público de referencia para el forecasting de ventas B2B. La única excepción parcial es Jovanovic et al. (2025), que utiliza el dataset de Amazon como proxy B2B imperfecto, aunque ese proxy presenta diferencias estructurales con el contexto B2B en sentido estricto que el propio artículo reconoce. La ausencia de validación en producción, documentada únicamente en Rezazadeh (2020), es el segundo vacío metodológico de mayor relevancia práctica: los diecinueve restantes validan sobre datos históricos sin verificar si los modelos mantienen su rendimiento cuando las distribuciones de los datos cambian, los mercados se transforman y los usuarios del sistema introducen dinámicas de retroalimentación que ningún dataset histórico captura.

En el plano teórico, los tres vacíos identificados en la sección 3.7 se articulan con las preguntas de investigación de forma directa. La ausencia de una teoría de la traducción de la precisión en decisión responde al componente organizativo no resuelto de la pregunta principal: ningún estudio del corpus proporciona un modelo que explique mediante qué mecanismos una reducción del error predictivo se convierte en una decisión comercial de mayor calidad. La ausencia de un marco de madurez organizativa responde a PI4: sin una tipología que permita clasificar a las empresas según su capacidad de absorción del forecasting algorítmico, la literatura no puede explicar por qué

mejoras técnicas equivalentes producen impactos operativos tan dispares entre la manufactura de PCB taiwanesa y la distribución de recambios neerlandesa. La ausencia de una teorización sobre la confianza algorítmica en contextos B2B responde al mecanismo de barrera más documentado del corpus (Bohanec et al., 2017) y lo convierte en un constructo teórico sin desarrollo formal: las variables psicológicas, jerárquicas y culturales que determinan si un directivo comercial delega su juicio en un modelo de IA están documentadas de forma anecdótica pero no integradas en ningún constructo que permita su operacionalización ni su contraste empírico.

En el plano contextual, la fragmentación geográfica del corpus impide determinar cuánto del conocimiento sobre barreras de implantación es específico de contexto cultural y cuánto es genuinamente general. Los siete estudios taiwaneses y los tres chinos documentan patrones de gobernanza de datos y adopción tecnológica que operan en culturas organizativas con centralización del control de datos y estructuras de autoridad jerárquica muy distintas a las que caracterizan los contextos europeos o norteamericanos. Ningún artículo del corpus replica el diseño de otro en un país o sector diferente, lo que impide cualquier estudio de transferibilidad explícita. Esa indeterminación contextual es especialmente relevante para el único sector que el corpus no cubre: el software empresarial B2B, donde los ciclos de venta son complejos, los pipelines son dinámicos, los datos CRM son estructuralmente distintos a los de la manufactura o la distribución, y las decisiones comerciales dependen de relaciones y negociaciones que ninguna serie temporal captura de forma directa.

Sobre los objetivos de la investigación

La cobertura de los cuatro objetivos del estudio no es homogénea. El primero, identificar las principales metodologías de IA utilizadas en el forecasting de ventas B2B, queda resuelto con la mayor solidez: la taxonomía de tres familias metodológicas de la sección 3.3 distingue con precisión las contribuciones específicas de cada generación arquitectónica y sus concesiones en términos de precisión, interpretabilidad y coste de implantación. El segundo objetivo, sintetizar los hallazgos empíricos en relación con metodologías, variables y limitaciones, presenta una cobertura asimétrica según la dimensión analizada. Los hallazgos sobre precisión técnica están sintetizados con densidad suficiente para extraer conclusiones; los relativos a variables y fuentes de datos muestran una cobertura desigual, dado que doce de los veinte artículos aportan información detallada sobre selección de variables mientras que los ocho restantes no justifican de forma sustantiva su arquitectura de datos; y los hallazgos sobre limitaciones técnicas y organizativas están disponibles pero concentrados en cuatro estudios, con escasa presencia transversal en el resto del corpus.

El tercer objetivo, analizar las barreras de implementación con mayor consistencia, queda cubierto de forma parcial. La barrera de calidad de datos es la más sólida y transversal, documentada en tres continentes y a lo largo de tres décadas; la opacidad algorítmica y la confianza del usuario reciben tratamiento sistemático solo en un estudio, aunque están implícitamente presentes como riesgo no estudiado en los artículos de la tercera familia; la barrera de infraestructura tecnológica se circunscribe a un único contexto geográfico de economía emergente; y la gestión del cambio organizativo no aparece como objeto de investigación primario en ninguno de los veinte artículos, lo que hace que ese componente del objetivo no pueda cubrirse con la evidencia disponible. El cuarto objetivo, detectar los vacíos que permanecen abiertos, es el que queda cubierto de forma más integral: los patrones de ausencia estructural identificados en la sección 3.7 proporcionan una delimitación suficientemente precisa para fundamentar preguntas de investigación doctoral, y el corpus no sólo no responde a esos vacíos, sino que los hace visibles con una claridad que la lectura transversal sistemática de los veinte estudios hace posible.

La distribución global de esa cobertura **reproduce el patrón que el análisis dimensional de la sección 3.2 ya anticipa**: la revisión responde con solidez a las preguntas sobre qué metodologías funcionan y en qué medida mejoran la precisión (D1), con suficiencia argumentativa a la pregunta sobre qué variables y datos contribuyen a esa mejora (D2 en su vertiente metodológica), con evidencia concentrada pero conceptualmente rica a la pregunta sobre qué barreras obstaculizan la implantación (D3), y con un silencio estructural elocuente a la pregunta sobre cómo se gestiona la transformación organizativa que esa implantación requiere (D4).

4. AGENDA DE INVESTIGACIÓN Y FUTURAS LÍNEAS DE INVESTIGACIÓN

Una revisión sistemática no termina cuando se cierra la lectura del último artículo del corpus. Termina, si alguna vez termina, cuando los vacíos que la lectura ha hecho visibles quedan formulados con la precisión suficiente para que alguien pueda investigarlos. Este trabajo ha producido, a lo largo de sus tres secciones anteriores, un diagnóstico estructurado sobre el estado de la investigación en inteligencia artificial aplicada al forecasting de ventas B2B: ha identificado qué metodologías predominan, en qué condiciones técnicas la mejora predictiva resulta robusta, qué barreras organizativas aparecen con mayor consistencia y qué dimensiones del problema han recibido una atención sistemáticamente menor.




Figura 9 - Cobertura del corpus por dimensión conceptual y los vacíos actuales (elaboración propia)

Ese diagnóstico no es, en sí mismo, una contribución menor. Pero su valor más duradero no reside en lo que ha confirmado, sino en lo que ha delimitado como abierto. La literatura revisada **ha generado evidencia técnica comparativamente sólida sobre la dimensión D1, mientras que las dimensiones D2, D3 y D4 permanecen insuficientemente atendidas, y el sector del software B2B, con toda su especificidad estructural, no ha sido objeto de ningún estudio del corpus.** Lo que sigue no es una síntesis de lo ya expuesto: es la traducción de esas ausencias en una agenda de investigación articulada, con líneas concretas, dos propuestas doctorales diferenciadas y la justificación de por qué esa dualidad es la respuesta adecuada a los dos tipos de silencio que la revisión ha documentado.

4.1. De la síntesis crítica a la formulación de una agenda

Una revisión sistemática que concluye con una lista de hallazgos ha resuelto, en el mejor de los casos, la mitad del problema que se propuso abordar. La otra mitad reside en lo que la literatura no ha dicho, no ha medido o no ha tenido siquiera la disposición de formular. En ese sentido, la síntesis crítica desarrollada en las secciones 3.7 y 3.8 no representa el cierre analítico de este trabajo, sino su punto de mayor tensión productiva: el momento en que la acumulación de evidencia sobre lo conocido obliga a detenerse y cartografiar con precisión lo desconocido. El resultado de la revisión no es una respuesta, sino un mapa estructurado de resolución diferencial, cuya utilidad para la comunidad investigadora no es inferior a la de los hallazgos sustantivos, y cuyas implicaciones para el diseño de investigación doctoral son considerablemente más directas.

Los vacíos identificados en la sección 3.7 se distribuyen en **cuatro niveles analíticos** que el propio corpus permite distinguir. Las restricciones más inmediatas son empíricas: ausencia de conjuntos de datos públicos y comparables

para el forecasting de ventas B2B, validación exclusivamente retrospectiva sobre datos históricos en diecinueve de los veinte estudios, y riesgo latente de contaminación temporal en los diseños que no aplican separación estricta entre entrenamiento y evaluación. La excepción es Rezazadeh (2020), cuyo despliegue en producción durante tres meses constituye el único caso documentado de validación en entorno real, lo que convierte esa contribución en un referente aislado más que en una práctica consolidada del campo. A esas restricciones empíricas se suman debilidades sistemáticas de diseño y protocolo: ausencia de pruebas de significancia estadística en diecinueve de los veinte artículos, escasísima comparación del modelo de IA con el forecast humano como línea base de referencia, y omisión universal del análisis de coste-beneficio como criterio de evaluación del valor real de la solución. Esas dos capas de limitación son las más visibles, pero no las más determinantes para la agenda. Las restricciones empíricas y de protocolo pueden mitigarse, al menos parcialmente, mediante mejoras en el diseño de los estudios. Las ausencias teóricas y las limitaciones de transferibilidad contextual, en cambio, no se resuelven con más datos ni con mejores métricas: requieren orientaciones de investigación distintas, con preguntas formuladas en registros conceptuales que el corpus no ha frecuentado. El alcance geográfico y sectorial del corpus, dominado por manufactura electrónica asiática y distribución industrial, deja sin cobertura estructural los servicios B2B de alta complejidad relacional, y esa subrepresentación no es una carencia menor: es la condición que hace imposible cualquier generalización de los hallazgos a los contextos donde el forecasting algorítmico tiene mayor potencial de impacto.

Tres ausencias teóricas organizan el núcleo de esa agenda. La más inmediata es la falta de un modelo que explique mediante qué mecanismos una reducción del error predictivo se convierte en una decisión comercial de mayor calidad. El corpus asume esa traducción como automática y no argumentada. El caso de Bohanec et al. (2017) lo ilustra con claridad: el sistema de explicación post-hoc produce predicciones auditables y permite al equipo comercial realizar análisis de escenarios, pero el estudio no mide cómo esas capacidades modifican las decisiones reales ni si su calidad mejora de forma verificable. La segunda ausencia es la inexistencia de un marco de madurez organizativa aplicable al forecasting algorítmico: sin esa tipología, la literatura no puede explicar por qué mejoras técnicas equivalentes producen impactos operativos tan dispares entre contextos organizativos tan distintos como la manufactura taiwanesa de PCB (Chang et al., 2007) y la distribución industrial de recambios neerlandesa (Rohaani et al., 2022). La tercera es la falta de una teorización formal sobre la confianza algorítmica en contextos B2B: las variables psicológicas, relacionales y culturales que determinan si un directivo comercial delega su juicio en el output de un modelo están documentadas de forma anecdótica en algunos estudios, pero ningún artículo las integra en un constructo susceptible de operacionalización y contraste empírico.

A esas tres ausencias teóricas **se añade un vacío de naturaleza distinta pero igualmente relevante: ninguno de los veinte estudios calcula ni estima el coste de implantación del modelo, el coste de mantenimiento y reentrenamiento, ni ningún indicador de coste-beneficio que vincule la mejora estadística con el valor económico de la solución.** Esa laguna no es accidental. Refleja una orientación del campo hacia la validación técnica del algoritmo y la indiferencia sistemática hacia la lógica de creación de valor que, en último término, es la que determina si una organización decide implantar, sostener o desmantelar un sistema de forecasting algorítmico. El déficit atraviesa la dimensión D4 de forma más visible, pero alcanza también a D2 y D3: sin un cálculo de valor que ancle la solución a la economía de la organización, las decisiones de adopción y de continuidad del sistema quedan sin fundamento racional verificable. Este diagnóstico organiza la agenda que sigue. La síntesis crítica ha producido un mapa asimétrico de cobertura: sólido en D1, débil en D2 y D3, prácticamente vacío en D4. Esa asimetría no es un defecto de la revisión; es su principal hallazgo estructural, y es lo que hace necesaria y justificable una agenda de investigación dual que responda, desde dos orientaciones distintas, a dos silencios distintos del campo: uno contextual-empírico, sobre qué sectores no han sido estudiados, y uno teórico-organizativo, sobre qué marcos conceptuales no han sido construidos.

4.2. Líneas futuras de investigación derivadas del corpus

El siguiente cuadro traduce los vacíos identificados en líneas de investigación accionables, especificando para cada una la evidencia disponible en el corpus, el diseño metodológico plausible, la contribución esperada y su relevancia para una agenda doctoral.

Tabla 14 - Resumen de vacíos detectados y futuras líneas de investigación

Vacío detectado	Evidencia en el corpus	Línea futura de investigación	Diseño metodológico plausible	Contribución esperada	Prioridad doctoral
<i>Ausencia de benchmarks compartidos y protocolos de comparación para el forecasting de ventas B2B</i>	Jovanovic et al. (2025) utilizan el dataset de Amazon como proxy imperfecto; ningún estudio utiliza un conjunto de datos público de referencia para ventas B2B	Construcción y validación de un benchmark público para el forecasting de ventas B2B con protocolos estandarizados de evaluación	Colaboración multi-organizacional para compilar datasets anonimizados; definición de métricas y protocolos comunes; validación cruzada de modelos en el mismo conjunto	Permitir la comparabilidad real entre estudios; superar la dependencia de datasets privados de una sola empresa	Alta (prerrequisito metodológico)
<i>Ausencia de validación longitudinal y en entornos de producción real</i>	Solo Rezazadeh (2020) documenta validación en producción (3 meses); los 19 artículos restantes validan exclusivamente sobre datos históricos	Estudios longitudinales de validación en producción de sistemas de forecasting algorítmico B2B	Diseño cuasi-experimental con implementación en producción; seguimiento del rendimiento del modelo durante 12–24 meses; comparación con el forecast humano como línea base primaria	Proporcionar evidencia sobre la estabilidad real de los modelos ante cambios de distribución de datos y dinámicas de mercado	Alta
<i>Subrepresentación estructural del software B2B, SaaS y software empresarial</i>	El corpus está dominado por manufactura electrónica, distribución industrial, logística, exportaciones y acero; el software B2B no está representado en ningún artículo	Desarrollo y validación de modelos de forecasting de ventas B2B en empresas de software, SaaS y software empresarial	Estudio empírico con datos CRM y pipeline de una o más empresas de software B2B; comparación entre modelos de IA y forecast humano; validación temporal estricta	Generar evidencia transferible a un sector de alta relevancia económica estructuralmente ausente en la literatura	Alta (Propuesta A)
<i>Señales CRM relacionales, datos de grafos y texto no estructurado como predictores infravalorados</i>	Henna et al. (2025) demuestran la superioridad de GCN sobre modelos convencionales usando estructura relacional del CRM; Rohaan et al. (2022) exploran NLP sobre texto de RFQ con resultados parciales; Zadeh et al. (2014) capturan relaciones entre fármacos y prescriptores	Integración de señales relacionales, grafos CRM y datos no estructurados en modelos de forecasting B2B	Extracción de características relacionales del CRM mediante análisis de grafos; procesamiento de texto libre de emails, notas de oportunidades y RFQ; comparación con modelos sin señales relacionales	Demostrar el valor incremental de los datos relacionales y no estructurados sobre las métricas de forecast en contextos B2B de alta complejidad relacional	Media-Alta

Vacío detectado	Evidencia en el corpus	Línea futura de investigación	Diseño metodológico plausible	Contribución esperada	Prioridad doctoral
<i>Déficit de investigación sobre interpretabilidad, confianza algorítmica y adopción directiva del forecast</i>	Bohanec et al. (2017) es el único estudio con orientación explícita a la explicabilidad; los modelos más recientes (Zhang et al., 2023; Chen, 2025; Jovanovic et al., 2025) incrementan la opacidad sin considerar su impacto sobre la adopción; Monat (2011) documenta la resistencia a la clasificación heterogénea de los vendedores	Investigación sobre explicabilidad, confianza directiva y adopción organizativa del forecasting algorítmico B2B	Diseño mixto: experimentos comparando forecasts explicados versus no explicados; encuestas sobre confianza y uso en muestras de directivos comerciales; entrevistas exploratorias sobre barreras de adopción	Construir el constructo de confianza algorítmica en ventas B2B; establecer la relación entre explicabilidad y adopción; informar el diseño de interfaces de XAI para la práctica comercial	Alta (Propuesta B)
<i>Ausencia total de marcos de madurez organizativa, gestión del cambio y análisis ROI del forecasting algorítmico</i>	Ningún artículo del corpus aborda la gestión del cambio como objeto de investigación primario; ninguno calcula ROI, coste de implantación, coste de reentrenamiento ni análisis de coste-beneficio; Rohaan et al. (2022) mencionan discrepancias CRM/ERP sin analizar su dimensión organizativa	Construcción de un marco de madurez organizativa para el forecasting algorítmico B2B y análisis de su relación con ROI y gestión del cambio	Revisión teórica integradora de marcos de madurez y gestión del cambio; estudio de casos múltiples longitudinal; encuesta a organizaciones B2B en distintos niveles de madurez de forecasting	Proporcionar el primer marco tipológico de madurez organizativa para el forecasting algorítmico; establecer las condiciones que determinan el ROI real de la implantación	Muy Alta (Propuesta B, núcleo teórico)

Las seis líneas que componen este cuadro **no son intercambiables ni equivalentes**. Entre ellas existe una lógica de dependencia que conviene explicitar para que la agenda sea útil como programa de investigación y no como lista de temas aislados. Las dos primeras líneas (benchmarks compartidos y validación en producción) son de naturaleza metodológica y funcionan como prerequisites para el avance del resto del campo. Sin conjuntos de datos de referencia compartidos, toda comparación entre estudios queda reducida a la modalidad cualitativa, con sus limitaciones de inferencia. Sin validación longitudinal en producción, la evidencia sobre el rendimiento de los modelos permanece confinada al contexto histórico y nunca puede responder a la pregunta que las organizaciones se formulan cuando evalúan la implantación de un sistema: ¿sigue funcionando cuando el mercado cambia? Estas dos líneas tienen una prioridad metodológica transversal cuya resolución beneficiaría a todas las demás. Son, sin embargo, las menos susceptibles de ser abordadas en el marco de una tesis doctoral individual, porque exigen colaboración multiorganizacional y acceso privilegiado a datos que raramente se obtiene en el contexto de una investigación académica sin financiación externa específica.

La tercera línea, sobre software B2B y SaaS, constituye el núcleo de la agenda empírico-contextual derivada de la dimensión D1. La ausencia de este sector en el corpus no es una omisión menor: el software empresarial B2B es uno de los segmentos de mayor crecimiento en la economía digital y presenta características estructurales (ciclos de venta largos, pipelines con múltiples etapas y actores, métricas de renovación y expansión, dependencia del historial de cuenta) que lo diferencian de forma sustantiva de los contextos que dominan el corpus. Transferir las conclusiones del corpus a ese contexto sin validación específica no es metodológicamente sostenible. La tercera línea responde directamente a esa brecha y alimenta la Propuesta doctoral A.

La cuarta línea, sobre señales CRM relacionales y datos no estructurados, es complementaria a la tercera desde la perspectiva de los datos. Henna et al. (2025) demuestran que la estructura relacional del CRM captura información predictiva que los modelos tabulares convencionales no pueden explotar, obteniendo mejoras sustanciales sobre Random Forest y XGBoost en la predicción de oportunidades ganadas. Rohaan et al. (2022) muestran, por su parte, que el texto no estructurado de las solicitudes de oferta contiene señales sobre la probabilidad de conversión que los modelos de procesamiento de lenguaje natural pueden explotar, aunque la calidad y la consistencia de esos datos limitan la madurez del resultado. Juntas, estas dos evidencias apuntan a que el valor predictivo de los datos CRM en entornos B2B no ha sido explotado de forma sistemática, y que su tratamiento mediante arquitecturas de grafos y procesamiento de lenguaje natural abre una línea con contribución potencialmente relevante.

Las dos últimas líneas pertenecen al eje teórico-organizativo y constituyen el núcleo de la Propuesta doctoral B. La quinta, sobre interpretabilidad, confianza y adopción, y la sexta, sobre madurez organizativa, cambio y ROI, no son temáticamente independientes: la confianza del directivo en el modelo depende, en parte, de la explicabilidad de sus outputs; la adopción sostenida depende, en parte, de la madurez organizativa del entorno; y el ROI de la implantación depende, en parte, de la calidad de esa adopción. La coherencia interna de estas dos líneas no justifica su fusión en una única propuesta: su amplitud y la diferencia entre sus orientaciones teóricas primarias hacen más rigurosa su presentación como dos componentes articulados de una propuesta doctoral de mayor alcance.

Las seis líneas forman, en conjunto, **un programa de investigación coherente que avanza en dos frentes simultáneos**. El primero responde a la pregunta de si la evidencia técnica disponible sobre el rendimiento de la IA en el forecasting B2B es transferible a contextos estructuralmente distintos. El segundo responde a la pregunta de qué marcos conceptuales y qué evidencia empírica son necesarios para que las ganancias técnicas se conviertan en valor organizativo sostenible. Esas dos preguntas no compiten entre sí: son complementarias, y la agenda doctoral que las instrumentaliza no refleja indecisión, sino amplitud de miras.

4.3. Justificación de una agenda doctoral dual

La propuesta de dos líneas doctorales diferenciadas no es el resultado de una dificultad para elegir entre alternativas de igual valor. Es la respuesta analítica directa a una asimetría estructural que la revisión ha hecho visible con suficiente claridad.

El corpus revisado ha producido evidencia comparativamente robusta sobre la capacidad técnica de los modelos de IA para mejorar la precisión del forecasting de ventas en entornos B2B. Esa evidencia tiene, sin embargo, una doble limitación de alcance: **está concentrada en sectores industriales con características específicas** (manufactura electrónica, distribución de componentes, logística, exportaciones) **y no explica con equivalente solidez cómo las ganancias predictivas se convierten en valor organizativo, en decisiones comerciales de mayor calidad o en adopción sostenida de la tecnología**. Esas dos limitaciones no son del mismo tipo. La primera es una limitación contextual, y su respuesta natural es investigación empírica en contextos distintos. La segunda es una limitación teórica, y su respuesta natural es el desarrollo de constructos y marcos explicativos que el campo no ha construido todavía.

Una agenda doctoral que solo abordara la primera limitación (la Propuesta A) produciría contribuciones valiosas para la dimensión D1, **pero dejaría sin investigar las dimensiones D2, D3 y D4**, cuya cobertura en el corpus es débil o prácticamente nula. Una agenda que solo abordará la segunda limitación (la Propuesta B) generaría marcos teóricos y evidencia organizativa sin el anclaje empírico que proporcionan los estudios de rendimiento técnico en contextos concretos. La coexistencia de ambas propuestas no refleja ambigüedad sobre qué es más importante: refleja que ambas son necesarias y que ninguna puede sustituir a la otra.

La Propuesta A se posiciona en la intersección de D1 y la brecha de transferibilidad contextual: su objeto es determinar si los modelos de IA producen ganancias predictivas documentadas en el forecasting de ventas de empresas de software B2B, bajo qué condiciones técnicas y con qué peculiaridades metodológicas derivadas de la estructura singular de ese sector. La Propuesta B se posiciona en la intersección de D2, D3 y D4: su objeto es construir los instrumentos conceptuales y la evidencia empírica necesarios para explicar cómo y bajo qué condiciones organizativas el forecasting algorítmico genera valor más allá de la métrica de error. Esa distribución de objetos no es arbitraria: responde exactamente a los dos tipos de silencio que la revisión ha diagnosticado, el empírico-contextual y el teórico-organizativo.

4.4. Propuesta doctoral A: precisión del forecasting con ia en empresas de software B2B




Figura 10 - Cronograma de propuesta doctoral A a 24 meses (elaboración propia)

Título tentativo: Inteligencia artificial aplicada al forecasting de ventas en empresas de software B2B: modelos, condiciones de rendimiento y validación en entornos de producción.

Justificación:

El software B2B y el software empresarial (ERP, CRM, plataformas SaaS, herramientas de automatización de ventas y marketing) configuran uno de los segmentos de mayor crecimiento en la economía digital global. Sus procesos comerciales presentan características que los distinguen estructuralmente de los contextos que dominan el corpus

revisado. Los ciclos de venta son largos (habitualmente de tres a dieciocho meses), multifásicos y dependientes de un número reducido de cuentas de alto valor medio. El proceso de compra implica múltiples actores en el lado del cliente (sponsor económico, usuario técnico, departamento de TI, dirección general), lo que introduce una complejidad decisional que ningún modelo univariado puede capturar. La estructura del pipeline comercial en estas empresas distingue habitualmente entre etapas de cualificación, demostración, propuesta, negociación y cierre, y cada etapa tiene una probabilidad de conversión diferente que depende del comportamiento histórico de cuentas similares, de la presencia o ausencia de competidores, del presupuesto reservado por el cliente y de la intensidad de la interacción reciente. Las métricas de renovación y expansión (churn de licencias, upsell, cross-sell, expansión de contrato) añaden una dimensión predictiva adicional sin equivalente directo en la manufactura o la distribución.

Ninguno de los veinte artículos del corpus aborda este contexto. La única excepción parcial es Bohanec et al. (2017), que trabaja con datos CRM de una empresa de software de tamaño mediano en Eslovenia, pero cuyo foco primario es la explicabilidad del modelo y no el rendimiento predictivo en sí. Rezazadeh (2020) trabaja con datos de una consultora B2B global, un perfil que comparte rasgos con el software empresarial, pero cuyas categorías de cuenta (energía, salud, servicios financieros) son sectorialmente distintas. La brecha es, por tanto, real y documentable: el sector que mayor relevancia práctica puede tener para la adopción empresarial de sistemas de forecasting algorítmico es precisamente el que la literatura ha ignorado de forma más sistemática.

Pregunta principal de investigación:

¿En qué medida los modelos de inteligencia artificial mejoran la precisión del forecasting de ventas en empresas de software B2B respecto a enfoques estadísticos convencionales y al juicio experto de los equipos comerciales, y bajo qué condiciones técnicas (calidad de datos CRM, estructura del pipeline, profundidad del historial de cuenta) resulta esa mejora estadísticamente robusta y organizativamente transferible?

Objetivos específicos:

1. Identificar y caracterizar las fuentes de datos disponibles en empresas de software B2B para el forecasting de ventas (datos CRM, etapas del pipeline, historial de interacciones, datos de renovación y expansión, señales de comportamiento digital).
2. Diseñar y comparar modelos de IA de distintas familias arquitectónicas (machine learning supervisado clásico, ensamblados, redes de grafos) para la predicción de conversión de oportunidades y del volumen de ventas trimestral.
3. Evaluar el rendimiento de los modelos mediante validación temporal estricta y comparación con líneas base estadísticas y con el forecast humano de los equipos comerciales.
4. Analizar en qué condiciones de calidad de datos, profundidad de historial y estructura de pipeline los modelos de IA producen mejoras predictivas estadísticamente significativas y prácticamente relevantes.
5. Identificar barreras de implantación específicas del contexto del software B2B (rotación de cuentas, cambios de estrategia de producto, heterogeneidad de ciclos de venta) que condicionan la transferibilidad del modelo.

Hipótesis:

- H1. Los modelos de aprendizaje automático supervisado (ensamblados basados en árboles y redes de grafos sobre datos CRM) producen mayor capacidad discriminante en la predicción de conversión de oportunidades, medida por AUC y F1, que los modelos estadísticos de referencia en contextos de software B2B.
- H2. Las variables relacionales del CRM (historial de interacciones, tiempo en etapa, número de actores en el proceso de compra) tienen mayor capacidad predictiva incremental sobre el resultado de la oportunidad que las variables macroeconómicas exógenas en el contexto del software B2B.
- H3. El rendimiento de los modelos entrenados sobre datos históricos de CRM experimenta una degradación estadísticamente detectable cuando se evalúa en producción sobre oportunidades no observadas durante el entrenamiento.

- H4. La ventaja predictiva del modelo algorítmico sobre el forecast subjetivo de los comerciales se atenúa en el subconjunto de oportunidades de alto valor unitario, donde la información relacional no capturada por el modelo reduce el diferencial de exactitud.

Diseño de la investigación:

El diseño propuesto combina un componente empírico cuantitativo con un análisis de condiciones de validez. El acceso a datos requiere acuerdos de colaboración con una o varias empresas de software B2B que dispongan de sistema CRM con historial estructurado de oportunidades cerradas (ganadas o perdidas), con un mínimo de 1.000 registros para garantizar potencia estadística mínima en los modelos de clasificación.

Las fases metodológicas incluirían: (1) extracción y limpieza de datos CRM, con documentación del protocolo de gobernanza y de las decisiones de imputación y codificación de variables; (2) ingeniería de características orientada a capturar la estructura temporal y relacional del pipeline (tiempo en cada etapa, ratio de avance entre etapas, frecuencia de interacción, señales de comportamiento digital del cliente); (3) entrenamiento y validación temporal con separación estricta entre períodos de entrenamiento y evaluación, evitando cualquier forma de data leakage; (4) comparación entre modelos de IA y líneas base estadísticas (regresión logística, modelo naive de tasa histórica de conversión) y entre modelos de IA y el forecast introducido manualmente por los comerciales en el CRM (línea base humana, análoga a la empleada por Rezazadeh, 2020); (5) análisis de condiciones de validez que identifique las características del contexto (profundidad de historial, tasa de renovación, velocidad del pipeline) que predicen la magnitud de la mejora obtenida; (6) despliegue en producción durante al menos seis meses para obtener validación longitudinal.

Las métricas principales serían AUC y F1 para la predicción de conversión (tarea de clasificación binaria), y MAPE y RMSE para la predicción de volumen trimestral de ventas (tarea de regresión). La evaluación de la precisión monetaria añadiría relevancia práctica a los resultados estadísticos. Los protocolos de gobernanza de datos y las salvaguardas éticas incluirían anonimización de cuentas y vendedores, acuerdos de confidencialidad y revisión de sesgo en las variables de entrada.

La plausibilidad de este diseño no depende de ningún supuesto extraordinario. El tipo de datos requerido (registros CRM de oportunidades cerradas con variables de pipeline) es estándar en las empresas de software B2B que operan con sistemas como Salesforce, HubSpot o Microsoft Dynamics. La colaboración entre universidades y empresas de software para investigación sobre forecasting y analítica comercial tiene precedentes documentados en la literatura, y el perfil de datos necesario es considerablemente menos sensible que el requerido por estudios en salud, finanzas o defensa.

Contribución esperada:

La contribución principal de esta propuesta es la generación de la primera evidencia sistemática sobre el rendimiento de los modelos de IA en el forecasting de ventas en el sector del software B2B, con comparación explícita contra el juicio experto humano y validación longitudinal en producción. Esa contribución responde directamente al vacío de transferibilidad contextual identificado en la sección 3.7 y permite determinar si las conclusiones del corpus revisado son aplicables a un sector con estructura de datos y dinámica de ventas fundamentalmente distintas.

La propuesta ofrece, adicionalmente, una contribución metodológica al campo: el diseño de validación en producción, raramente implementado en la literatura existente, proporciona un estándar más riguroso para la evaluación del valor real de los sistemas de forecasting algorítmico.

Condiciones de viabilidad y riesgos:

La viabilidad principal depende del acceso a datos CRM estructurados de empresas colaboradoras. Ese acceso es el principal factor de riesgo: las empresas de software pueden ser reacias a compartir datos de pipeline por razones de competitividad o de cumplimiento normativo. Una estrategia de mitigación consiste en diseñar el protocolo de acceso de forma que los datos permanezcan en las instalaciones de la empresa y el investigador solo acceda a conjuntos anonimizados.

Un segundo riesgo es la heterogeneidad inter-organizacional: si el estudio se realiza sobre una única empresa, la generalización de los resultados queda restringida por definición, repitiendo la limitación más frecuente del corpus. El diseño multi-empresa es el que permite comparar los resultados entre contextos e identificar las variables moderadoras que condicionan la magnitud de la mejora.

4.5. Propuesta doctoral B: interpretabilidad, confianza y adopción organizativa del forecasting algorítmico en B2B




Figura 11 - Cronograma de propuesta doctoral B a 26 meses (elaboración propia)

Título tentativo: Del modelo al directivo: explicabilidad, confianza algorítmica y gestión del cambio en la adopción del forecasting algorítmico en organizaciones de venta B2B.

Justificación:

La literatura técnica sobre IA en forecasting de ventas B2B ha optimizado sin interrupción las métricas de error predictivo. La dimensión D1 del marco analítico tiene cobertura sólida. Las dimensiones D2, D3 y D4, en cambio, constituyen un espacio de investigación prácticamente no explorado que determina, de manera más directa que la precisión del modelo, si una organización adopta el forecasting algorítmico, lo utiliza de forma sostenida y obtiene de él un valor comercial verificable.

La razón por la que un directivo comercial confía o no confía en la predicción de un modelo de IA no se puede explicar mediante métricas de AUC o MAPE. Se puede explicar, en cambio, mediante la percepción de utilidad y facilidad de uso que articulan los marcos TAM y UTAUT (Davis, 1989; Venkatesh et al., 2003), mediante la comprensión de las variables que han generado esa predicción (que la investigación sobre XAI ha teorizado con creciente rigor), y mediante las condiciones organizativas que facilitan o dificultan la integración del sistema en las rutinas del equipo comercial. El corpus revisado no conecta ninguno de esos planos: presenta modelos que mejoran el forecast y descripciones fragmentarias de barreras de implantación, pero no ofrece el puente conceptual entre ambos. Construir ese puente es el objeto de esta propuesta.

El caso de Bohanec et al. (2017) es especialmente revelador en este sentido. Los autores construyen el sistema EXPLAINIME para hacer auditables las predicciones de un modelo de Random Forest, y demuestran que los usuarios de negocio pueden validar sus supuestos, identificar patrones de éxito y fracaso, y tomar decisiones fundamentadas sobre oportunidades de venta abiertas. Pero el estudio no mide ni analiza cómo cambia la confianza del equipo comercial en el modelo tras el acceso a esas explicaciones, ni si la calidad de las decisiones mejora de forma verificable. Esa distancia entre la demostración técnica de la explicabilidad y la medición de su impacto organizativo es el espacio de investigación que esta propuesta habita.

Pregunta principal de investigación:

¿A través de qué mecanismos la explicabilidad de los modelos de IA aplicados al forecasting de ventas B2B modifica la confianza de los directivos comerciales en esos modelos, y en qué condiciones organizativas (madurez de forecasting, cultura de datos, estructura del equipo de ventas, apoyo directivo) esa confianza se traduce en adopción sostenida y en mejora verificable de las decisiones comerciales?

Objetivos específicos:

1. Desarrollar y validar un constructo de confianza algorítmica en el forecasting B2B, diferenciando sus dimensiones cognitivas (comprensión del modelo), afectivas (disposición a delegar el juicio en el modelo) y conductuales (uso efectivo del forecast en la toma de decisiones).
2. Analizar el efecto de distintos niveles de explicabilidad del forecast (sin explicación, con importancia de variables, con análisis de escenarios what-if) sobre la confianza declarada y el uso efectivo del modelo en muestras de directivos comerciales B2B.
3. Construir y validar un marco de madurez organizativa para el forecasting algorítmico en B2B, que permita tipificar a las organizaciones según su capacidad de absorción, integración y explotación de los sistemas de previsión basados en IA.
4. Analizar la relación entre el nivel de madurez organizativa de forecasting y el éxito percibido de la implantación del sistema de IA, medido tanto en términos de adopción individual como de impacto sobre la calidad de las decisiones comerciales.
5. Proporcionar una estimación estructurada del retorno sobre la inversión (ROI) de la implantación de sistemas de forecasting algorítmico en organizaciones B2B, integrando costes de implantación, mantenimiento, reentrenamiento y coste de los errores de predicción con los beneficios derivados de la mejora de la planificación comercial.

Hipótesis:

- **H1.** La exposición a forecasts con explicaciones de importancia de variables incrementa la confianza declarada en el modelo y la intención de uso respecto a la exposición a predicciones sin explicación, en un diseño experimental entre sujetos con directivos comerciales B2B.
- **H2.** El efecto de la explicabilidad sobre la confianza está moderado por la madurez de forecasting de la organización, de forma que ese efecto es significativo en organizaciones con cultura de datos consolidada y se atenúa en organizaciones con madurez baja.
- **H3.** La adopción sostenida del forecasting algorítmico está asociada positivamente con la presencia de patrocinio directivo explícito, la existencia de un protocolo estructurado de revisión del forecast y la disponibilidad de formación específica para el equipo comercial.
- **H4.** La relación entre madurez organizativa de forecasting y ROI de la implantación no es monotónica: las organizaciones con mayor madurez obtienen mayores beneficios estimados, pero también incurren en mayores costes de transición, lo que produce un perfil de retorno no lineal.

Diseño metodológico:

El diseño propuesto es de naturaleza mixta, integrando fases cualitativas y cuantitativas en secuencia que permite que cada fase informe a la siguiente.

La primera fase es de carácter exploratorio cualitativo: entrevistas semiestructuradas con directivos comerciales y responsables de analítica de ventas en empresas B2B de distintos sectores y tamaños, con el objetivo de identificar las dimensiones relevantes de la confianza algorítmica en forecasting, las barreras organizativas de mayor consistencia y las condiciones que los propios actores asocian con el éxito de la implantación. Esta fase alimenta el desarrollo y la validación del constructo de confianza algorítmica y del marco de madurez. La segunda fase es experimental: diseño de experimentos de tipo survey-experiment en muestras de directivos comerciales o estudiantes de MBA con experiencia comercial, comparando distintas condiciones de presentación del forecast (sin explicación; con importancia de variables globales; con análisis what-if para la oportunidad específica). Las variables dependientes incluyen confianza declarada, intención de uso y calidad de la decisión comercial en escenarios controlados.

La tercera fase es de encuesta cuantitativa a una muestra de organizaciones B2B, orientada a validar el constructo de confianza algorítmica y el instrumento de madurez de forecasting, a analizar las relaciones entre madurez, confianza, adopción e impacto percibido, y a recoger datos para el análisis ROI estructurado. La cuarta fase, opcional según los recursos disponibles, consiste en un estudio de casos longitudinal en dos o tres organizaciones B2B en proceso de implantación de un sistema de forecasting algorítmico, con observación de los procesos de cambio organizativo durante 12–18 meses. Esta fase permitiría validar los marcos conceptuales generados en las fases anteriores en condiciones de mayor naturalismo.

Contribución esperada:

La contribución principal de esta propuesta es la construcción de tres instrumentos conceptuales que el corpus revisado no ha producido: el constructo de confianza algorítmica en el forecasting B2B, el marco de madurez organizativa para el forecasting algorítmico y la primera estimación estructurada del ROI de implantación en el sector B2B. Estos instrumentos no solo llenan vacíos teóricos específicos: articulan un marco integrador que conecta la dimensión técnica de la precisión (D1) con las dimensiones organizativas de la interpretabilidad, la adopción y el cambio (D2–D4), resolviendo la desconexión estructural más profunda que la revisión ha diagnosticado.

La propuesta tiene, además, una contribución metodológica: el diseño mixto que combina experimentos de XAI, encuesta organizativa y estudio longitudinal de cambio ofrece un modelo de investigación replicable para investigadores que trabajan en la intersección de la analítica empresarial y el comportamiento organizativo.

Condiciones de viabilidad y riesgos:

El riesgo principal es el acceso a muestras de directivos comerciales con experiencia suficiente en el uso de sistemas de forecast. Las encuestas a directivos tienen tasas de respuesta bajas en investigación académica, lo que puede comprometer el poder estadístico de los análisis cuantitativos. La mitigación pasa por el establecimiento de colaboraciones con asociaciones sectoriales de ventas B2B o con programas de formación ejecutiva. Un segundo riesgo es la complejidad del diseño longitudinal de la cuarta fase, cuyo carácter opcional en el diseño propuesto permite que la investigación doctoral sea viable incluso si esa fase no puede implementarse completamente. Un tercer riesgo conceptual es la posible inestabilidad del constructo de confianza algorítmica: si sus dimensiones cognitiva, afectiva y conductual muestran baja convergencia en la validación, el constructo deberá ser rediseñado o desagregado. Ese riesgo es inherente a toda investigación que propone constructos nuevos y se gestiona mediante una fase exploratoria cualitativa suficientemente densa antes de comprometerse con el instrumento cuantitativo definitivo.

4.6. Contribución integradora y cierre de la agenda

Este trabajo no ha pretendido resolver los problemas que ha cartografiado. Ha pretendido algo más modesto y, en cierto sentido, más útil para el avance del campo: construir la documentación analítica que hace posible formular esos problemas con la precisión necesaria para abordarlos en una investigación posterior. La diferencia entre ambas pretensiones no es de grado sino de función: una revisión sistemática que culmina en agenda doctoral no es un sustituto de la investigación empírica, sino su precondition más rigurosa.

La contribución del presente trabajo opera en tres planos. El primero es **documental**: el corpus de veinte artículos, seleccionado mediante un protocolo explícito y reproducible a partir de 3.121 registros iniciales, constituye la base bibliográfica más sistemática disponible en español sobre inteligencia artificial aplicada al forecasting de ventas en entornos B2B. El segundo plano es **analítico**: el marco de cuatro dimensiones (D1 a D4) y la taxonomía de tres familias metodológicas proporcionan instrumentos de ordenación que permiten comparar estudios de épocas, sectores y diseños muy distintos bajo una estructura conceptual común. El tercer plano, directamente **doctoral**, es el diagnóstico de vacíos: la identificación de los dos déficits estructurales del campo, el de transferibilidad contextual al software B2B y el de traducción de la ganancia predictiva en valor organizativo, proporciona los fundamentos documentales para las dos propuestas de investigación doctoral cuya pertinencia está anclada en evidencia y no en preferencias temáticas del investigador.

Los dos déficits no tienen el mismo tipo de consecuencia para la práctica. El déficit de transferibilidad contextual limita la aplicabilidad de las conclusiones disponibles a los profesionales de sectores subrepresentados: una empresa de software B2B que busca en la literatura académica evidencia sobre qué modelo de IA debería adoptar para mejorar su forecasting de ventas no encontrará ningún estudio que hable directamente de su contexto. El déficit de traducción organizativa es más profundo: incluso las organizaciones que operan en los sectores mejor representados del corpus carecen de marcos conceptuales que les permitan gestionar la adopción, evaluar el ROI o diagnosticar su madurez para el forecasting algorítmico.

El campo ha producido, a lo largo de casi dos décadas de investigación documentada en este corpus, una evidencia técnica genuinamente acumulativa sobre la capacidad de los modelos de IA para mejorar el forecasting de ventas B2B. Esa acumulación tiene valor. El análisis comparativo entre las redes neuronales difusas evolutivas de Chang et al. (2007) y las redes de convolución espectral sobre grafos de Henna et al. (2025) muestra un progreso técnico real en dieciocho años de investigación. Pero ese progreso técnico coexiste con un estancamiento teórico-organizativo documentable: las preguntas sobre cómo las organizaciones absorben y explotan ese progreso, qué condiciones hacen que la mejora predictiva se convierta en mejor planificación comercial, y qué coste tiene la implantación en relación con el valor que genera, siguen sin respuesta en la literatura. Reconocer ese estancamiento con precisión, cómo hace este trabajo, es la condición necesaria para superarlo.

5. LIMITACIONES DEL ESTUDIO REALIZADO

Toda investigación de alcance definido produce, al completarse, un mapa de sus propias fronteras. El presente capítulo traza ese mapa. Se identifican y analizan las restricciones que condicionan el valor epistémico de esta revisión sistemática: qué afirmaciones sostiene con rigor demostrable, cuáles descansan en inferencias plausibles pero no verificadas, y cuáles quedan fuera del alcance de la evidencia disponible. El análisis opera sobre cuatro niveles jerárquicos que se articulan entre sí en sentido descendente: limitaciones del corpus y la muestra (L1), del alcance analítico (L2), del marco teórico propio del trabajo (L3), y de la transferibilidad contextual de las conclusiones (L4).



Figura 12 - Cadena jerárquica de limitaciones del presente estudio (elaboración propia)

5.1 Alcance y tipología de las limitaciones identificadas

Las limitaciones de una revisión sistemática no son síntomas de debilidad metodológica. Son, de forma más precisa, el instrumento mediante el cual **la investigación define el perímetro de sus afirmaciones y señala las condiciones bajo las cuales sus conclusiones pueden generalizarse** y, con la misma importancia, las condiciones bajo las cuales no pueden hacerlo. Omitirlas o presentarlas como incidencias menores equivale a inflar artificialmente la solidez de los resultados, un vicio que la metodología de revisión sistemática combate de forma estructural al exigir transparencia sobre el protocolo, la muestra y los límites del análisis (Tranfield et al., 2003).

La distinción operativa que organiza este capítulo separa dos planos que a menudo se confunden. La Sección 2.8 documentó las limitaciones del protocolo de selección: las decisiones adoptadas durante el diseño de la búsqueda, los filtros aplicados y las restricciones que condicionaron la construcción del corpus. Su función era procesal (justificar, con criterios explícitos, las opciones metodológicas adoptadas durante las fases 0 a 4). El presente capítulo evalúa el trabajo terminado desde una posición exterior.

Identifica lo que esta revisión, como estudio completo, no puede sostener, no puede demostrar o no puede transferir con las garantías que la práctica científica exige. Son niveles de análisis distintos: la Sección 2.8 mira hacia el interior del protocolo; este capítulo mira hacia el exterior del estudio.

La cadena de dependencia entre ambos niveles **opera en sentido descendente**. Las restricciones del protocolo (Sección 2.8) generan restricciones en el corpus resultante (L1). Las restricciones del corpus condicionan el alcance del análisis que puede construirse sobre él (L2). Las restricciones analíticas determinan los límites del marco teórico que el trabajo propone como contribución propia (L3). Los límites teóricos, combinados con las asimetrías sectoriales del corpus, definen el perímetro de la transferibilidad contextual (L4). Esa cadena no es circular. Es la estructura que permite leer este capítulo como un diagnóstico coherente y no como un inventario desconectado de precauciones.

No todas las limitaciones aquí identificadas tienen el mismo origen ni remedio. Algunas son mitigables mediante mejoras de diseño en investigaciones futuras (la ausencia de un segundo revisor, la restricción a dos bases de datos). Otras son estructurales al tipo de investigación realizado: una revisión sistemática cualitativa sin benchmark compartido en el campo no puede producir metanálisis cuantitativos, con independencia de las decisiones del investigador. La distinción entre limitación corregible y limitación inherente al tipo de estudio es tan relevante para la interpretación de los resultados como la propia identificación de las limitaciones.

5.2 Limitaciones del corpus y la muestra bibliográfica

Aunque ya se trataron en la sección 2.8, cabe resaltar que **la muestra de veinte artículos no pretende ser exhaustiva**. Lo que sí pretende, y lo que el protocolo PRISMA-2020 garantiza formalmente, es ser representativa del espacio bibliográfico indexado en Scopus y Web of Science sobre inteligencia artificial aplicada al forecasting de ventas en contextos B2B (Page et al., 2021). Esa distinción (entre exhaustividad inalcanzable y representatividad metodológicamente verificable) no es un recurso retórico para neutralizar la crítica; es la condición de posibilidad de cualquier revisión sistemática sobre un campo activo donde la producción científica crece a un ritmo que supera la capacidad individual de procesarla (Snyder, 2019).

Sin embargo, la representatividad de lo indexado en dos bases de datos no equivale a representatividad del campo en su conjunto. La restricción a Scopus y WoS documentada en la Sección 2.8 excluye publicaciones indexadas únicamente en IEEE Xplore, ACM Digital Library o EBSCO. La decisión fue asumida como equilibrio entre cobertura y manejabilidad del protocolo, pero sus consecuencias sobre la composición de la muestra no son cuantificables retrospectivamente: requeriría ejecutar un protocolo paralelo con idénticos descriptores en esas bases para medir el solapamiento y el sesgo. Toda la producción académica presentada en conferencias IEEE y ACM sobre IA aplicada a pipelines comerciales, predicción de probabilidad de cierre en CRM o modelos de conversión de oportunidades queda sistemáticamente fuera del corpus sobre el que se construyen las Secciones 3 y 4. El volumen y la dirección de ese sesgo permanecen indeterminados.

La preferencia por fuentes en lengua inglesa, heredada estructuralmente de las bases de datos utilizadas, genera un sesgo de cobertura lingüística que esta revisión no puede corregir. La producción académica alemana, francesa y española sobre CRM analítico, forecasting en distribución industrial y gestión del pipeline en empresas de software B2B europeas permanece fuera del corpus. La relevancia de esa ausencia no es menor: el contexto focal de la pregunta de investigación (mercados europeos de software empresarial B2B) dispone de una producción académica en lenguas distintas al inglés que esta revisión no incorpora. Las conclusiones sobre el sector focal del TFM carecen, en consecuencia, del respaldo de su propia literatura regional.

Hay una asimetría epistemológica adicional que el sistema de puntuación ponderada mitiga parcialmente sin llegar a neutralizar. Los seis artículos del período 2024-2025 (Chen, 2025; Huang et al., 2025; Henna et al., 2025; Jovanovic et al., 2025; Wang et al., 2025; Pekkaya & Uysal, 2024) presentan adecuación temática máxima y calidad editorial predominantemente Q1. Su influencia acumulada en el momento de la consulta es, sin embargo, mínima o nula. Técnicamente avanzados, epidémicamente incipientes. La validación colectiva del campo (la citación sostenida que convierte un hallazgo en resultado consolidado) no ha tenido tiempo de operar sobre esos trabajos. Las conclusiones que descansan principalmente en ese subconjunto reciente tienen el estatus de indicios de alta relevancia temática, no de evidencia acumulada: una distinción que la lectura de la Sección 3 debe preservar.

La sobrerrepresentación de la manufactura electrónica asiática condiciona de forma estructural el perfil empírico sobre el que se construyen los hallazgos del trabajo. Diez de los veinte artículos provienen de Taiwán o China; los sectores dominantes (PCB, distribución mayorista de componentes, electrónica industrial) generan datos de alta densidad transaccional, ciclos de venta cortos y demanda relativamente estable. Esa clase de datos produce condiciones de modelado favorables para los algoritmos de forecasting que el corpus evalúa. La inferencia no es que esos modelos funcionen igual en un entorno de venta consultiva de software ERP con ciclos de 9 a 18 meses; la inferencia es que el corpus no prueba que funcionen de otra manera. La distinción entre ambas lecturas es la que separa una conclusión rigurosa de una extrapolación no autorizada.

5.3 Limitaciones del alcance analítico

La síntesis cualitativa es el **único método de análisis que la estructura del corpus permite aplicar**. No se trata de una elección metodológica evitable. La heterogeneidad de datos, métricas y baselines entre los veinte estudios hace materialmente imposible la síntesis cuantitativa mediante metanálisis: cada artículo define su propio problema de forecasting, establece sus propios criterios de rendimiento y reporta bajo condiciones de comparación que no son equivalentes entre estudios. Esa imposibilidad no es un déficit de diseño de esta revisión, sino una restricción estructural del campo documentada en la Sección 3.7 (ausencia de benchmark público compartido). Lo que sí constituye una limitación del alcance analítico es su consecuencia directa: los patrones comparativos identificados en la Sección 3 tienen estatus de convergencias cualitativas, no de generalizaciones estadísticas verificadas. La diferencia importa cuando las Propuestas Doctorales de la Sección 4 se leen como conclusiones del trabajo.

La codificación temática fue ejecutada por un único revisor. El peso más sensible del protocolo, la dimensión AP (50% del total en la selección final), fue evaluado mediante lectura directa y aplicación de una escala operativa de cinco niveles sin contraste externo. La ausencia de un coeficiente de concordancia interobservador (el kappa de Cohen como estándar metodológico habitual en revisiones sistemáticas) es un déficit formal del proceso que afecta a la reproducibilidad de dos elementos encadenados: primero, la selección de los veinte artículos que componen el corpus; segundo, la codificación de cada artículo bajo las dimensiones D1-D4. Ambas operaciones dependen del juicio del revisor. La Sección 2.8 ya reconoció esa limitación en el plano del protocolo; sus efectos se extienden aquí hacia el análisis. Un segundo revisor independiente podría producir tanto una muestra como una clasificación temática parcialmente distintas.

La cobertura dimensional es marcadamente asimétrica. D1 (precisión predictiva) está respaldada por los veinte artículos: las Secciones 3.3 y 3.5 producen conclusiones con densidad empírica suficiente para sostener afirmaciones comparativas. D2 (interpretabilidad y explicabilidad) tiene cobertura parcial. D3 (adopción tecnológica) descansa en cuatro estudios con evidencia directa y en inferencias transversales sobre el resto. D4 (gestión del cambio organizativo) carece de evidencia primaria en el corpus: ningún artículo la estudia como objeto de investigación. El análisis disponible sobre D4 es inferencial y apoyado en marcos externos (Kotter, 1996; Armenakis et al., 1993), no en hallazgos empíricos del corpus. La solidez de las afirmaciones de la Sección 3 decrece de forma monótona de D1 a D4, y esa gradación debe presidir la lectura de cualquier conclusión que las involucre.

Existe una limitación adicional que tiene carácter autorreferencial. El marco analítico D1-D4 es una construcción del propio revisor, no una taxonomía extraída del corpus ni validada por paneles de expertos. Que su aplicación produzca resultados coherentes con la pregunta de investigación no demuestra su corrección como sistema de categorías: puede simplemente reflejar que las categorías de lectura determinan, en parte, lo que se lee. Esa circularidad potencial no invalida el análisis, pero sí restringe el alcance demostrativo del marco. Su estatus epistémico correcto es el de instrumento heurístico de productividad analítica reconocida, no el de constructo validado.

5.4 Limitaciones teóricas y conceptuales

Cuatro ausencias teóricas condicionan de forma sustantiva las conclusiones de las Secciones 3 y 4. Ninguna de ellas es imputable al diseño del protocolo; son restricciones derivadas de la estructura del campo que esta revisión no puede corregir con sus propios recursos.

La tipología de madurez organizativa carece de validación empírica. Los tres estadios identificados en la Sección 3.5 (organizaciones en estadio de juicio subjetivo, de estadística básica preexistente, y de datos ricos con gobernanza deficiente) son una contribución interpretativa construida comparando los perfiles de contexto organizativo que Monat (2011), Rezazadeh (2020), Sohrabpour et al. (2021) y Rohaan et al. (2022) describen de forma fragmentaria en sus secciones de limitaciones y trabajo futuro. Esa tipología no fue extraída inductivamente del corpus mediante un proceso de codificación formalizado, ni contrastada con un segundo revisor, ni validada mediante consulta a paneles de expertos. Su estatus correcto es el de hipótesis interpretativa con utilidad analítica documentada en el contexto de esta revisión. Las afirmaciones de las Secciones 3 y 4 que descansan sobre esa tipología tienen carácter propositivo, no demostrativo.

La brecha entre precisión estadística y calidad decisional no dispone de un modelo explicativo. Bohanec et al. (2017) y Rohaan et al. (2022) documentan empíricamente que una mejora técnica verificada no se traduce automáticamente en adopción ni en valor organizativo: el primero porque los directivos rechazaron inicialmente el modelo de caja negra; el segundo porque las barreras de gobernanza de datos limitaron la explotación real del modelo. Esa brecha es un hallazgo empírico del corpus. Lo que el corpus no proporciona es un mecanismo causal que explique bajo qué condiciones la traducción ocurre y bajo cuáles falla. La revisión puede constatar la brecha. No puede explicarla. Las afirmaciones de la Sección 3.6 sobre la cadena precisión-decisión-valor son diagnósticas, no explicativas; se apoyan en la observación de patrones, no en la especificación de mecanismos.

El constructo de confianza algorítmica en contextos B2B no está formalizado. Los factores que determinan si un directivo comercial delega su juicio en un modelo de IA (variables psicológicas, jerárquicas y culturales) aparecen en el corpus de forma anecdótica. Bohanec et al. (2017) los documentan en un único caso esloveno; ningún otro artículo los tematiza como objeto de estudio. La Sección 2 incorpora la Teoría de Aceptación Tecnológica (Davis, 1989) y el modelo UTAUT (Venkatesh et al., 2003) como marcos de apoyo interpretativo, pero ninguno de ellos fue diseñado para el fenómeno específico de la delegación de juicio comercial en sistemas algorítmicos de predicción. La transferencia de esos constructos a este contexto es una decisión interpretativa de la revisión, no una aplicación validada. Las afirmaciones sobre barreras de adopción relativas a la confianza del directivo tienen, en consecuencia, respaldo empírico en un único estudio y apoyo teórico en marcos de segunda derivada.

La ausencia de análisis coste-beneficio en el corpus deja sin respuesta la pregunta empresarialmente decisiva. Ninguno de los veinte artículos calcula o estima el retorno sobre la inversión de implantar un sistema de forecasting con IA: el coste de desarrollo, implantación, mantenimiento y reentrenamiento, frente al beneficio económico de la mejora de precisión. Esa ausencia persiste durante los dieciocho años del período analizado (2007-2025) y es transversal a todos los sectores representados. La revisión puede señalar su existencia y sus consecuencias para la práctica empresarial; no puede cubrirla con sus propios datos porque esa información no está en el corpus. Las Propuestas Doctorales de la Sección 4 identifican ese vacío como línea de investigación prioritaria; en el presente capítulo interesa subrayar que cualquier conclusión de este TFM sobre la viabilidad económica de la adopción de IA para el forecasting B2B es de carácter normativo, no empírico.

5.5 Limitaciones de transferibilidad contextual

El corpus está **dominado por contextos de manufactura de alta densidad transaccional**. Diez de los veinte artículos provienen de Taiwán o China; los sectores representados (PCB, componentes electrónicos industriales, distribución mayorista de maquinaria) generan series de pedidos con cientos o miles de observaciones mensuales por producto, ciclos de reposición cortos y demanda relativamente estabilizada por contratos marco. Esas condiciones son estructuralmente favorables para los modelos de forecasting evaluados en el corpus: el volumen de

datos reduce el riesgo de sobreajuste, la regularidad de los patrones facilita el aprendizaje secuencial y la variable objetivo (unidades vendidas por referencia) es directamente observable sin ambigüedad. Las conclusiones de las Secciones 3 y 4 sobre qué arquitecturas producen mejoras de precisión y bajo qué condiciones reflejan, ante todo, ese perfil empírico. Su transferibilidad a otros entornos B2B donde esas condiciones no se reproducen es plausible como hipótesis; no está demostrada como resultado.

Los entornos B2B de ciclo largo y alta complejidad relacional presentan características estructurales que el corpus no modela. La distribución industrial con alta variabilidad de la demanda, los servicios profesionales con proyectos discontinuos y presupuesto negociado por encargo, o cualquier contexto donde la unidad de análisis sea la oportunidad individual y no la serie de transacciones agregadas introducen variables que las arquitecturas del corpus no fueron diseñadas para capturar: señales de pipeline en CRM con campos heterogéneamente cumplimentados, múltiples decisores con pesos cambiantes a lo largo del proceso, y alta dependencia del componente relacional entre vendedor y cuenta. La distancia estructural entre esos entornos y los registros de pedidos de una distribuidora neerlandesa de recambios industriales (Rohaani et al., 2022) o las series mensuales de una fábrica taiwanesa de PCB (Chang et al., 2007) no invalida la extrapolación, pero sí la condiciona. Plausibilidad no es evidencia.

La dimensión D4 presenta el caso más severo. Las observaciones de esta revisión sobre gestión del cambio organizativo en la adopción de IA para el forecasting son inferencias construidas sobre la ausencia de evidencia primaria en el corpus y sobre marcos teóricos externos (Kotter, 1996; Armenakis et al., 1993) que no fueron diseñados para este fenómeno específico. El presente trabajo no puede formular afirmaciones sustantivas sobre cómo reaccionan los equipos comerciales ante la introducción de un modelo de predicción algorítmico, qué tipos de resistencia surgen o qué capacidades organizativas se requieren para la adopción sostenida. Que D4 esté prácticamente ausente del corpus no autoriza la inferencia de que la gestión del cambio sea irrelevante o sencilla en estos contextos. Autoriza, con mayor precisión, una inferencia sobre el campo: la investigación no ha producido metodologías adecuadas para estudiarla. Es un vacío estructural de la disciplina, no un defecto de este TFM.

La fragmentación geográfica introduce un factor de confusión adicional sobre la generalidad de los hallazgos organizativos. Los contextos asiáticos que dominan el corpus operan bajo patrones de centralización del control de datos, jerarquía en la toma de decisiones y tolerancia a la opacidad algorítmica que difieren estructuralmente de los entornos corporativos de Europa occidental y Norteamérica. Los hallazgos sobre barreras de calidad de datos son suficientemente consistentes entre contextos dispares (Monat, 2011; Rezazadeh, 2020; Rohaani et al., 2022) como para sugerir cierta robustez transcultural; cuánto de esa consistencia es generalizable y cuánto es convergencia superficial entre culturas organizativas similares en su distancia a los contextos objetivo no puede determinarse sin estudios de transferibilidad explícita que el corpus no contiene.

La extensión temporal del corpus (2007-2025) introduce, por último, una restricción de actualización tecnológica. Catorce de los veinte estudios preceden a la consolidación de los modelos de lenguaje de gran escala y los modelos de fundación como herramientas de análisis aplicado. La arquitectura más avanzada representada son las redes de convolución espectral en grafos (Henna et al., 2025) y las redes recurrentes con descomposición VMD (Jovanovic et al., 2025). Las afirmaciones de este trabajo sobre el techo de precisión alcanzable con IA en el forecasting B2B son conservadoras respecto al estado del arte de 2025-2026: se refieren al conjunto de arquitecturas efectivamente evaluadas en el corpus, no al conjunto de arquitecturas disponibles en el momento de la consulta. La literatura académica indexada va por detrás del desarrollo tecnológico, y esta revisión va por detrás de esa literatura.

5.6 Resumen de las limitaciones

A continuación, una tabla resumen de todas las limitaciones del presente estudio:

Tabla 15 - Limitaciones detectadas del presente estudio por área de impacto

Limitación	Área	Descripción	Impacto	Solucion
<i>Restricción a Scopus y WoS (herencia de Sección 2.8)</i>	Nivel 1: Corpus	Exclusión sistemática de IEEE Xplore, ACM y EBSCO; sesgo no cuantificable sin protocolo paralelo	El corpus omite potencialmente trabajos relevantes de conferencias IEEE/ACM sobre IA en pipelines comerciales; las conclusiones de la Sección 3 se aplican al espacio indexado en Scopus y WoS, no al campo en sentido amplio	Replicar el protocolo en IEEE Xplore y ACM con idénticos descriptores; comparar muestras resultantes para evaluar solapamiento y dirección del sesgo
<i>Ausencia de producción académica europea en lenguas no inglesas</i>	Nivel 1: Corpus	La literatura alemana, francesa y española sobre CRM analítico, forecasting en distribución industrial y gestión del pipeline B2B en mercados europeos queda excluida estructuralmente por la indexación de Scopus y WoS	Los patrones organizativos y las barreras de adopción identificados en el corpus no incorporan la perspectiva de los mercados B2B europeos donde esa producción es más densa; las conclusiones sobre contextos occidentales carecen de respaldo regional propio	Ampliar búsquedas a repositorios nacionales con cobertura multilingue (REDIB, DART-Europe, BASE); incorporar descriptores en español, alemán y francés sobre prévision des ventes B2B y equivalentes
<i>Asimetría temporal: seis artículos 2024-2025 con acumulación citatoria nula o mínima</i>	Nivel 1: Corpus	Los artículos más recientes tienen adecuación temática máxima, pero validación colectiva inexistente en el momento de la consulta	Las conclusiones apoyadas en ese subconjunto tienen estatus de indicios de alta relevancia temática, no de evidencia acumulada	Actualizar la revisión en el horizonte 2027-2028 para evaluar si esos artículos han recibido validación citatoria; ponderar explícitamente la madurez citatoria en síntesis futuras
<i>Sobrerrepresentación de manufactura electrónica asiática</i>	Nivel 1: Corpus	Diez de los veinte estudios provienen de Taiwán o China; el sector dominante (PCB, distribución de componentes) genera condiciones de alta densidad transaccional y ciclo corto que no son representativas del conjunto de entornos B2B	Los hallazgos sobre condiciones para la mejora predictiva reflejan principalmente contextos transaccionales favorables para el modelado; la inferencia a entornos B2B de ciclo largo o alta complejidad relacional es plausible pero no demostrada	Ampliar el corpus con búsquedas específicas en sectores B2B de ciclo largo: distribución con alta variabilidad de demanda, servicios profesionales, proyectos discontinuos con presupuesto negociado

Limitación	Área	Descripción	Impacto	Solución
<i>Sesgo de publicación hacia resultados técnicamente positivos</i>	Nivel 1: Corpus	Las revistas arbitradas indexadas en Scopus y WoS publican sistemáticamente estudios donde el modelo de IA supera al baseline; los veinte artículos del corpus reportan mejoras sin excepción	El valor esperado de la IA para el forecasting B2B que se desprende del corpus puede estar sobreestimado respecto a las condiciones medias reales; los estudios donde el modelo no mejora o donde la implantación fracasó no están representados	Complementar la revisión con literatura gris (informes de consultoras, libros blancos de proveedores CRM, registros de proyectos fallidos) para triangular la tasa de éxito real de la adopción de IA en ventas B2B
<i>Síntesis cualitativa sin posibilidad de metanálisis</i>	Nivel 2: Alcance analítico	La heterogeneidad de métricas y baselines entre los veinte estudios impide la agregación cuantitativa; todas las conclusiones comparativas son narrativas	Las afirmaciones sobre qué arquitecturas funcionan mejor tienen estatus de patrones cualitativos convergentes, no de generalizaciones estadísticas verificadas	El metanálisis requiere primero la creación de un benchmark público compartido para el forecasting de ventas B2B; es una precondition metodológica del campo, no una alternativa de diseño disponible para esta revisión
<i>Revisor único sin coeficiente de concordancia interobservador</i>	Nivel 2: Alcance analítico	La codificación D1-D4 y la evaluación AP (50% del peso de selección) fueron realizadas por un único revisor; no se calculó el kappa de Cohen	La reproducibilidad de la selección de los veinte artículos y de su clasificación temática no está formalmente garantizada; un segundo revisor podría producir corpus y codificación parcialmente distintos	Incorporar al menos un segundo revisor independiente para el 20-25% del corpus en replicaciones futuras; calcular y reportar el kappa de Cohen como estándar de transparencia
<i>Cobertura asimétrica entre dimensiones D1-D4</i>	Nivel 2: Alcance analítico	D1 cubierta por los veinte artículos; D3 por cuatro; D4 por ninguno como objeto primario de investigación; la asimetría es estructural al campo	Las conclusiones sobre precisión predictiva (D1) son sustantivamente más sólidas que las sobre adopción (D3) o gestión del cambio (D4); la gradación de solidez debe presidir la lectura de la Sección 3	La asimetría no es corregible en el marco de una revisión sistemática; requiere investigación primaria con diseños mixtos longitudinales orientados específicamente a D3 y D4

Limitación	Área	Descripción	Impacto	Solucion
Marco D1-D4 construido por el revisor, no validado externamente	Nivel 2: Alcance analítico	El marco analítico no fue extraído inductivamente del corpus ni contrastado con paneles de expertos; las categorías de lectura pueden condicionar lo que se encuentra	Existe un sesgo potencial de estructuración: el análisis puede confirmar la pertinencia del marco más de lo que el corpus justifica de forma independiente	En investigaciones futuras, generar el marco mediante codificación abierta inductiva sobre una submuestra inicial antes de aplicarlo al corpus completo; contrastar con revisores externos
Tipología de madurez organizativa no validada empíricamente	Nivel 3: Teórico- conceptu al	La tipología de tres estadios esbozada en la Sección 3.5 es una contribución interpretativa original de esta revisión, no un constructo establecido ni validado colectivamente	Las interpretaciones sobre por qué mejoras técnicas equivalentes producen impactos organizativos dispares tienen estatus de hipótesis propositiva, no de constructo verificado	Diseñar y validar una escala de madurez de forecasting organizativo mediante metodología Delphi y estudio cuantitativo multi-empresa; articular el constructo con marcos de madurez de analytics ya existentes
Brecha precisión- decisión sin modelo causal	Nivel 3: Teórico- conceptu al	La revisión constata la brecha (documentada por Bohanec et al., 2017, y Rohaan et al., 2022) pero no puede explicar el mecanismo que determina cuándo la mejora técnica se traduce en valor organizativo	Las afirmaciones sobre "utilidad organizativa" de la IA son diagnósticas, no explicativas; la cadena precisión-decisión-valor queda sin especificación del mecanismo causal	Desarrollar un modelo teórico formal de la cadena de valor del forecasting algorítmico; contrastar mediante estudios de campo que midan simultáneamente precisión técnica e impacto sobre calidad decisional
Ausencia de constructo operacionalizable de confianza algorítmica	Nivel 3: Teórico- conceptu al	Los factores que determinan la delegación del juicio comercial en un modelo de IA están documentados anecdóticamente en un único estudio (Bohanec et al., 2017); los marcos TAM y UTAUT son de segunda derivada para este fenómeno	Las afirmaciones sobre barreras de adopción relativas a la confianza del directivo tienen respaldo empírico en un único caso y apoyo teórico en marcos no diseñados para este contexto específico	Desarrollar y validar un constructo de confianza algorítmica específico para el contexto B2B de forecasting; no es transferible directamente desde los constructos de aceptación tecnológica general

Limitación	Área	Descripción	Impacto	Solucion
<i>Ausencia de análisis coste-beneficio; conclusiones normativas sobre viabilidad económica</i>	Nivel 3: Teórico-conceptual	Ningún artículo del corpus calcula el ROI de implantar un sistema de IA para forecasting; la revisión no puede suplir esa ausencia con sus propios datos	Las afirmaciones sobre viabilidad económica de la adopción son de carácter normativo, no empírico; no pueden responder a la pregunta empresarialmente decisiva de "¿justifica el retorno la inversión?"	Diseñar estudios con componente de análisis económico explícito; colaborar con empresas dispuestas a publicar estimaciones de coste-beneficio de proyectos de IA en ventas
<i>Corpus dominado por manufactura transaccional; entornos B2B de ciclo largo ausentes</i>	Nivel 4: Transferibilidad	Ninguno de los veinte estudios modela entornos B2B con pipelines de oportunidades individuales, múltiples decisores y alta dependencia relacional; las arquitecturas del corpus no fueron diseñadas para esas condiciones	Las conclusiones técnicas se derivan de contextos estructuralmente favorables para el forecasting algorítmico; su aplicabilidad a entornos B2B de mayor complejidad relacional es una extrapolación plausible, no una demostración	Diseñar estudios primarios en entornos B2B de ciclo largo con el pipeline CRM como unidad de análisis; replicar los diseños de Rohaan et al. (2022) y Rezazadeh (2020) en esos contextos
<i>D4 sin evidencia primaria; conclusiones sobre gestión del cambio son inferencias sobre ausencia</i>	Nivel 4: Transferibilidad	Las observaciones sobre gestión del cambio organizativo en la adopción de IA se apoyan en marcos externos (Kotter, 1996; Armenakis et al., 1993) no diseñados para este fenómeno	La revisión no puede hacer afirmaciones sustantivas sobre resistencias organizativas, cambio de rutinas comerciales o desarrollo de capacidades; las proposiciones sobre D4 son especulativas por construcción	Diseñar estudios longitudinales mixtos con observación directa durante el proceso de adopción; publicar casos de adopción fallida o parcial, no solo casos de éxito técnico
<i>Desfase temporal respecto a modelos de fundación (LLM)</i>	Nivel 4: Transferibilidad	14 de los 20 estudios preceden a la era LLM; incluso los artículos de 2024-2025 no incorporan modelos de fundación como componentes del pipeline de forecasting	Las afirmaciones sobre el estado del arte y el techo de precisión alcanzable pueden ser conservadoras respecto al estado real de 2025-2026; la literatura indexada va por detrás del desarrollo tecnológico	Actualizar la revisión en el horizonte 2026-2028 con descriptores específicos para LLM y modelos de fundación aplicados a forecasting de ventas; evaluar si la ventaja predictiva sobre baselines estadísticos se amplía con esas arquitecturas

5.7 Implicaciones de las limitaciones para la interpretación de los resultados

Las limitaciones documentadas **no afectan por igual a todas las afirmaciones del trabajo**. La solidez de las conclusiones de las Secciones 3 y 4 decrece de forma reconocible según la dimensión analítica que se considere, y esa gradación no es un defecto que deba disimularse: es la información que permite al lector calibrar qué peso otorgar a cada resultado.

Las afirmaciones sobre rendimiento técnico comparativo son las más robustas. D1 está respaldado por los veinte artículos; las tres regularidades empíricas transversales identificadas en la Sección 3.5 emergen de la comparación sistemática del corpus completo. Lo que las limita no es la densidad de la evidencia sino su procedencia: manufactura y distribución industrial de alta densidad transaccional, predominantemente asiática. Esa concentración impone un perímetro a las regularidades detectadas. La afirmación correcta no es que los modelos de mayor complejidad arquitectónica superan sistemáticamente a los anteriores en contextos B2B; es que lo hacen en los contextos documentados por el corpus, con una ventaja relativa inferior a la que la diferencia de complejidad haría prever, y que esa pauta no ha sido contrastada en entornos de ciclo largo o alta complejidad relacional. El sesgo de publicación añade una capa adicional: los veinte estudios reportan mejoras sin excepción, lo que impide estimar la tasa de éxito real en condiciones medias de adopción.

Las afirmaciones sobre barreras de implantación y factores organizativos tienen respaldo empírico más estrecho. Cuatro artículos sostienen esas conclusiones con evidencia directa; el resto las insinúa de forma tangencial en secciones de limitaciones o trabajo futuro. La consistencia transversal de la barrera de calidad de datos entre contextos geográficos y sectoriales dispares es el argumento más sólido para atribuirle cierta generalidad, pero ese argumento no demuestra su vigencia en entornos B2B estructuralmente distintos a los del corpus. El constructo de confianza algorítmica está documentado en un único caso; el análisis coste-beneficio está ausente en los dieciocho años del período analizado. Las afirmaciones sobre esas dos dimensiones tienen valor diagnóstico, no demostrativo.

Las observaciones sobre D4 y las contribuciones teóricas propias del trabajo ocupan el extremo de menor certeza. La tipología de tres estadios de madurez organizativa y el diagnóstico de la brecha precisión-decisión no fueron extraídos inductivamente del corpus ni validados externamente: son hipótesis interpretativas con utilidad heurística reconocida en el contexto de esta revisión. Que D4 esté prácticamente ausente del corpus no es evidencia de que la gestión del cambio sea irrelevante en la adopción del forecasting algorítmico. Es evidencia de que el campo no ha producido metodologías para estudiarla. Esa distinción no es retórica: determina si una limitación debe atribuirse al diseño del trabajo o a la estructura de la disciplina.

Las contribuciones teóricas propias encuentran su justificación precisamente en ese vacío. Su valor no reside en haber demostrado algo que el corpus no podía demostrar, sino en haber identificado con precisión qué falta y por qué importa. Las Propuestas Doctorales de la Sección 4 son la consecuencia directa de ese diagnóstico. No clausuran el problema. Lo abren con rigor.

6. CONCLUSIONES

El presente capítulo sintetiza el valor analítico acumulado por las secciones precedentes del trabajo, no para reproducir sus argumentos sino para evaluar, desde la posición exterior que solo el cierre permite, qué sostiene el corpus con rigor demostrable, qué queda parcialmente abierto y qué permanece fuera del alcance de la evidencia disponible. La revisión sistemática de veinte artículos seleccionados mediante protocolo PRISMA 2020 (Page et al., 2021) a partir de 3.121 registros iniciales ha producido un mapa de resolución diferencial que no se agota en la catalogación de hallazgos técnicos: el análisis dimensional revela una asimetría estructural entre lo que el campo sabe sobre la precisión algorítmica (D1, respaldada por la totalidad del corpus) y lo que ignora sobre la gobernanza organizativa de esa precisión (D4, ausente como objeto primario de investigación en los veinte artículos), con dos dimensiones intermedias (D2 y D3) cuya cobertura decreciente señala el territorio donde el conocimiento acumulado cede paso a la conjetura fundada. Leer las conclusiones que siguen requiere preservar esa gradación: las afirmaciones sobre rendimiento técnico comparativo tienen una base empírica cualitativamente distinta a las afirmaciones sobre transferibilidad organizativa, y esa distinción no es un matiz retórico sino la información que determina qué puede derivarse del trabajo para la práctica y qué necesita investigación primaria antes de ser operacionalizado.

6.1 Síntesis integradora de hallazgos por dimensión analizada

El corpus produce su respuesta más densa precisamente aquí. Los veinte artículos confirman sin excepción que los modelos de inteligencia artificial superan a sus baselines de referencia en los sectores B2B representados (manufactura de circuitos impresos, distribución farmacéutica iraní, distribución de recambios industriales neerlandesa, exportaciones corporativas de Oriente Medio, telecomunicaciones B2B indonesias, logística marítima taiwanesa, automatización B2B china, CRM B2B irlandés, ventas empresariales y siderurgia turca), con reducciones de MAPE que oscilan entre el 28% documentado por Hadavandi et al. (2011) sobre el modelo WEFuNN de Chang et al. (2007) y el 87,6% de reducción de MAE medio sobre ARIMA registrado por Zadeh et al. (2014) en distribución farmacéutica iraní. La arquitectura de red convolucional espectral de grafos de Henna et al. (2025) alcanza precisión 1,00 y AUC de 0,929 en el conjunto de prueba del dataset CRM B2B irlandés, el valor más elevado del corpus. En el único estudio con validación en producción real, Rezazadeh (2020) documenta 83% de accuracy frente al 63% del juicio manual de los vendedores, una brecha de 20 puntos porcentuales mantenida durante tres meses con 846 oportunidades reales en el pipeline comercial.

Esa aparente coherencia oculta una heterogeneidad metodológica de consecuencias interpretativas graves. Cada estudio define su propio baseline (algunos comparan contra ARIMA (Zadeh et al., 2014), otros contra regresión lineal múltiple (Chang et al., 2007; Pekaya y Uysal, 2024), otros contra modelos estadísticos más sofisticados como ES o Holt-Winters (Lu y Kao, 2016), y solo dos comparan directamente contra el juicio humano experto (Rezazadeh, 2020; Monat, 2011)). Cada estudio selecciona sus propias métricas (MAPE, RMSE, MAE, R^2 , AUC-ROC, F1-score, accuracy) y opera sobre datasets con tamaños muestrales que van desde 60 observaciones mensuales (Chang et al., 2007) hasta decenas de miles de registros transaccionales (Rohaan et al., 2022). Los estudios con muestras más pequeñas tienden a reportar mejoras de mayor magnitud, patrón consistente con la hipótesis de sobreajuste: un modelo flexible puede ajustarse al ruido del conjunto de entrenamiento y obtener métricas artificialmente elevadas sobre un conjunto de prueba igualmente reducido. Solo dos estudios del corpus aplican tests de significancia estadística (test de Wilcoxon no paramétrico) para verificar que las diferencias entre modelos no son producto de la varianza muestral (Chang et al., 2007; Lu y Kao, 2016).

La convergencia que el corpus exhibe es de naturaleza cualitativa, no estadística. No existe ningún benchmark público compartido que permita la comparación directa entre los veinte artículos; cada uno reporta su mejora sobre su propio contexto de referencia, con sus propios datos y sus propias métricas (Hyndman y Koehler, 2006). Lo que la evidencia del corpus autoriza epistemológicamente es afirmar que existe una regularidad de dirección (los modelos de IA mejoran la precisión sobre baselines estadísticos convencionales en contextos B2B de manufactura, distribución y logística) sin que esa regularidad tenga el rango demostrativo de una síntesis cuantitativa verificable. La ausencia de ese benchmark no es una carencia de esta revisión: es un déficit estructural del campo que ningún diseño de revisión puede compensar a posteriori, y que las secciones 3.5 y 3.7 documentaron con precisión

suficiente. El único avance hacia un dataset semi-público procede de Jovanovic et al. (2025), que emplea el dataset de Amazon for Business, aunque ese contexto es un proxy imperfecto del B2B industrial en sentido estricto.

La **heterogeneidad de los protocolos de validación introduce una segunda capa de incertidumbre sobre la magnitud real de las mejoras**. Solo tres estudios del corpus garantizan separación cronológica estricta entre entrenamiento y prueba (validación temporal sin fuga de datos futuros) como condición de rigor metodológico mínima para series temporales (Hyndman y Koehler, 2006). Los diecisiete restantes no explicitan este protocolo o emplean validación cruzada estándar, que en series temporales con tendencia o estacionalidad puede inflar los resultados porque permite que observaciones futuras contaminen el entrenamiento. Esa omisión sistemática no invalida los resultados del corpus, pero impone una lectura cautelosa: las mejoras reportadas representan probablemente un límite superior del valor real de los modelos en condiciones de producción.

Sobre la dimensión D2 (interpretabilidad y explicabilidad)

La trayectoria temporal del corpus en esta dimensión **no describe un progreso acumulativo**. Describe una inversión estructural que tiene consecuencias directas para la gobernabilidad algorítmica del forecasting comercial en entornos B2B. Los modelos simbólicos y fuzzy de la primera familia (2007-2014) ofrecían interpretabilidad estructural intrínseca: las reglas generadas evolutivamente por WEFuNN (Chang et al., 2007), los subsistemas fuzzy especializados del KGFS (Hadavandi et al., 2011) y los casos recuperados por similitud en el FCBF (Chang et al., 2008) son el modelo, no una aproximación post-hoc a él. Cuando un directivo comercial de la manufactura de PCB taiwanesa preguntaba por qué el sistema predecía un determinado volumen de ventas para el mes siguiente, la respuesta era directamente auditable en las reglas fuzzy generadas por el algoritmo evolutivo: los cuatro factores seleccionados mediante el Análisis Relacional Gris (índice de comercio de exportación, demanda de elementos de cristal líquido, valor de ventas PCB de la industria y pronóstico de Winters) con sus pesos de contribución explícitos. Esa auditabilidad no era un añadido al modelo: era su principio constructivo.

Bohanec et al. (2017) representan el único intento del corpus de construir interpretabilidad extrínseca sobre un modelo opaco, diseñando el sistema EXPLAINIME específicamente para hacer auditables las salidas del Random Forest ante directivos comerciales eslovenos que habían rechazado el modelo sin ese mecanismo. La razón del rechazo es precisa: los directivos no podían explicar a sus superiores ni a sus clientes por qué el modelo predecía un determinado resultado para una oportunidad específica, lo que les impedía usarlo como base de decisiones que debían ser justificadas públicamente. La solución propuesta por Bohanec et al. no mejora la precisión técnica del modelo (el AUC de 0,85 permanece inalterado); resuelve el problema organizativo que impedía su uso. Ese diseño es metodológicamente singular: son el único equipo del corpus que comprendió que el problema central del forecasting B2B con IA no era técnico sino organizativo, y que construyó su investigación en respuesta a esa comprensión.

Los seis artículos del período 2023-2025 (Zhang et al. (2023), Chen (2025), Henna et al. (2025), Jovanovic et al. (2025), Wang et al. (2025), Huang et al. (2025)) alcanzan la mayor precisión técnica del corpus en sus respectivos sectores y presentan opacidad algorítmica total: ninguno incorpora mecanismo alguno de explicabilidad (Adadi y Berrada, 2018). La arquitectura híbrida HATT-MSCNN-IBiLSTM con atención de Zhang et al. (2023), la red convolucional espectral de grafos de Henna et al. (2025) y el ensemble de stacking multi-modelo de Wang et al. (2025) son, desde la perspectiva de la interpretabilidad, cajas negras de mayor sofisticación que el Random Forest de Bohanec et al. (2017) que los directivos eslovenos rechazaron en 2017 por exactamente ese motivo. Trece de los veinte artículos del corpus ignoran D2 por completo: esa concentración de la producción científica en la novedad arquitectónica en detrimento de la adoptabilidad organizativa refleja los incentivos del proceso de publicación del campo más que la irrelevancia del problema.

El hallazgo estructuralmente relevante de D2 no es la escasez de cobertura (puntuación media de 1,45/3 documentada en la sección 3.2), sino la dirección de esa escasez: **a medida que el campo gana precisión técnica, pierde de forma sistemática transparencia operativa**. El trade-off interpretabilidad-precisión que la literatura de XAI describe como una tensión gestionable (Adadi y Berrada, 2018) se manifiesta en el corpus como una divergencia creciente no gestionada. El campo no ha desarrollado aún el vocabulario conceptual para preguntar qué

significa, para la gobernanza comercial B2B, depender de modelos cuyas predicciones no pueden ser justificadas ante la dirección ni explicadas a los clientes.

Sobre la dimensión D3 (adopción tecnológica)

Cuatro estudios sostienen esta dimensión con evidencia directa; **el resto del corpus la implica sin estudiarla**. La lectura comparativa de estos cuatro estudios produce una tipología de tres estadios de madurez organizativa que permite interpretar por qué mejoras técnicas de magnitud similar generan impactos operativos estructuralmente distintos.

Monat (2011) documenta el caso arquetípico del primer estadio: organizaciones que utilizan el juicio subjetivo de los vendedores como proceso de forecasting primario, sin infraestructura de datos históricos ni proceso estadístico formalizado. En ese contexto, la introducción del modelo ANN-logit supone la transición desde la opinión a la evidencia, y el baseline relevante no es ARIMA sino el juicio de los vendedores. Monat documenta una mejora del AUC desde 0,61 (correspondiente al juicio experto) hasta 0,78, con implicaciones directas sobre la rentabilidad del proceso de prospección de leads industriales en el contexto estadounidense. La barrera de adopción en este estadio no es técnica sino conductual: los vendedores clasificaban las oportunidades en el CRM con criterios heterogéneos, introduciendo sesgo sistemático en los datos de entrenamiento que degradaba el modelo antes de que pudiera operar. Esa barrera (un problema de comportamiento organizativo, no de infraestructura) no es resoluble con un algoritmo más sofisticado.

Rezazadeh (2020) y Sohrabpour et al. (2021) representan el segundo estadio: organizaciones con infraestructura de datos moderadamente avanzada, donde el forecasting estadístico básico ya existe y el modelo de IA supone una mejora incremental sobre ese proceso ya formalizado. Rezazadeh documenta el único caso del corpus con validación en producción real: el pipeline ensemble (Gradient Boosting, Random Forest, Regresión Logística) desplegado en Azure ML mantiene el 83% de accuracy frente al 63% del juicio manual de los vendedores durante tres meses, con reentrenamiento semanal automatizado. La condición de contorno que permite ese rendimiento en producción es explícita: datos CRM suficientemente limpios tras una fase de preparación que consumió una proporción sustancial del tiempo total del proyecto.

Rohaan et al. (2022) representan el tercer estadio, cualitativamente diferente: organizaciones con datos ricos en volumen y con infraestructura técnica avanzada, pero con gobernanza de datos insuficiente para explotar esa riqueza. Las discrepancias entre identificadores de empresa en el CRM y el sistema de RFQs (dos sistemas diseñados con propósitos distintos, por equipos distintos, en momentos distintos, y que acumulaban décadas de datos bajo lógicas incompatibles) imposibilitaron la vinculación del historial de compras con las características de la oportunidad entrante, anulando la transferibilidad práctica del modelo Random Forest con umbral optimizado a 0,62 con independencia de su rendimiento técnico sobre los datos históricos disponibles. **El cuello de botella no era la precisión del algoritmo: era la coherencia institucional de los sistemas que lo alimentaban**, un problema cuya resolución requería decisiones de gobernanza sobre responsabilidades de calidad de datos, inversión en infraestructura de master data management y cambio cultural en los equipos de ventas.

El caso de Bohanec et al. (2017) (un modelo con AUC de 0,85 rechazado por los directivos eslovenos porque no podía explicar sus predicciones) no es la excepción del corpus: es el ejemplar teórico que cristaliza un mecanismo causal que el resto de los artículos solo implica. Los marcos TAM (Davis, 1989) y UTAUT (Venkatesh et al., 2003) operan en esta revisión como lentes interpretativas, no como constructos aplicados directamente al fenómeno estudiado: ninguno fue diseñado para el caso específico de la delegación del juicio comercial en un sistema algorítmico de predicción, donde la confianza del directivo en el modelo no depende únicamente de la utilidad percibida y la facilidad de uso (las dimensiones centrales del TAM), sino también de su capacidad para justificar públicamente las decisiones que ese modelo fundamenta. Esa distinción entre confianza personal en el modelo y confianza justificable ante terceros en las decisiones derivadas del modelo es la que Bohanec et al. (2017) documentaron empíricamente sin teorizarla.

Sobre la dimensión D4 (gestión del cambio organizativo)

La puntuación media del corpus en D4 es 1,25 sobre 3, lo que indica que la mayoría de los veinte artículos ni siquiera menciona el cambio organizativo en sus secciones de limitaciones o trabajo futuro (véase sección 3.2). Ningún artículo documenta cómo reaccionaron los equipos de ventas ante la introducción del modelo, si los directivos comerciales modificaron sus rutinas de planificación en respuesta a las predicciones del sistema, si surgieron resistencias en torno a la redistribución del poder informativo que la adopción del modelo conlleva (la pérdida del monopolio sobre la información de ventas que el vendedor ejercía mediante su juicio subjetivo), o si la organización desarrolló capacidades internas para mantener y actualizar el modelo a lo largo del tiempo.

Esa ausencia no es aleatoria ni reparable mediante una búsqueda bibliográfica más amplia. **Refleja que el campo ha construido sus problemas de investigación en términos técnicos y no ha desarrollado aún las herramientas teóricas ni los diseños metodológicos para estudiar qué ocurre en las organizaciones cuando se decide adoptar un sistema algorítmico de predicción comercial.** Los diseños longitudinales mixtos (estudios de caso con observación participante, entrevistas semiestructuradas con directivos antes y después de la adopción, análisis de cambios en los procesos de planificación comercial a lo largo del tiempo) son costosos de implementar, difíciles de publicar en las revistas de ingeniería y sistemas expertos donde se concentra el corpus, y requieren acceso organizativo sostenido que pocas empresas B2B están dispuestas a conceder a investigadores externos. Los marcos de transformación organizativa disponibles en la literatura de gestión, incluidos los modelos de etapas de adopción institucional y los marcos de análisis de resistencias (Kotter, 1996), no aparecen en ningún artículo del corpus como herramientas de diseño o de interpretación.

La distancia entre el modelo produce mejores predicciones y la organización toma mejores decisiones gracias al modelo es la brecha analítica más relevante que el corpus deja abierta. El silencio de D4 es, en sí mismo, el hallazgo más informativo de la revisión: señala el límite exterior del conocimiento actual del campo con mayor precisión que cualquiera de sus resultados positivos.

6.2 Respuestas a las preguntas de investigación

P11 interroga en qué medida la IA incrementa la precisión del forecasting de ventas en entornos B2B y bajo qué condiciones técnicas y organizativas esa mejora predictiva es transferible a la práctica comercial. La evidencia del corpus no permite responder con una afirmación incondicional. La respuesta epistemológicamente honesta que la evidencia disponible autoriza es una proposición tripartita condicional: la IA mejora el forecasting B2B de forma sistemática y sustancial si y sólo si se satisfacen simultáneamente tres condiciones, de naturaleza técnica, metodológica y organizativa respectivamente. Fuera de esas tres condiciones, el corpus no sostiene afirmaciones generalizables.

La primera condición es de naturaleza técnica. La mejora predictiva es sistemática y sustancial cuando el dataset dispone de suficiente volumen y calidad para entrenar el modelo sin sobreajuste. El corpus sitúa ese umbral orientativamente por encima de los 1.000 registros etiquetados en contextos de clasificación binaria de oportunidades (Rezazadeh (2020) opera con decenas de miles de registros; Henna et al. (2025), con 448 instancias, reconocen el riesgo de sobreajuste como limitación explícita) y por encima de tres a cinco años de historial mensual en contextos de series temporales (los estudios con 36 a 60 observaciones como Chang et al. (2007) y Zadeh et al. (2014) reportan las mejoras de mayor magnitud relativa, patrón consistente con la hipótesis de que el modelo se ajusta parcialmente al ruido del conjunto de entrenamiento). La condición técnica incluye también la validación temporal estricta: la separación cronológica entre entrenamiento y prueba, sin fuga de datos futuros, es la condición mínima para que las métricas reportadas sean extrapolables a producción real (Hyndman y Koehler, 2006). Solo tres de los veinte estudios la garantizan explícitamente.

La segunda condición es de naturaleza metodológica. El baseline de comparación relevante para determinar si la IA añade valor operativo no es ARIMA ni la regresión lineal múltiple: es el proceso de predicción humana vigente en la organización, medido mediante el Forecast Value Added (FVA) o métricas equivalentes que comparan el modelo contra el juicio experto, no contra un modelo estadístico que la organización puede ya no estar usando (Tashman, 2000). Solo dos artículos del corpus miden esa diferencia directamente: Rezazadeh (2020) documenta una brecha de 20 puntos porcentuales en accuracy entre el pipeline ML y el juicio manual de los vendedores en producción

real; Monat (2011) documenta una mejora del AUC desde 0,61 hasta 0,78 sobre la estimación experta en conversión de leads industriales. Cuando el baseline es exclusivamente estadístico, las mejoras reportadas pueden ser artefactos de una elección de referencia débil: el campo ha acumulado diecisiete estudios que demuestran que la IA supera a ARIMA o a la regresión lineal, una pregunta cuya respuesta tiene limitado interés práctico para un directivo comercial cuyo equipo lleva años generando previsiones con Excel y el CRM.

La tercera condición es de naturaleza organizativa. Las predicciones del modelo deben ser suficientemente interpretables para que los directivos comerciales puedan confiar en ellas, cuestionarlas e integrarlas en las rutinas de gobernanza comercial de la organización. Bohanec et al. (2017) demuestran que un modelo con AUC de 0,85 fracasa en esta condición cuando sus salidas no pueden ser explicadas ante la dirección: el modelo no es rechazado por ser técnicamente inferior sino por ser organizativamente inutilizable. Rohaan et al. (2022) demuestran que un modelo técnicamente válido es inutilizable cuando la gobernanza de datos del CRM no garantiza la integridad de los identificadores que vinculan el historial de compras con la oportunidad entrante: el cuello de botella no es la arquitectura del modelo sino la coherencia institucional de los sistemas que lo alimentan. La condición organizativa no puede ser satisfecha por una mejora técnica adicional: requiere intervenciones de gobernanza de datos, mecanismos de explicabilidad adecuados al contexto decisonal específico y (lo que ningún artículo del corpus teoriza) un proceso de transformación organizativa que alinee las rutinas de trabajo de los equipos de ventas con las capacidades y limitaciones del sistema algorítmico.

Fuera de estas tres condiciones simultáneamente satisfechas, el corpus no sostiene afirmaciones generalizables sobre la capacidad de la IA para mejorar el forecasting B2B en la práctica comercial. Esa condicionalidad no debilita la respuesta a PI1: la precisa. Una respuesta que omitiera esas condiciones sería, desde el punto de vista epistémico, menos rigurosa que una afirmación condicional que las explicita, aunque la primera pudiera parecer superficialmente más contundente (Tranfield et al., 2003; Snyder, 2019).

La asimetría interna de la respuesta merece ser enunciada de forma explícita porque tiene consecuencias directas para la ponderación de las secciones precedentes del trabajo. El componente técnico de PI1 (¿mejora la IA la precisión del forecasting?) queda respondido con alta confianza: diecisiete de los veinte artículos del corpus aportan evidencia convergente en la misma dirección, con cobertura sectorial que abarca manufactura electrónica, distribución industrial, logística, siderurgia, farmacéutica, telecomunicaciones y comercio exterior, y cobertura geográfica que incluye Taiwán, Irán, Países Bajos, Canadá, Eslovenia, Turquía, Indonesia, China e Irlanda. El componente sobre transferibilidad organizativa (bajo qué condiciones esa mejora técnica llega a traducirse en decisiones comerciales mejores) está respaldado por tres artículos con evidencia directa: Bohanec et al. (2017), Rohaan et al. (2022) y Rezazadeh (2020). Una respuesta apoyada en tres casos tiene un estatus epistémico sustancialmente diferente al de una respuesta apoyada en diecisiete. Esa gradación de solidez no es una concesión retórica a la humildad académica: es la información que el lector necesita para calibrar el peso que puede otorgar a cada componente de las conclusiones del presente capítulo.

Las **preguntas secundarias PI2 a PI5**, respondidas con detalle en la sección 3.8, convergen en un patrón que refuerza y matiza esta respuesta principal. PI2 (qué arquitecturas predominan y cómo se compara su rendimiento) confirma que no existe una arquitectura dominante universal: los modelos simbólicos y fuzzy de la primera familia son superiores en contextos de catálogo reducido con datos escasos y requerimientos de interpretabilidad; los ensembles de la segunda familia equilibran precisión, robustez y adoptabilidad organizativa; las arquitecturas de deep learning e híbridas de la tercera familia maximizan la precisión técnica a costa de la interpretabilidad y la transferibilidad organizativa. PI3 (qué variables y fuentes de datos exhiben mayor capacidad predictiva) señala que los datos transaccionales internos del CRM/ERP dominan el corpus, pero que las variables exógenas macroeconómicas (tipo de cambio en Pekkaya y Uysal (2024) y Sohrabpour et al. (2021), KPIs de fletes en Wang et al. (2025)) producen mejoras sustanciales condicionadas al sector y al horizonte de predicción. PI4 (con qué mecanismos y consistencia se documentan las barreras de implementación) confirma que la gobernanza de datos es la única barrera documentada transversalmente en todos los sectores y períodos del corpus, y que la opacidad algorítmica es la segunda barrera en importancia, documentada como mecanismo causal explícito por Bohanec et al. (2017) e implícita en la mayoría del resto. PI5 (qué vacíos permanecen insuficientemente abordados) produce el

mapa de ausencias que fundamenta la agenda doctoral de la sección 4: ausencia de teoría de la traducción precisión-decisión, ausencia de marco de madurez organizativa para el forecasting algorítmico, ausencia de constructo formalizado de confianza algorítmica en contextos B2B.

6.3 Contribuciones del trabajo

Sobre el mapa de resolución diferencial del campo

Esta revisión no produce un estado del arte en el sentido convencional del término. **Produce un mapa explícito de lo que la literatura ha resuelto, de lo que ha dejado parcialmente abierto y de lo que ni siquiera ha intentado formular como pregunta de investigación.** Ese mapa tiene un valor analítico específico e irreproducible mediante una revisión narrativa: muestra que D1 ha alcanzado una convergencia cualitativa de dirección que no puede elevarse a generalización estadística sin la creación previa de un benchmark público compartido (ausente del campo durante casi dos décadas de producción científica); que D2 ha documentado la inversión del trade-off interpretabilidad-precisión sin teorizar sus consecuencias para la gobernanza comercial B2B ni producir el constructo de confianza algorítmica que el fenómeno requiere; que D3 ha producido el mecanismo causal clave (el caso de Bohanec et al. (2017) como ejemplar teórico que cristaliza la cadena opacidad / rechazo / fallo de adopción) pero no el constructo formal que lo generalice a otros contextos; y que D4 constituye el punto ciego estructural del campo: una dimensión que ninguno de los veinte artículos ha abordado como objeto primario de investigación porque el campo no ha desarrollado los instrumentos metodológicos para hacerlo.

La producción de ese mapa requiere la aplicación sistemática de un protocolo PRISMA 2020 (Page et al., 2021) sobre un corpus acotado con criterios de inclusión y exclusión explícitos (20 artículos seleccionados de 3.121 registros iniciales mediante protocolo de cuatro fases) y la codificación dimensional de cada artículo bajo un marco analítico común con escala ordinal explícita. Ese proceso es el que hace visible la **asimetría de cobertura (D1: media 2,85/3; D2: media 1,45/3; D3: media 1,50/3; D4: media 1,25/3)** con la claridad necesaria para que sus implicaciones sean derivables y documentables, no intuitivas. Una revisión narrativa de la misma literatura habría producido una taxonomía de resultados, no una jerarquía de vacíos. La distinción no es semántica: la taxonomía de resultados es útil para el investigador que quiere saber qué se ha hecho; la jerarquía de vacíos es necesaria para el investigador que quiere saber qué hacer a continuación y por qué.

Sobre la tipología de madurez organizativa como marco propositivo

Del análisis comparativo de los perfiles organizativos descritos, de forma fragmentaria, por Monat (2011), Rezazadeh (2020), Sohrabpour et al. (2021) y Rohaan et al. (2022), emerge una tipología de tres estadios que permite interpretar por qué mejoras técnicas de magnitud similar producen impactos operativos estructuralmente distintos. El estadio de juicio subjetivo como proceso primario (donde el cuello de botella es la confianza del usuario y la ausencia de datos históricos consistentes) requiere intervenciones orientadas a la formalización del proceso de captura de datos y al desarrollo de confianza institucional en el sistema antes que cualquier optimización arquitectónica. El estadio de estadística básica preexistente (donde el forecasting formalizado ya existe y el modelo de IA aporta ganancia incremental) requiere principalmente una gestión del cambio que posicione el modelo como herramienta de apoyo al juicio experto en lugar de como sustituto. El estadio de datos ricos con gobernanza deficiente (donde el cuello de botella no es la precisión del algoritmo sino la integridad de los sistemas de información que lo alimentan) requiere inversión en gobernanza de datos como condición previa e irremplazable a cualquier decisión sobre arquitectura algorítmica.

El estatus epistémico de esta tipología es el de heurístico propositivo, no el de constructo validado. No fue extraída inductivamente mediante codificación formalizada con múltiples revisores ni contrastada con paneles de expertos; emergió del análisis interpretativo de cuatro casos con perfiles organizativos suficientemente distintos para hacer visible la variabilidad entre estadios. La contribución del presente trabajo no reside en afirmar que la tipología es correcta y completa: reside en hacerla visible como necesidad teórica del campo. El campo necesita un instrumento de clasificación de la madurez organizativa para el forecasting algorítmico que permita anticipar cuál es el factor limitante real de la adopción en cada tipo de organización, y que permita explicar la varianza de resultados que el

corpus documenta sin poder explicar. Esta revisión identifica esa necesidad con la precisión suficiente para que pueda ser operacionalizada empíricamente en investigaciones futuras, lo que supone una contribución de primer orden para la agenda doctoral del campo.

Sobre la agenda doctoral anclada en vacíos documentables

Las dos propuestas doctorales articuladas en la sección 4 no son recomendaciones genéricas de investigación futura. Derivan de vacíos específicos identificados mediante la lectura sistemática del corpus, y la conexión entre vacío y propuesta es explícita y trazable a partir de la evidencia del corpus, lo que las distingue cualitativamente de las secciones de trabajo futuro convencionales.

La Propuesta Doctoral A (sobre la precisión del forecasting de IA en empresas de software B2B) deriva de la subrepresentación estructural y documentable de ese sector en el corpus: ninguno de los veinte artículos opera en una empresa de software empresarial con ciclos de venta largos y alta complejidad relacional, que es precisamente el tipo de organización B2B con mayor necesidad de forecasting preciso y menor penetración documentada de herramientas algorítmicas. La pregunta sobre si los mecanismos de mejora predictiva documentados en manufactura de PCB, distribución de recambios o siderurgia son transferibles a ese contexto sin modificación (o si la estructura de los datos, los ciclos de venta y los patrones de demanda de las empresas de software requieren arquitecturas específicas) no puede responderse a partir del corpus existente.

La Propuesta Doctoral B (sobre interpretabilidad, confianza y adopción organizativa del forecasting algorítmico en B2B) deriva de las tres ausencias teóricas documentadas en la sección 3.7: la ausencia de una teoría de la traducción precisión-decisión, la ausencia de un marco de madurez organizativa formalizado y la ausencia de un constructo de confianza algorítmica específico para el contexto de la delegación del juicio comercial en sistemas de predicción. El caso de Bohanec et al. (2017) (el único del corpus que documenta el mecanismo de rechazo por opacidad) proporciona la evidencia fundacional de esa propuesta, pero no el andamiaje teórico que permita diseñar estudios replicables en otros sectores y contextos. La trazabilidad entre vacío y propuesta es la propiedad que eleva la agenda de la sección 4 de lo aspiracional a lo metodológicamente fundamentado: cada propuesta tiene una justificación documental que puede ser examinada críticamente (sección 3.7 para los vacíos, sección 3.2 para la cobertura dimensional, sección 3.6 para las barreras de implementación) y que no descansa en la autoridad del revisor sino en la evidencia del corpus.

6.4 Breve remisión a limitaciones

La sección 5 ofrece el análisis jerárquico completo de las restricciones que condicionan el valor epistémico de este trabajo, operando sobre cuatro niveles diferenciados en naturaleza y consecuencia (L1: corpus y muestra bibliográfica; L2: alcance analítico; L3: marco teórico propio del trabajo; L4: transferibilidad contextual). De entre todas las limitaciones identificadas en ese análisis, la que tiene mayor consecuencia directa para la interpretación de las conclusiones del presente capítulo es la ausencia de coeficientes de concordancia interobservador (kappa de Cohen como estándar metodológico habitual en revisiones sistemáticas (Tranfield et al., 2003)) tanto en la selección de los veinte artículos que componen el corpus como en su codificación bajo las dimensiones D1-D4: ambas operaciones dependen del juicio de un único revisor, y un segundo revisor independiente podría producir una muestra y una clasificación temática parcialmente distintas. **Esa limitación es corregible en investigaciones futuras mediante la incorporación de al menos un segundo revisor para el 20-25% del corpus con cálculo explícito del kappa; el protocolo PRISMA 2020 (Page et al., 2021) lo recomienda expresamente.** Resulta imprescindible distinguirla de las limitaciones inherentes al tipo de investigación realizada: una revisión sistemática cualitativa no puede producir síntesis cuantitativas mediante metaanálisis, con independencia de las decisiones de diseño del investigador, porque la heterogeneidad de métricas, baselines y contextos entre los veinte estudios hace materialmente imposible la agregación estadística directa de sus resultados. Las conclusiones del presente capítulo deben leerse bajo esa doble restricción: dependencia del juicio del revisor en la codificación dimensional, y estatus de convergencias cualitativas (no de generalizaciones estadísticamente verificadas) en los patrones transversales identificados.

6.5 Reflexión de cierre

La inteligencia artificial no está entrando en el forecasting de ventas B2B como una herramienta técnica más eficiente. **Está reconfigurando la relación entre el dato, el juicio experto y la gobernanza comercial en formas que el corpus ha documentado técnicamente pero no ha explicado organizativamente.** Esa reconfiguración tiene una dimensión visible (la que diecisiete estudios han medido con creciente sofisticación arquitectónica durante casi dos décadas) y una dimensión prácticamente invisible: la que atañe a cómo las organizaciones transforman sus procesos decisionales, sus estructuras de responsabilidad y sus culturas de previsión cuando el sistema algorítmico empieza a producir predicciones que los vendedores no pueden refutar porque no entienden cómo se generaron, o que los directivos no pueden defender ante sus superiores porque el modelo no produce explicaciones auditables. Los casos de Bohanec et al. (2017) y Rohaan et al. (2022) demuestran que un modelo técnicamente superior puede fracasar en su adopción por razones que ninguna mejora arquitectónica puede resolver: la incapacidad de justificar una predicción ante la dirección, la discrepancia entre sistemas que acumulan décadas de datos bajo lógicas institucionales incompatibles. Esos fracasos no son anómalos. Son los indicadores más informativos del corpus porque señalan el territorio que la investigación académica todavía no ha cartografiado con rigor (el territorio donde la ganancia técnica documentada por veinte estudios debe convertirse, o no, en ganancia organizativa verificable). **Las propuestas doctorales de la sección 4 son la respuesta lógica a esa cartografía incompleta:** no porque sean las preguntas más sencillas de abordar (son notoriamente las más difíciles de diseñar, financiar y publicar), sino porque son las únicas preguntas cuya respuesta determina si la inversión en IA para el forecasting B2B produce el valor que la literatura técnica promete.

REFERENCIAS BIBLIOGRÁFICAS

- Adadi, A., & Berrada, M. (2018). Peeking inside the black-box: A survey on explainable artificial intelligence (XAI). *IEEE Access*, 6, 52138–52160. <https://doi.org/10.1109/ACCESS.2018.2870052>
- American Marketing Association. (2017). *Definition of marketing*. Enlace recuperado en Mayo 2026 en la web <https://www.ama.org/the-definition-of-marketing-what-is-marketing/>
- Armenakis, A. A., Harris, S. G., & Mossholder, K. W. (1993). Creating readiness for organizational change. *Human Relations*, 46(6), 681–703. <https://doi.org/10.1177/001872679304600601>
- Bohanec, M., Kljajić Borštnar, M., & Robnik-Šikonja, M. (2017). Explaining machine learning models in sales predictions. *Expert Systems with Applications*, 71, 416–428. <https://doi.org/10.1016/j.eswa.2016.11.010>
- Chang, P.-C., Liu, C.-H., & Lai, R. K. (2008). A fuzzy case-based reasoning model for sales forecasting in print circuit board industries. *Expert Systems with Applications*, 34(3), 2352–2360. <https://doi.org/10.1016/j.eswa.2007.02.011>
- Chang, P.-C., Wang, Y.-W., & Liu, C.-H. (2007). The development of a weighted evolving fuzzy neural network for PCB sales forecasting. *Expert Systems with Applications*, 32(1), 86–96. <https://doi.org/10.1016/j.eswa.2005.11.021>
- Chen, Z.-Y. (2025). Application of immunological and swarm intelligence learning-based algorithm for industrial grade computer sales prediction. *Applied Artificial Intelligence*, 39(1), Article 2440836. <https://doi.org/10.1080/08839514.2024.2440836>
- Davis, F. D. (1989). Perceived usefulness, perceived ease of use, and user acceptance of information technology. *MIS Quarterly*, 13(3), 319–340. <https://doi.org/10.2307/249008>
- Fischer, H., Seidenstricker, S., Berger, T., & Holopainen, T. (2022). Artificial intelligence in B2B sales: Impact on the sales process. En T. Ahram, J. Kalra, & W. Karwowski (Eds.), *Artificial intelligence and social computing* (Vol. 28). AHFE International. <https://doi.org/10.54941/ahfe1001456>
- Fries, M., & Ludwig, T. (2024). “Why are the sales forecasts so low?” Socio-technical challenges of using machine learning for forecasting sales in a bakery. *Computer Supported Cooperative Work*, 33(2), 253–293. <https://doi.org/10.1007/s10606-022-09458-z>
- Hadavandi, E., Shavandi, H., & Ghanbari, A. (2011). An improved sales forecasting approach by the integration of genetic fuzzy systems and data clustering: Case study of printed circuit board. *Expert Systems with Applications*, 38(8), 9392–9399. <https://doi.org/10.1016/j.eswa.2011.01.132>
- Henna, S., Kalliadán, S. K., & Amjath, M. (2025). Optimizing B2B customer relationship management and sales forecasting with spectral graph convolutional networks: A quantitative approach. *Quantitative Finance and Economics*, 9(2), 449–478. <https://doi.org/10.3934/QFE.2025015>
- Huang, D., Mao, Z., Fang, K., Kumar, S., & Zhang, M. (2025). Forecasting automobile sales with social media information under pandemic emergencies: Evidence from Chinese automobile industry. *Annals of Operations Research*. <https://doi.org/10.1007/s10479-025-06705-6>
- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>

- Jarotschkin, V., Soykoth, M. W., & Chaker, N. N. (2025). Artificial intelligence in sales research: Identifying emergent themes and looking forward. *Journal of Business Research*, 198, Article 115383. <https://doi.org/10.1016/j.jbusres.2025.115383>
- Jovanovic, L., Bacanin, N., Zivkovic, T., Antonijevic, M., Zivkovic, M., & Djordjevic, A. (2025). Performance evaluation of metaheuristics-tuned recurrent networks with VMD decomposition for Amazon sales prediction. *International Journal of Data Science and Analytics*. <https://doi.org/10.1007/s41060-025-00712-5>
- Khalil Zadeh, N., Sepehri, M. M., & Farvareh, H. (2014). Intelligent sales prediction for pharmaceutical distribution companies: A data mining based approach. *Mathematical Problems in Engineering*, 2014, Article 420310. <https://doi.org/10.1155/2014/420310>
- Kotler, P., & Keller, K. L. (2012). *Marketing management* (14th ed.). Pearson.
- Kotter, J. P. (1996). *Leading change*. Harvard Business School Press.
- Lackman, C. L. (2007). Forecasting sales for a B2B product category: Case of auto component product. *Journal of Business & Industrial Marketing*, 22(6), 388–396. <https://doi.org/10.1108/08858620710780236>
- Lu, C.-J., & Kao, L.-J. (2016). A clustering-based sales forecasting scheme by using extreme learning machine and ensembling linkage methods with applications to computer server. *Engineering Applications of Artificial Intelligence*, 55, 231–238. <https://doi.org/10.1016/j.engappai.2016.06.015>
- Lu, C.-J., & Wang, Y.-W. (2012). Sales forecasting for computer wholesalers: A comparison of multivariate adaptive regression splines and artificial neural networks. *Decision Support Systems*, 54(1), 584–596. <https://doi.org/10.1016/j.dss.2012.08.006>
- Manos, G., Giannakis, M., Katsikeas, C. S., & Wetzels, M. (2024). AI in sales: Laying the foundations for future research. *Journal of Personal Selling & Sales Management*, 44(2), 97–116. <https://doi.org/10.1080/08853134.2024.2329905>
- Mentzer, J. T., & Moon, M. A. (2005). *Sales forecasting management: A demand management approach* (2.^a ed.). Sage Publications.
- Monat, J. P. (2011). Industrial sales lead conversion modeling. *Marketing Intelligence & Planning*, 29(2), 178–194. <https://doi.org/10.1108/02634501111117610>
- Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., Shamseer, L., Tetzlaff, J. M., Akl, E. A., Brennan, S. E., Chou, R., Glanville, J., Grimshaw, J. M., Hróbjartsson, A., Lalu, M. M., Li, T., Loder, E. W., Mayo-Wilson, E., McDonald, S., ... Moher, D. (2021). The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. *BMJ*, 372, Article n71. <https://doi.org/10.1136/bmj.n71>
- Pavlyshenko, B. M. (2019). Machine-learning models for sales time series forecasting. *Data*, 4(1), Article 15. <https://doi.org/10.3390/data4010015>
- Pekkaya, M., Uysal, Z., Altan, A., & Karasu, S. (2024). Artificial intelligence-based evaluation of the factors affecting the sales of an iron and steel company. *Turkish Journal of Electrical Engineering and Computer Sciences*, 32(1), 51–67. <https://doi.org/10.55730/1300-0632.4055>
- Rezazadeh, A. (2020). A generalized flow for B2B sales predictive modeling: An Azure machine-learning approach. *Forecasting*, 2(3), 267–283. <https://doi.org/10.3390/forecast2030015>

- Rohaani, D., Topan, E., & Groothuis-Oudshoorn, C. G. M. (2022). Using supervised machine learning for B2B sales forecasting: A case study of spare parts sales forecasting at an after-sales service provider. *Expert Systems with Applications*, 188, Article 115925. <https://doi.org/10.1016/j.eswa.2021.115925>
- Snyder, H. (2019). Literature review as a research methodology: An overview and guidelines. *Journal of Business Research*, 104, 333–339. <https://doi.org/10.1016/j.jbusres.2019.07.039>
- Sohrabpour, V., Oghazi, P., Toorajipour, R., & Nazarpour, A. (2021). Export sales forecasting using artificial intelligence. *Technological Forecasting and Social Change*, 163, Article 120480. <https://doi.org/10.1016/j.techfore.2020.120480>
- Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: An analysis and review. *International Journal of Forecasting*, 16(4), 437–450. [https://doi.org/10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0)
- Tranfield, D., Denyer, D., & Smart, P. (2003). Towards a methodology for developing evidence-informed management knowledge by means of systematic review. *British Journal of Management*, 14(3), 207–222. <https://doi.org/10.1111/1467-8551.00375>
- Venkatesh, V., Morris, M. G., Davis, G. B., & Davis, F. D. (2003). User acceptance of information technology: Toward a unified view. *MIS Quarterly*, 27(3), 425–478. <https://doi.org/10.2307/30036540>
- Wang, Y.-H., Tsai, C.-F., & Chang, Y.-C. (2025). Identify key performance indicators to conduct demand and sales forecasting for container ships and capesize bulk carriers. *Computers & Industrial Engineering*, 205, Article 111178. <https://doi.org/10.1016/j.cie.2025.111178>
- Wisesa, O., Adriansyah, A., & Khalaf, O. I. (2020). Prediction analysis for business to business (B2B) sales of telecommunication services using machine learning techniques. *Majlesi Journal of Electrical Engineering*, 14(4), 145–153.
- Yuan, F.-C., & Lee, C.-H. (2020). Intelligent sales volume forecasting using Google search engine data. *Soft Computing*, 24(3), 2033–2047. <https://doi.org/10.1007/s00500-019-04039-9>
- Zhang, X., & Kim, T. (2023). A hybrid attention and time series network for enterprise sales forecasting under digital management and edge computing. *Journal of Cloud Computing*, 12, Article 13. <https://doi.org/10.1186/s13677-023-00406-6>

ÍNDICE DE TABLAS Y FIGURAS

Figuras

- Figura 1 - Diagrama de delimitación de las cuatro dimensiones conceptuales | pág. 5
- Figura 2 - Diagrama del resumen de diseño del estudio | pág. 8
- Figura 3 - Diagrama del proceso PRISMA2020 realizado para la selección y cribado del corpus | pág. 9
- Figura 4 - Gráficos descriptivos del corpus final de artículos seleccionados | pág. 18
- Figura 5 - Ejes de clasificación principales del corpus seleccionado | pág. 21
- Figura 6 - Cobertura de las dimensiones conceptuales dentro del corpus de artículos | pág. 26
- Figura 7 - Organización del corpus en familias según su tipología y contexto temporal | pág. 29
- Figura 8 - Jerarquización de las principales barreras identificadas en el corpus | pág. 46
- Figura 9 - Cobertura del corpus por dimensión conceptual y los vacíos actuales | pág. 57
- Figura 10 - Cronograma de propuesta doctoral A a 24 meses | pág. 62
- Figura 11 - Cronograma de propuesta doctoral B a 26 meses | pág. 65
- Figura 12 - Cadena jerárquica de limitaciones del presente estudio | pág. 69

Tablas

- Tabla 1 - Ficha técnica de metodología de búsqueda | pág. 11
- Tabla 2 - Criterios de Inclusión y su definición | pág. 12
- Tabla 3 - Criterios de Exclusión y su definición | pág. 12
- Tabla 4 - Puntuación del cribado de la fase 3 y su definición | pág. 13
- Tabla 5 - Dimensiones utilizadas para la priorización final con pesos, escalas y criterios | pág. 15
- Tabla 6 - Selección final del corpus de artículos con su puntuación de fase 4 | pág. 16
- Tabla 7 - Resumen del protocolo PRISMA2020 utilizado con nº de artículos y descartes | pág. 20
- Tabla 8 - Resumen del corpus en base a su tipología y contexto de estudio | pág. 25
- Tabla 9 - Evaluación del corpus en base a su contribución a la dimensión del marco conceptual | pág. 27
- Tabla 10 - Categorías de datos utilizados en el corpus | pág. 38
- Tabla 11 - Métricas de evaluación utilizados en el corpus | pág. 39
- Tabla 12 - Resultados comparativos de precisión: modelo propuesto frente a baseline en cada estudio | pág. 43
- Tabla 13 - Limitaciones declaradas por los autores del corpus analizado | pág. 51
- Tabla 14 - Resumen de vacíos detectados y futuras líneas de investigación | pág. 59
- Tabla 15 - Limitaciones detectadas del presente estudio por área de impacto | pág. 74